

Análisis Estadístico de la NBA: Reporte Completo

Análisis Exploratorio de Datos y Estadísticos Descriptivos

Dataset: Estadísticas Temporada Regular NBA (2010-2024)

Autores:

Daniela De La Caridad Guerrero Álvarez (C311)

Sammy Raul Sosa Justiz (C312)

Rubén Martínez Rojas (C311)

Índice

Introducción	3
1. Información General del Dataset	5
2. Clasificación de Variables Utilizadas	6
2.1. Variables Cualitativas	6
2.2. Variables Cuantitativas Discretas	6
2.3. Variables Cuantitativas Continuas	7
3. Variables Seleccionadas para el Análisis Estadístico	7
4. Estadísticos Descriptivos	8
4.1. Medidas de Tendencia Central y Dispersión	8
4.2. Análisis e Interpretación de los Estadísticos Descriptivos	8
5. Distribución Gráfica de las Variables	11
5.1. Boxplots y Detección de Valores Atípicos	14
5.2. Asimetría y Curtosis	15
5.3. Síntesis del Análisis Gráfico	16
5.4. Conclusión sobre la Distribución y Normalidad	16
6. Análisis de Correlaciones	17
6.1. Matriz de Correlación	17
6.2. Correlaciones Significativas	17
6.3. Conclusiones	17
7. Análisis de Outliers (Método IQR)	18
8. Transformaciones y Preprocesamiento de Datos	18
8.1. Manejo de Valores Faltantes	18
8.2. Codificación de Variables Categóricas	19
8.3. Estandarización y Normalización de Variables Numéricas	19
8.3.1. Diagnóstico de Escalas Diferentes	19
8.3.2. Transformaciones Aplicadas	20
8.4. Tratamiento de Valores Atípicos	20
8.5. Creación de Variables Derivadas Avanzadas	21
9. Análisis Estadístico de Preguntas de Investigación	22
9.1. Pregunta 1: Correlación FG3M vs Victoria	22
9.1.1. Análisis Chi-Cuadrado	22

9.1.2. Regresión Logística	22
9.2. Pregunta 2: Evolución Temporal de PTS y Triples	23
9.2.1. Regresión Lineal Simple	23
9.2.2. ANOVA por Temporada	23
9.3. Pregunta 3: Predictores de PLUS_MINUS	23
9.3.1. Regresión Lineal Múltiple	23
Conclusiones Finales	24

Introducción

El presente estudio se basa en el análisis de un conjunto de datos estadísticos oficiales de la National Basketball Association (NBA), correspondientes exclusivamente a partidos de **temporada regular** desde la temporada 2010 hasta la 2024. El dataset recoge información a nivel de equipo por partido, lo que permite evaluar el rendimiento colectivo y analizar patrones asociados al éxito competitivo en la liga a lo largo del tiempo, evitando los sesgos propios de los encuentros de posttemporada.

Los datos utilizados provienen de un archivo en formato `.csv`, específicamente:

- **regular_season_totals_2010_2024.csv**

Este archivo puede descargarse desde repositorios públicos de estadísticas deportivas basados en la API oficial de la NBA, como *NBA Stats*, así como desde plataformas académicas y repositorios de ciencia de datos utilizados para análisis estadístico y analítica avanzada.

El dataset almacena información detallada de cada partido de temporada regular, incluyendo variables de identificación (temporada, equipo y partido), el resultado del encuentro, estadísticas tradicionales de box score (puntos, rebotes, asistencias, tiros de campo, triples, pérdidas, robos, bloqueos y faltas), métricas de eficiencia (porcentajes de tiro) y estadísticas derivadas como el diferencial de puntos (PLUS_MINUS). Además, incorpora rankings relativos por temporada para múltiples categorías estadísticas, lo que permite realizar comparaciones relativas entre equipos durante el período analizado.

El análisis se estructura en torno a **tres preguntas de investigación principales**, las cuales guían la selección de variables y la aplicación de técnicas estadísticas, con el objetivo de estudiar tendencias del baloncesto moderno y determinar los factores más influyentes en el rendimiento de los equipos durante la temporada regular.

Pregunta 1

¿Existe una correlación significativa entre el número de triples anotados (FG3M) y la victoria (WL) de un equipo en un partido, controlando por la efectividad general de tiro (FG_PCT)?

Relevancia: El baloncesto moderno ha evolucionado hacia un mayor énfasis en el tiro de tres puntos. Entender si un mayor volumen de triples está asociado con mayores probabilidades de victoria, independientemente de la efectividad general de tiro, es clave para evaluar estrategias ofensivas y determinar si la filosofía de “vivir o morir por el triple” tiene un sustento estadístico sólido.

Variables involucradas:

- **Variable respuesta:**

- WL: Resultado del partido (Win/Loss).
- **Variables predictoras:**
 - FG3M: Triples anotados (Field Goals 3 Made).
 - FG_PCT: Porcentaje total de tiros de campo convertidos (Field Goal Percentage).

Pregunta 2

¿Cómo ha cambiado la media de puntos por partido (PTS) y el porcentaje de tiros de tres puntos intentados (FG3A/FGA) a lo largo de las temporadas (SEASON_YEAR), y existe una relación temporal significativa entre ambas variables?

Relevancia: La NBA ha experimentado una marcada “revolución del triple” en la última década. Analizar la evolución temporal de los puntos anotados y del uso del tiro de tres puntos permite cuantificar la transformación ofensiva de la liga y contextualizar el incremento en la producción anotadora observado en temporadas recientes.

Variables involucradas:

- **Variable temporal:**
 - SEASON_YEAR: Año de la temporada de la NBA.
- **Variables de interés:**
 - PTS: Puntos totales anotados por el equipo.
 - FG3A: Intentos de tiro de tres puntos (Field Goals 3 Attempted).
 - FGA: Intentos totales de tiro de campo (Field Goals Attempted).

Pregunta 3

¿Qué combinación de estadísticas de juego (por ejemplo, asistencias AST, rebotes REB, robos STL, porcentaje de tiros FG_PCT) predice de manera más robusta la diferencia de puntos (PLUS_MINUS) en un partido?

Relevancia: El estadístico plus-minus refleja el impacto neto de un equipo durante un partido. Identificar qué estadísticas de box score contribuyen de manera más significativa a un plus-minus positivo permite priorizar métricas de rendimiento colectivo y comprender mejor los factores asociados a la dominancia en el marcador.

Variables involucradas:

■ Variable respuesta:

- PLUS_MINUS: Diferencial de puntos del equipo en el partido.

■ Variables predictoras:

- AST: Asistencias (Assists).
- REB: Rebotes totales (Total Rebounds).
- STL: Robos de balón (Steals).
- BLK: Bloqueos realizados (Blocks).
- TOV: Pérdidas de balón (Turnovers).
- FG_PCT: Porcentaje de tiros de campo.
- FG3_PCT: Porcentaje de triples.
- FT_PCT: Porcentaje de tiros libres.

1. Información General del Dataset

El conjunto de datos utilizado corresponde a estadísticas por partido a nivel de equipo de la NBA, abarcando las temporadas desde 2010 hasta 2024. En la Tabla 1 se resumen las principales características del dataset.

Característica	Valor
Total de registros	1,231
Total de variables	52
Período cubierto	2010–2024
Equipos representados	30 equipos de la NBA
Valores nulos totales	202 (0.31 %)

Tabla 1: Características generales del dataset

Dado el amplio número de variables disponibles, para responder de manera precisa las preguntas de investigación se trabajará con un **subconjunto de variables relevantes**. Estas variables se seleccionan en función de su relación directa con el rendimiento ofensivo, defensivo y el resultado de los partidos, y se clasifican a continuación según su naturaleza estadística.

2. Clasificación de Variables Utilizadas

2.1. Variables Cualitativas

Estas variables describen características categóricas del partido o del equipo y se utilizan principalmente para identificación, segmentación de datos y análisis comparativos.

- **SEASON_YEAR**: Temporada de la NBA en la que se disputó el partido.
- **TEAM_ID**: Identificador numérico único del equipo.
- **TEAM_ABBREVIATION**: Abreviatura oficial del nombre del equipo.
- **TEAM_NAME**: Nombre completo del equipo.
- **GAME_ID**: Identificador único del partido.
- **GAME_DATE**: Fecha en la que se jugó el partido.
- **MATCHUP**: Información del enfrentamiento (local/visitante y rival).
- **WL**: Resultado del partido (Win/Loss).

Estas variables permiten estructurar el análisis temporal, identificar equipos y diferenciar entre partidos ganados y perdidos, siendo fundamentales para las pruebas de hipótesis y modelos de clasificación.

2.2. Variables Cuantitativas Discretas

Corresponden a conteos de eventos que ocurren durante un partido y reflejan el volumen de acciones de juego.

- **PTS**: Puntos totales anotados por el equipo en el partido.
- **AST**: Asistencias totales del equipo.
- **REB**: Rebotes totales del equipo (suma de ofensivos y defensivos).
- **FGM**: Tiros de campo convertidos.
- **FGA**: Tiros de campo intentados.
- **FG3M**: Triples convertidos.
- **FG3A**: Triples intentados.
- **TOV**: Pérdidas de balón.

- **STL**: Robos de balón.
- **BLK**: Tapones realizados.

Estas variables permiten cuantificar el volumen ofensivo y defensivo del equipo, y son clave para explicar diferencias en el marcador y el impacto global del desempeño colectivo.

2.3. Variables Cuantitativas Continuas

Estas variables representan proporciones, promedios o métricas con escala continua, y reflejan la eficiencia y el impacto neto del equipo.

- **FG_PCT**: Porcentaje de tiros de campo convertidos.
- **FG3_PCT**: Porcentaje de triples convertidos.
- **FT_PCT**: Porcentaje de tiros libres convertidos.
- **PLUS_MINUS**: Diferencia de puntos mientras el equipo estuvo en cancha.

Estas variables son fundamentales para evaluar la eficiencia ofensiva y el impacto real del equipo más allá del simple volumen de anotación.

3. Variables Seleccionadas para el Análisis Estadístico

A partir de la clasificación anterior, el análisis estadístico se centrará en las siguientes variables:

- **PTS**: para analizar la evolución ofensiva y su relación con otras métricas.
- **REB** y **AST**: como indicadores del control del juego y del juego colectivo.
- **FG_PCT**: para evaluar la eficiencia general de tiro.
- **PLUS_MINUS**: como medida del impacto neto del equipo en el partido.
- **FG3M** y **FG3A**: para estudiar la influencia del tiro de tres puntos en la victoria.
- **WL**: como variable respuesta en modelos de clasificación y pruebas de hipótesis.

Estas variables se seleccionan porque permiten responder directamente las preguntas de investigación planteadas, combinando volumen de juego, eficiencia y resultado final, y son adecuadas para la aplicación de técnicas estadísticas como regresión, pruebas de hipótesis y análisis multivariado.

4. Estadísticos Descriptivos

4.1. Medidas de Tendencia Central y Dispersión

La Tabla 2 presenta los principales estadísticos descriptivos de las variables seleccionadas, calculados a partir del conjunto de datos completo.

Tabla 2: Estadísticos descriptivos principales

	PTS	REB	AST	FG_PCT	PLUS_MINUS
Media	106.04	43.44	23.38	0.46	0.00
Mediana	106.00	43.00	23.00	0.459	0.00
Moda	104.00	43.00	24.00	0.500	-7.00
Desv. Estándar	13.59	6.60	5.27	0.056	14.17
Varianza	184.60	43.55	27.74	0.003	200.82
Coef. Variación	12.81 %	15.19 %	22.52 %	12.07 %	—
Mínimo	56.00	17.00	4.00	0.246	-73.00
Máximo	176.00	81.00	50.00	0.687	73.00
Rango	120.00	64.00	46.00	0.441	146.00
Q1	97.00	39.00	20.00	0.422	-9.00
Q3	115.00	48.00	27.00	0.500	9.00
IQR	18.00	9.00	7.00	0.078	18.00

4.2. Análisis e Interpretación de los Estadísticos Descriptivos

A partir de los estadísticos descriptivos presentados en la Tabla 2, se realiza a continuación un análisis detallado del comportamiento de cada variable seleccionada, con el objetivo de interpretar su significado estadístico y sus implicaciones en el contexto del rendimiento de los equipos en la NBA.

Puntos por partido (PTS)

La media de puntos por partido es de 106.04, con una mediana prácticamente idéntica (106.00), lo que indica una distribución aproximadamente simétrica de la anotación ofensiva. La moda, ubicada en 104 puntos, refuerza la idea de que la mayoría de los partidos se concentran alrededor de este valor.

La desviación estándar de 13.59 puntos y un rango amplio de 120 puntos (desde 56 hasta 176) evidencian una elevada variabilidad ofensiva entre partidos. Esta dispersión puede explicarse por diferencias en el ritmo de juego, el nivel del rival y el contexto competitivo de cada encuentro.

Desde un punto de vista analítico, esta variabilidad justifica el estudio de factores explicativos del rendimiento ofensivo y respalda la aplicación de modelos estadísticos para identificar qué variables influyen de manera significativa en la producción de puntos.

Rebotes totales (REB)

El número medio de rebotes por partido es de 43.44, con valores de mediana y moda iguales a 43, lo que refleja una distribución muy estable y centrada. La desviación estándar es relativamente baja (6.60), indicando una menor dispersión en comparación con la anotación.

El coeficiente de variación del 15.19 % sugiere que, aunque existen diferencias entre partidos, el rebote es una métrica consistente y menos sujeta a extremos. Esto indica que el control del rebote es una característica estructural del juego, más estable que otras métricas ofensivas.

Como consecuencia, los rebotes resultan especialmente útiles como variable explicativa en modelos que buscan analizar el impacto global del rendimiento del equipo, como el diferencial de puntos.

Asistencias (AST)

Las asistencias presentan una media de 23.38, con una mediana de 23 y una moda de 24, lo que indica que la mayoría de los equipos generan entre 20 y 25 asistencias por partido. Sin embargo, la desviación estándar de 5.27 y el coeficiente de variación del 22.52 % revelan una alta variabilidad relativa.

Esta dispersión refleja diferencias notables en los estilos de juego de los equipos, distinguiendo entre ofensivas más colectivas y otras más dependientes de acciones individuales. Por ello, AST captura no solo volumen de juego, sino también calidad del movimiento del balón.

En términos analíticos, esta variable es clave para explicar el rendimiento colectivo y resulta especialmente relevante en modelos multivariados que buscan predecir el diferencial de puntos.

Porcentaje de tiros de campo (FG_PCT)

El porcentaje medio de tiros de campo convertidos es de 0.46 (46 %), con una mediana muy cercana (45.9 %), lo que indica una eficiencia ofensiva relativamente estable en la liga. La desviación estándar es baja (0.056), confirmando que esta variable presenta una menor dispersión que las métricas de volumen.

El rango observado, que va desde 24.6 % hasta 68.7 %, corresponde a partidos atípicos, en los que se producen rendimientos excepcionalmente bajos o altos, generalmente asociados a encuentros muy desequilibrados.

FG_PCT constituye una variable fundamental para controlar la eficiencia ofensiva en los análisis estadísticos, permitiendo aislar el efecto de otras métricas como el tiro de tres puntos o las asistencias.

Diferencial de puntos (PLUS_MINUS)

El diferencial de puntos presenta una media y mediana iguales a 0.00, lo cual es coherente con un conjunto de datos que incluye tanto victorias como derrotas. Sin embargo, la desviación estándar es elevada (14.17) y el rango es extremadamente amplio, con valores entre -73 y 73 puntos.

Esta alta dispersión indica la coexistencia de partidos muy igualados con otros claramente desequilibrados. Debido a que la media es cero, el coeficiente de variación no resulta interpretable, por lo que el análisis de esta variable debe centrarse en su variabilidad absoluta.

Desde el punto de vista metodológico, la elevada dispersión de PLUS_MINUS justifica su elección como variable respuesta en modelos de regresión múltiple, ya que existe suficiente variabilidad para identificar relaciones significativas con otras estadísticas del juego.

Conclusión del análisis descriptivo

En conjunto, los resultados muestran que las variables de volumen ofensivo, como puntos y asistencias, presentan una mayor variabilidad, mientras que las métricas de eficiencia, como FG_PCT, son más estables. El diferencial de puntos es la variable con mayor dispersión, lo que la convierte en un indicador idóneo para analizar el impacto combinado de múltiples estadísticas.

Este análisis descriptivo proporciona una base sólida para la aplicación de técnicas estadísticas inferenciales y modelos multivariados en las siguientes secciones del estudio.

Análisis de la Distribución de Resultados

La variable WL representa el resultado final de cada partido, clasificándolo como victoria (W) o derrota (L). El análisis de su distribución es fundamental para evaluar el equilibrio del conjunto de datos y la posible presencia de sesgos en la variable objetivo.

Tabla 3: Distribución de resultados de partidos

Resultado	Frecuencia	Porcentaje
Derrota (L)	16658	50.00 %
Victoria (W)	16658	50.00 %

Los resultados muestran una distribución perfectamente balanceada, con 16,658 victorias y 16,658 derrotas, lo que corresponde exactamente al 50 % de los registros para cada categoría. Este equilibrio indica que el dataset no presenta predominancia de un resultado sobre otro, lo cual es deseable desde el punto de vista estadístico.

La ausencia de desbalance en la variable WL valida el uso posterior de técnicas inferenciales y de clasificación, como pruebas de hipótesis o regresión logística, sin necesidad de aplicar métodos de corrección por desbalance de clases. Asimismo, refuerza la representatividad del conjunto de datos para el análisis del rendimiento competitivo de los equipos.

5. Distribución Gráfica de las Variables

A continuación se presentan los histogramas y polígonos de frecuencias acumuladas de las variables cuantitativas más relevantes, que permiten visualizar la distribución de los datos y complementar el análisis estadístico descriptivo.

Distribución de Puntos (PTS)




Figura 1: Histograma de Puntos (PTS).
Media: 106.04, Mediana: 106.00




Figura 2: Polígono acumulado de Puntos (PTS)

La distribución de puntos por partido muestra una forma aproximadamente normal con centro alrededor de 106 puntos. El histograma revela una simetría en la distribución, confirmada por la proximidad entre media (106.04) y mediana (106.00). El polígono acumulado muestra que aproximadamente el 50 % de los partidos tienen menos de 106 puntos, con una progresión suave que indica ausencia de valores extremadamente concentrados.

Distribución de Rebotes (REB)




Figura 3: Histograma de Rebotes (REB).
Media: 43.44, Mediana: 43.00




Figura 4: Polígono acumulado de Rebotes (REB)

La distribución de rebotes presenta una forma aproximadamente normal con ligera asimetría hacia la derecha. La mayoría de los partidos se concentran entre 40 y 50 rebotes, siendo 43 el valor más frecuente. El polígono acumulado muestra una curva de crecimiento uniforme, indicando una distribución equilibrada sin agrupamientos anómalos.

Distribución de Asistencias (AST)




Figura 5: Histograma de Asistencias (AST). Media: 23.38, Mediana: 23.00




Figura 6: Polígono acumulado de Asistencias (AST)

Las asistencias muestran una distribución ligeramente asimétrica hacia la derecha, con valores típicos entre 20 y 27 asistencias por partido. La proximidad entre media (23.38) y mediana (23.00) sugiere una distribución razonablemente simétrica. El polígono acumulado presenta una curva suave, indicando una transición gradual entre los diferentes niveles de asistencia.

Distribución del Porcentaje de Tiro (FG_PCT)




Figura 7: Histograma de FG %. Media: 0.46, Mediana: 0.46




Figura 8: Polígono acumulado de FG %

El porcentaje de tiro presenta una distribución aproximadamente normal centrada en 0.46 (46 %), con coincidencia exacta entre media y mediana. La distribución es relativamente compacta, indicando consistencia en la eficiencia de tiro entre partidos. El polígono acumulado muestra una progresión uniforme, confirmando la homogeneidad de esta métrica.

Distribución del Diferencial de Puntos (PLUS_MINUS)




Figura 9: Histograma de PLUS_MINUS. Media: 0.00, Mediana: 0.00




Figura 10: Polígono acumulado de PLUS_MINUS

El diferencial de puntos muestra una distribución simétrica centrada en cero, como era de esperar en un conjunto de datos balanceado (igual número de victorias y derrotas). La forma aproximadamente normal con colas extendidas indica presencia de partidos con diferencias extremas. El polígono acumulado presenta una curva en forma de S invertida, típica de distribuciones simétricas, con punto de inflexión en el 50 % correspondiente al valor cero.

5.1. Boxplots y Detección de Valores Atípicos

Los diagramas de caja (boxplots) resumen la distribución mediante cuartiles y permiten identificar valores atípicos (outliers) de manera visual.




Figura 11: Boxplots de las principales variables del dataset.

Análisis de Boxplots (Figura 11):

- **PTS:** La distribución se centra alrededor de 106 puntos, con un rango intercuartílico aproximado entre 100 y 115. Se observan valores atípicos tanto por debajo como por encima del rango típico, correspondientes a partidos con anotaciones excepcionalmente bajas o altas.
- **AST:** Presenta una mediana cercana a 23 asistencias y una dispersión moderada. Los outliers reflejan partidos con volúmenes inusuales de generación ofensiva.
- **REB:** La mediana se sitúa alrededor de 43 rebotes, con una distribución relativamente simétrica. Los valores atípicos corresponden a partidos con dominio o déficit extremo en el rebote.
- **FG_PCT:** Muestra la menor dispersión relativa, con mediana cercana a 0.46. Los pocos outliers indican partidos con eficiencias de tiro excepcionalmente altas o bajas.
- **PLUS_MINUS:** Está centrado en cero, con una dispersión amplia y presencia de outliers en ambos extremos, reflejando partidos con diferenciales de puntos muy marcados.

5.2. Asimetría y Curtosis

Las medidas de asimetría y curtosis cuantifican desviaciones de la distribución normal.




Figura 12: Medidas de asimetría y curtosis para las variables principales.

Análisis de Asimetría y Curtosis (Figura 12):

■ Asimetría (Skewness):

- La mayoría de las variables presentan asimetría positiva leve, mientras que FG_PCT y PLUS_MINUS muestran distribuciones cercanas a la simetría.
- PLUS_MINUS presenta la mayor asimetría ($\text{skew} = 0,32$), seguido de AST (0,235) y REB (0,195).
- FG_PCT exhibe la menor asimetría (0,095), siendo la variable más cercana a una distribución simétrica.

■ Curtosis:

- Mide el "apuntamiento" de la distribución respecto a la normal.
- PLUS_MINUS presenta la mayor curtosis (0.32), indicando distribución más puntiaguda con colas más pesadas.
- PTS y FG_PCT tienen curtosis cercana a cero (0.015 y -0.03 respectivamente), sugiriendo formas similares a la normal.
- AST y REB muestran curtosis positiva moderada (0.06 y 0.09), con distribuciones ligeramente más apuntadas.

5.3. Síntesis del Análisis Gráfico

- **Normalidad:** Las variables PTS y FG_PCT muestran distribuciones más cercanas a la normal, con asimetría y curtosis mínimas. AST, REB y PLUS_MINUS presentan desviaciones notables de la normalidad.
- **Outliers:** Todas las variables exhiben valores atípicos significativos, especialmente en los extremos superiores. Esto sugiere la presencia frecuente de partidos con desempeños estadísticamente excepcionales.
- **Asimetría general:** La asimetría positiva predominante indica que, en general, las distribuciones tienen colas más largas hacia valores altos, reflejando la ocurrencia de partidos con estadísticas excepcionalmente buenas.
- **Consistencia métrica:** FG_PCT muestra el comportamiento más estable y simétrico, confirmando que el porcentaje de tiro es una métrica más consistente que las de volumen.
- **Consideraciones analíticas:** La presencia de asimetría y outliers justifica considerar transformaciones de datos o métodos robustos en análisis inferenciales posteriores.

5.4. Conclusión sobre la Distribución y Normalidad

El análisis gráfico y de medidas de forma revela que las variables presentan diferentes grados de aproximación a la distribución normal. Mientras PTS y FG_PCT muestran distribuciones razonablemente simétricas con curtosis cercana a cero (compatibles con normalidad), AST, REB y PLUS_MINUS exhiben asimetría positiva y mayor curtosis, desviándose significativamente del supuesto de normalidad. La presencia generalizada de valores atípicos en todas las variables indica la ocurrencia frecuente de partidos con desempeños extremos. Estas características distribucionales sugieren que, para análisis inferenciales rigurosos, deberían considerarse técnicas robustas o transformaciones de datos, especialmente para las variables con mayor asimetría y curtosis. No obstante, para muestras grandes como la analizada, muchos procedimientos estadísticos son relativamente robustos a estas desviaciones de normalidad.

6. Análisis de Correlaciones

Tabla 4: Matriz de correlación entre variables principales

	PTS	REB	AST	FG_PCT	PLUS_MINUS
PTS	1.000000	0.149700	0.618600	0.685500	0.521500
REB	0.149700	1.000000	0.051600	-0.170700	0.340200
AST	0.618600	0.051600	1.000000	0.559100	0.396200
FG_PCT	0.685500	-0.170700	0.559100	1.000000	0.546900
PLUS_MINUS	0.521500	0.340200	0.396200	0.546900	1.000000

6.1. Matriz de Correlación

La Tabla 4 presenta la matriz de correlación entre las principales variables estadísticas analizadas, permitiendo identificar la intensidad y dirección de las relaciones lineales entre ellas.

6.2. Correlaciones Significativas

- **PTS – FG_PCT:** $r = 0,6855$ (correlación alta positiva). Existe una relación fuerte entre el porcentaje de tiro y los puntos anotados, lo que confirma que la eficiencia ofensiva es un factor clave en la producción anotadora.
- **PTS – AST:** $r = 0,6186$ (correlación moderada-alta positiva). Las asistencias muestran una asociación significativa con los puntos, reflejando la importancia del juego colectivo en la generación de anotaciones.
- **PTS – PLUS_MINUS:** $r = 0,5215$ (correlación moderada positiva). Un mayor volumen de puntos se relaciona con un diferencial positivo, indicando impacto directo del rendimiento ofensivo en el resultado del partido.
- **FG_PCT – PLUS_MINUS:** $r = 0,5469$ (correlación moderada positiva). La efectividad en el tiro contribuye de forma consistente a mejores diferenciales de puntos.
- **REB – FG_PCT:** $r = -0,1707$ (correlación débil negativa). Esta relación sugiere que un mayor volumen de rebotes no está necesariamente asociado con una mayor eficiencia de tiro, posiblemente reflejando diferencias de rol o estilo de juego.

6.3. Conclusiones

El análisis de correlaciones confirma que la NBA actual está fuertemente influenciada por la eficiencia ofensiva. La relación elevada entre FG_PCT y PTS ($r = 0,69$) consolida al

porcentaje de tiro como el principal predictor del volumen anotador, superando la influencia de variables como los rebotes. Asimismo, las correlaciones moderadas con PLUS_MINUS indican que el rendimiento ofensivo tiene un impacto directo en el diferencial final de puntos, reforzando la relevancia estratégica de la eficiencia en el baloncesto moderno.

7. Análisis de Outliers (Método IQR)

Tabla 5: Detección de outliers usando el método IQR

Variable	Total	Outliers	%	Límite Inf.	Límite Sup.
PTS	33316	231	0.69	70.0	142.0
REB	33316	229	0.69	25.5	61.5
AST	33316	260	0.78	9.5	37.5
PLUS_MINUS	33316	460	1.38	-36.0	36.0

La Tabla 5 presenta la detección de valores atípicos utilizando el método del rango intercuartílico (IQR), definido por los límites $Q_1 - 1,5 \cdot IQR$ y $Q_3 + 1,5 \cdot IQR$.

Los resultados muestran que el porcentaje de outliers es reducido en todas las variables analizadas, con valores inferiores al 1.5 % incluso en un conjunto de datos de gran tamaño ($n = 33,316$), lo que indica una alta estabilidad estadística del dataset.

La variable PLUS_MINUS presenta la mayor proporción de valores atípicos (1.38 %), lo cual es consistente con su naturaleza altamente dependiente del contexto del partido y de diferencias extremas de anotación. Sin embargo, esta proporción sigue siendo baja en términos absolutos, por lo que no compromete la validez del análisis global.

En conjunto, la baja incidencia de outliers confirma la calidad del conjunto de datos y respalda el uso de técnicas estadísticas paramétricas en los análisis posteriores.

8. Transformaciones y Preprocesamiento de Datos

El preprocesamiento de datos constituye una etapa fundamental para garantizar la consistencia y calidad del análisis estadístico posterior. En esta sección se describen las transformaciones aplicadas al conjunto de datos NBA correspondiente al período 2010–2024, enfocándose únicamente en las variables utilizadas en los análisis posteriores.

8.1. Manejo de Valores Faltantes

Se realizó un análisis sistemático de valores faltantes sobre las variables seleccionadas para el estudio: PTS, REB, AST, FG_PCT y PLUS_MINUS. Los resultados se resumen en la Tabla 6.

Tabla 6: Tratamiento de valores faltantes en las variables analizadas

Variable	Valores Faltantes	Porcentaje (%)	Tratamiento Aplicado
PTS	0	0.000	No requiere tratamiento
REB	0	0.000	No requiere tratamiento
AST	0	0.000	No requiere tratamiento
FG_PCT	0	0.000	No requiere tratamiento
PLUS_MINUS	0	0.000	No requiere tratamiento

Dado que no se detectaron valores faltantes en ninguna de las variables analizadas, no fue necesario aplicar técnicas de imputación ni realizar transformaciones adicionales en esta etapa. Este resultado garantiza la integridad de los datos y permite proceder directamente con las etapas de escalado y modelado estadístico.

8.2. Codificación de Variables Categóricas

Las variables categóricas contienen información cualitativa que debe transformarse a formato numérico para su uso en modelos estadísticos. En este estudio, únicamente se consideró necesaria la codificación de la variable objetivo WL, correspondiente al resultado del partido.

La variable WL es de naturaleza dicotómica, tomando los valores W (victoria) y L (derrota). Para su incorporación en modelos de regresión y clasificación, se realizó una codificación binaria estándar, definida como:

$$WL_{bin} = \begin{cases} 1 & \text{si el partido termina en victoria (W)} \\ 0 & \text{si el partido termina en derrota (L)} \end{cases}$$

Esta codificación es ampliamente utilizada en regresión logística y otros modelos lineales generalizados, ya que permite interpretar los coeficientes estimados en términos de cambios en probabilidad u *odds ratio*.

8.3. Estandarización y Normalización de Variables Numéricas

8.3.1. Diagnóstico de Escalas Diferentes

Variable	Media	Desviación Estándar	Rango
PTS	106.04	13.59	120.00
AST	23.38	5.27	46.00
REB	43.44	6.60	64.00
FG_PCT	0.46	0.056	0.441
PLUS_MINUS	0.00	14.17	146.00

Tabla 7: Estadísticos que evidencian escalas diferentes (valores reales)

Problema identificado: Las variables están en unidades incomparables, por ejemplo:

- Puntos en escala 100 (106 ± 13.59)
- Porcentajes en escala 0.5 (0.46 ± 0.056)
- Diferenciales centrados en 0 con gran rango (0 ± 14.17)

Consecuencias de no estandarizar:

1. Algoritmos basados en distancias (K-Means, K-NN, PCA) se verían dominados por variables de mayor rango.
2. Coeficientes de regresión múltiple y logística no serían comparables.
3. Algoritmos de optimización numérica (gradiente descendente) convergerían más lentamente.

8.3.2. Transformaciones Aplicadas

1. **Estandarización Z-score:** aplicada a PTS, AST, REB, STL, BLK, TOV para centrar en 0 y escala 1.
2. **Normalización Min-Max:** aplicada a FG_PCT, FG3_PCT y FT_PCT para reescalar en $[0,1]$.

Nota: Transformaciones adicionales como Box-Cox o log no se aplicaron de forma generalizada, dado que las desviaciones de normalidad y outliers observados fueron leves, y el tamaño de muestra grande garantiza robustez suficiente para las pruebas posteriores.

8.4. Tratamiento de Valores Atípicos

Variable	Outliers	Porcentaje	Tratamiento y Justificación
PLUS_MINUS	460	1.4 %	Winsorizing al 5 %-95 %: Partidos extremadamente desbalanceados distorsionan varianza.
PTS	231	0.7 %	Mantenidos: Partidos históricos de alta puntuación son eventos válidos e informativos.
AST	260	0.8 %	Mantenidos: Récorde de asistencias representan desempeños excepcionales reales.
FG_PCT	275	0.8 %	Mantenidos: Eficiencias extremas son métricas legítimas de rendimiento.

Tabla 8: Estrategia de tratamiento de outliers

Método de Winsorizing aplicado:

$$X_{\text{winsor}} = \begin{cases} Q_{0,05} & \text{si } X < Q_{0,05} \\ Q_{0,95} & \text{si } X > Q_{0,95} \\ X & \text{en otro caso} \end{cases}$$

Justificación del tratamiento diferencial:

- **PLUS_MINUS:** Los valores extremos representan partidos anómalos que pueden distorsionar análisis de varianza y correlación. Winsorizing preserva el tamaño muestral mientras mitiga su influencia.
- **PTS, AST, FG_PCT:** Los outliers en estas variables representan récords y desempeños históricos legítimos que contienen información valiosa sobre el límite superior del rendimiento humano en baloncesto.
- **Enfoque robusto:** Para análisis sensibles a outliers, se utilizarán métodos robustos (medianas, regresión robusta) complementariamente.

8.5. Creación de Variables Derivadas Avanzadas

Las variables originales del dataset capturan estadísticas básicas, pero no necesariamente métricas avanzadas de rendimiento. Se crearon las siguientes variables derivadas:

Variable Derivada	Fórmula y Cálculo	Propósito Analítico
POSS (Posesiones)	$\text{FGA} - \text{OREB} + \text{TOV} + 0,4 \times \text{FTA}$	Estimación estándar NBA de posesiones por partido
PACE (Ritmo)	$\frac{\text{POSS}}{\text{MIN}} \times 48$	Ritmo de juego ajustado a 48 minutos
OFF_EFF (Eficiencia Ofensiva)	$\frac{\text{PTS}}{\text{POSS}} \times 100$	Puntos por 100 posesiones (métrica estándar NBA)
AST_TO_RATIO (Ratio Asist/Pérdida)	$\frac{\text{AST}}{\text{TOV}}$	Eficiencia en distribución del balón
FG3A_RATE (Tasa de Triples)	$\frac{\text{FG3A}}{\text{FGA}}$	Porcentaje de tiros que son de tres puntos
EFFICIENT_SCORING	$\text{FG_PCT} + 0,5 \times \text{FG3_PCT}$	Métrica ponderada que valora más los triples

Tabla 9: Variables derivadas creadas para análisis avanzado

Justificación de cada variable derivada:

- **POSS y PACE:** Permiten comparar equipos independientemente del ritmo de juego, controlando por diferencias en posesiones.

- **OFF_EFF**: Considerada la métrica más importante de eficiencia ofensiva en baloncesto moderno, ya que controla por oportunidades de anotación.
- **AST_TO_RATIO**: Combina creatividad ofensiva (asistencias) con cuidado del balón (pérdidas) en una sola métrica.
- **FG3A_RATE**: Cuantifica directamente la revolución del triple” que motiva la Pregunta 1 de investigación.
- **EFFICIENT_SCORING**: Reconoce que un triple anotado al 40 % es equivalente a un tiro de 2 anotado al 60 %, capturando la eficiencia real de anotación.

9. Análisis Estadístico de Preguntas de Investigación

9.1. Pregunta 1: Correlación FG3M vs Victoria

9.1.1. Análisis Chi-Cuadrado

Objetivo: Determinar si existe asociación significativa entre FG3M y WL.

FG3M	Derrota	Victoria	Total
Bajo	9633	6897	16530
Medio	6917	9238	16155
Alto	108	523	631

Tabla 10: Tabla de contingencia FG3M vs WL

Estadístico	Valor
χ^2	1059.25
Grados de libertad	2
Valor p	<0.001
V de Cramér	0.178

Tabla 11: Resultados Chi-Cuadrado ($\alpha = 0.05$)

9.1.2. Regresión Logística

$$\text{Modelo: } \log\left(\frac{P(Win)}{1-P(Win)}\right) = \beta_0 + \beta_1 \cdot FG3M + \beta_2 \cdot FG_PCT$$

Variable	Coeficiente	Odds Ratio
FG3M	0.21	1.23
FG_PCT	1.08	2.93

Tabla 12: Coeficientes de regresión logística

Conclusión: La filosofía de vivir o morir por el triple tiene respaldo estadístico.

9.2. Pregunta 2: Evolución Temporal de PTS y Triples

9.2.1. Regresión Lineal Simple

Objetivo: Cuantificar la relación temporal entre la temporada y PTS/FG3A.

Variable	Pendiente	R^2	Valor p	Sig.
PTS	+1.47 pts/temp	0.922	<0.001	Sí
FG3A/FGA	+1.58 %/temp	0.952	<0.001	Sí

Tabla 13: Regresión lineal simple ($\alpha = 0.05$)

9.2.2. ANOVA por Temporada

Objetivo: Verificar diferencias significativas entre temporadas.

Variable	F	Valor p	Decisión
PTS	647.86	<0.001	Rechazar H_0
FG3A/FGA	1950.55	<0.001	Rechazar H_0

Tabla 14: ANOVA por temporada ($\alpha = 0.05$)

Conclusión: La NBA ha experimentado una transformación ofensiva significativa, con aumentos de 1.5 puntos y 1.6 % en triples por temporada.

9.3. Pregunta 3: Predictores de PLUS_MINUS

9.3.1. Regresión Lineal Múltiple

Objetivo: Identificar qué estadísticas predicen mejor PLUS_MINUS.

Variable	β	Error	t	p-valor
AST	-0.070	0.012	-5.97	<0.001***
REB	1.088	0.008	136.15	<0.001***
STL	1.167	0.018	66.38	<0.001***
TOV	-0.815	0.013	-62.17	<0.001***
FG_PCT	166.414	1.129	147.39	<0.001***

Tabla 15: Coeficientes de regresión. ***p<0.001

Estadístico	Valor
R^2	0.585
R^2 ajustado	0.585
F-estadístico	9400.22

Tabla 16: Bondad de ajuste

Conclusión: El modelo explica el 58.5 % de la variabilidad. FG_PCT es el predictor más fuerte.

Conclusiones Finales

- El análisis exploratorio revela distribuciones normales para la mayoría de las variables estadísticas principales.
- Las correlaciones más fuertes se observan entre puntos y porcentaje de tiro, confirmando la importancia de la eficiencia en el baloncesto moderno.
- La detección de outliers indica partidos extremos que podrían merecer análisis más detallado.
- El dataset presenta alta calidad de datos con valores nulos mínimos y consistencia en las relaciones entre variables.