

Análisis Estadístico de la NBA: Reporte Completo

Análisis Exploratorio de Datos y Estadísticos Descriptivos

Dataset: Estadísticas Temporada Regular NBA (2010-2024)

Autores:

Daniela De La Caridad Guerrero Álvarez (C311)

Sammy Raul Sosa Justiz (C312)

Rubén Martínez Rojas (C311)

Índice

Introducción	3
1. Estadísticos Descriptivos	7
1.1. Medidas de Tendencia Central y Dispersión	7
1.2. Análisis e Interpretación de los Estadísticos Descriptivos	7
1.3. Análisis de la Distribución de Resultados	13
1.4. Análisis gráfico de las distribuciones	13
1.5. Boxplots y Detección de Valores Atípicos	19
2. Pregunta 1: Análisis de la Relación entre Triples y Victoria	24
2.1. Regresión logística binaria	25
2.1.1. Evaluación de supuestos y resultados del modelo logístico	26
2.2. Prueba de Mann–Whitney U para el número de triples anotados (FG3M)	28
2.2.1. Preparación de los datos	28
2.2.2. Hipótesis planteadas	29
2.2.3. Resultados e interpretación	29
2.2.4. Conclusión de la prueba	30
3. Pregunta 2: Análisis de la Evolución Temporal del Juego	31
3.1. Ejecución de ANOVA	31
3.1.1. Preparación de los datos	32
3.2. Hipótesis estadísticas	32
3.3. Resultados del ANOVA	33
3.4. Regresión lineal para el análisis temporal (Pregunta 2)	35
3.5. Regresión lineal para el análisis temporal (Pregunta 2)	35
3.5.1. Preparación de los datos	36
3.5.2. Detalles del modelo	36
3.6. Análisis de los resultados del modelo	37
3.6.1. Resultados del modelo para PTS	38
3.6.2. Resultados del modelo para FG3A/FGA	38
3.6.3. Conclusión de la prueba	39
3.7. Conclusion General de la pregunta	39
4. Pregunta 3: Análisis de Predictores del Diferencial de Puntos	39
4.1. Preparación de los datos	42
4.2. Análisis gráfico de relaciones lineales con PLUS_MINUS	42
4.3. Análisis de Componentes Principales y regresión	47
4.3.1. Modelo Estadístico	48

4.3.2. Hipótesis Estadísticas	49
4.4. Análisis del funcionamiento del modelo de regresión	49
4.5. Conclusiones	51

Introducción

El presente estudio se basa en el análisis de un conjunto de datos estadísticos oficiales de la National Basketball Association (NBA), correspondientes exclusivamente a partidos de temporada regular desde la temporada 2010 hasta la 2024. El dataset recoge información a nivel de equipo por partido, lo que permite evaluar el rendimiento colectivo y analizar patrones asociados al éxito competitivo en la liga a lo largo del tiempo, evitando los sesgos propios de los encuentros de posttemporada.

Los datos utilizados provienen del archivo en formato .csv: `regular_season_totals_2010_2024.csv`, el cual puede descargarse desde el repositorio de GitHub [Repositorio NBA Data 2010–2024](#).

El dataset almacena información detallada de cada partido de temporada regular, incluyendo variables de identificación (temporada, equipo y partido), el resultado del encuentro, estadísticas tradicionales de box score (puntos, rebotes, asistencias, tiros de campo, triples, pérdidas, robos, bloqueos y faltas), métricas de eficiencia (porcentajes de tiro) y estadísticas derivadas como el diferencial de puntos (PLUS_MINUS). Además, incorpora rankings relativos por temporada para múltiples categorías estadísticas, lo que permite realizar comparaciones relativas entre equipos durante el período analizado.

El análisis se estructura en torno a tres preguntas de investigación principales, las cuales guían la selección de variables y la aplicación de técnicas estadísticas, con el objetivo de estudiar tendencias del baloncesto moderno y determinar los factores más influyentes en el rendimiento de los equipos durante la temporada regular.

Preguntas de Investigación

Pregunta 1

El baloncesto moderno ha evolucionado hacia un mayor énfasis en el tiro de tres puntos. Entender si un mayor volumen de triples está asociado con mayores probabilidades de victoria, independientemente de la efectividad general de tiro, es clave para evaluar estrategias ofensivas y determinar si la filosofía de “vivir o morir por el triple” tiene un sustento estadístico sólido, por eso nos preguntamos:

¿Existe una correlación significativa entre el número de triples anotados (FG3M) y la victoria (WL) de un equipo en un partido, controlando por la efectividad general de tiro (FG_PCT)?

Para su análisis se utilizarán:

Como variable respuesta:

WL: Resultado del partido (Win/Loss).

Como variables predictoras:

FG3M: Triples anotados (Field Goals 3 Made).

FG_PCT: Porcentaje total de tiros de campo convertidos (Field Goal Percentage).

Pregunta 2

La NBA ha experimentado una marcada “revolución del triple” en la última década, caracterizada por un aumento sostenido en el uso del tiro de tres puntos y en la producción ofensiva. Analizar la evolución temporal de los puntos anotados y del porcentaje de triples intentados permite cuantificar esta transformación del juego, evaluar si el incremento en la anotación está asociado al mayor protagonismo del tiro exterior y contextualizar los cambios estratégicos observados en temporadas recientes, por esto aparece la pregunta:

¿Como ha cambiado la media de puntos por partido (PTS) y el porcentaje de tiros de tres puntos intentados (FG3A/FGA) a lo largo de las temporadas (SEASON_YEAR), y existe una relación temporal significativa entre ambas variables?

Para su análisis se utilizarán:

Como variable temporal:

SEASON_YEAR: Año de la temporada de la NBA.

Como variables de interés:

PTS: Puntos totales anotados por el equipo.

FG3A: Intentos de tiro de tres puntos (Field Goals 3 Attempted).

FGA: Intentos totales de tiro de campo (Field Goals Attempted).

Pregunta 3

El estadístico plus-minus refleja el impacto neto de un equipo durante un partido, ya que mide la diferencia de puntos mientras el equipo está en cancha. Identificar qué estadísticas del box score contribuyen de manera más significativa a un plus-minus positivo permite priorizar métricas de rendimiento colectivo y comprender mejor los factores asociados a la dominancia en el marcador, por esto aparece la pregunta:

¿Que combinación de estadísticas de juego (por ejemplo, asistencias AST, rebotes REB, robos STL, porcentaje de tiros FG_PCT) predice de manera más robusta la diferencia de puntos (PLUS_MINUS) en un partido?

Para su análisis se utilizarán:

Como variable respuesta:

PLUS_MINUS: Diferencial de puntos del equipo en el partido.

Como variables predictoras:

AST: Asistencias (Assists).

REB: Rebotes totales (Total Rebounds).

STL: Robos de balón (Steals).

BLK: Bloqueos realizados (Blocks).

TOV: Pérdidas de balón (Turnovers).

FG_PCT: Porcentaje de tiros de campo.

FG3_PCT: Porcentaje de triples.

FT_PCT: Porcentaje de tiros libres.

Análisis Exploratorio de Datos

El conjunto de datos utilizado corresponde a estadísticas por partido a nivel de equipo de la NBA, abarcando las temporadas desde 2010 hasta 2024. En la siguiente tabla se resumen las principales características del dataset.

Característica	Valor
Total de registros	1,231
Total de variables	52
Período cubierto	2010–2024
Equipos representados	30 equipos de la NBA
Valores nulos totales	202 (0.31 %)

Tabla 1: Características generales del dataset

Dado el amplio número de variables disponibles, para responder de manera precisa las preguntas de investigación se trabajará con un subconjunto de variables relevantes. Estas variables se seleccionan en función de su relación directa con el rendimiento ofensivo, defensivo y el resultado de los partidos, y se clasifican a continuación según su naturaleza estadística.

Variables cuantitativas continuas

Corresponden a variables numéricas que pueden tomar valores reales dentro de un intervalo y que se utilizan principalmente para medir eficiencia, proporciones y diferenciales.

- FG_PCT: porcentaje total de tiros de campo convertidos.
- FG3_PCT: porcentaje de triples convertidos.
- FT_PCT: porcentaje de tiros libres convertidos.
- FG3A/FGA: proporción de intentos de tiro de tres puntos respecto al total de tiros de campo.
- PLUS_MINUS: diferencial de puntos del equipo en el partido.

Variables cuantitativas discretas

Son variables numéricas que representan conteos enteros de eventos ocurridos durante el partido.

- PTS: puntos totales anotados por el equipo.
- FG3M: triples anotados.
- FG3A: intentos de tiro de tres puntos.
- AST: asistencias.
- REB: rebotes totales.
- STL: robos de balón.
- BLK: bloqueos realizados.
- TOV: pérdidas de balón.

Variables cualitativas

Incluyen variables categóricas que describen características no numéricas o resultados del partido.

- WL: resultado del partido (victoria o derrota).
- SEASON_YEAR: año de la temporada, utilizada como variable temporal para el análisis de tendencias.

Esta clasificación permite seleccionar y transformar adecuadamente las variables durante el preprocesamiento del dataset, facilitando la aplicación coherente de técnicas estadísticas como regresión logística binaria, análisis de varianza, regresión lineal simple y múltiple, y análisis de componentes principales, en concordancia con los objetivos del estudio.

1. Estadísticos Descriptivos

1.1. Medidas de Tendencia Central y Dispersión

La Tabla ?? presenta los principales estadísticos descriptivos de las variables seleccionadas, calculados a partir del conjunto de datos completo.

Tabla 2: Estadísticos descriptivos para el análisis exploratorio de datos

	PTS	REB	AST	STL	BLK	PLUS_MINUS
Media	106.040000	43.444000	23.384000	7.624000	4.879000	0.000000
Mediana	106.000000	43.000000	23.000000	7.000000	5.000000	0.000000
Moda	104.000000	43.000000	24.000000	7.000000	4.000000	-7.000000
Desv. Estándar	13.587000	6.599000	5.267000	2.899000	2.535000	14.171000
Varianza	184.599000	43.552000	27.740000	8.406000	6.428000	200.816000
Coef. Var. (%)	12.813000	15.191000	22.523000	38.031000	51.965000	—
Mínimo	56.000000	17.000000	4.000000	0.000000	0.000000	-73.000000
Máximo	176.000000	81.000000	50.000000	22.000000	20.000000	73.000000
Rango	120.000000	64.000000	46.000000	22.000000	20.000000	146.000000
Q1	97.000000	39.000000	20.000000	6.000000	3.000000	-9.000000
Q3	115.000000	48.000000	27.000000	9.000000	6.000000	9.000000
IQR	18.000000	9.000000	7.000000	3.000000	3.000000	18.000000

1.2. Análisis e Interpretación de los Estadísticos Descriptivos

A partir de los estadísticos descriptivos presentados en la Tabla ??, se realiza a continuación un análisis detallado del comportamiento de cada variable seleccionada, con el objetivo de interpretar su significado estadístico y sus implicaciones en el contexto del rendimiento de los equipos en la NBA.

Puntos por partido (PTS)

La media de puntos por partido es de 106.04, con una mediana prácticamente idéntica (106.00), lo que indica una distribución aproximadamente simétrica de la anotación ofensiva. La moda, ubicada en 104 puntos, refuerza la idea de que la mayoría de los partidos se concentran alrededor de este valor.

La desviación estándar de 13.59 puntos y un rango amplio de 120 puntos (desde 56 hasta 176) evidencian una elevada variabilidad ofensiva entre partidos. Esta dispersión puede explicarse por diferencias en el ritmo de juego, el nivel del rival y el contexto competitivo de cada encuentro.

Rebotes totales (REB)

El número medio de rebotes por partido es de 43.44, con valores de mediana y moda iguales a 43, lo que refleja una distribución muy estable y centrada. La desviación estándar es relativamente baja (6.60), indicando una menor dispersión en comparación con la anotación.

El coeficiente de variación del 15.19% sugiere que, aunque existen diferencias entre partidos, el rebote es una métrica consistente y menos sujeta a extremos. Esto indica que el control del rebote es una característica estructural del juego, más estable que otras métricas ofensivas.

Asistencias (AST)

Las asistencias presentan una media de 23.38, con una mediana de 23 y una moda de 24, lo que indica que la mayoría de los equipos generan entre 20 y 25 asistencias por partido. Sin embargo, la desviación estándar de 5.27 y el coeficiente de variación del 22.52% revelan una alta variabilidad relativa.

Esta dispersión refleja diferencias notables en los estilos de juego de los equipos, distinguiendo entre ofensivas más colectivas y otras más dependientes de acciones individuales. Por ello, AST captura no solo volumen de juego, sino también calidad del movimiento del balón.

Robos de balón (STL)

La media de robos por partido es de 7.62, con una mediana de 7 y una moda también igual a 7, lo que indica que la mayoría de los equipos registran entre 6 y 8 robos por encuentro. Esta coincidencia entre las medidas de tendencia central sugiere una distribución relativamente simétrica y bien concentrada alrededor de su valor medio.

La desviación estándar es de 2.90 robos, acompañada de un coeficiente de variación del 38.03%, lo que evidencia una alta variabilidad relativa. El rango observado, que va desde 0 hasta 22 robos, pone de manifiesto la existencia de partidos con una presión defensiva muy baja frente a otros con una actividad defensiva excepcional.

Bloqueos (BLK)

El número medio de bloqueos por partido es de 4.88, con una mediana de 5 y una moda de 4, lo que indica que la mayoría de los equipos registran entre 4 y 6 tapones

por encuentro. La cercanía entre estas medidas sugiere una distribución moderadamente simétrica, aunque con ligeras asimetrías derivadas de partidos atípicos.

La desviación estándar es de 2.54 bloqueos y el coeficiente de variación alcanza el 51.97 %, el valor más alto entre las variables analizadas. Este resultado evidencia una elevada variabilidad relativa, indicando que los bloqueos presentan una gran dispersión entre partidos.

El rango, que se extiende desde 0 hasta 20 bloqueos, refleja diferencias marcadas en la protección del aro, asociadas principalmente a la presencia o ausencia de jugadores interiores dominantes y al enfoque defensivo del equipo.

Porcentaje de tiros de campo (FG_PCT)

El porcentaje medio de tiros de campo convertidos es de 0.46 (46 %), con una mediana muy cercana (45.9 %), lo que indica una eficiencia ofensiva relativamente estable en la liga. La desviación estándar es baja (0.056), confirmando que esta variable presenta una menor dispersión que las métricas de volumen.

El rango observado, que va desde 24.6 % hasta 68.7 %, corresponde a partidos atípicos, en los que se producen rendimientos excepcionalmente bajos o altos, generalmente asociados a encuentros muy desequilibrados.

Diferencial de puntos (PLUS_MINUS)

El diferencial de puntos presenta una media y mediana iguales a 0.00, lo cual es coherente con un conjunto de datos que incluye tanto victorias como derrotas. Sin embargo, la desviación estándar es elevada (14.17) y el rango es extremadamente amplio, con valores entre -73 y 73 puntos.

Esta alta dispersión indica la coexistencia de partidos muy igualados con otros claramente desequilibrados. Debido a que la media es cero, el coeficiente de variación no resulta interpretable, por lo que el análisis de esta variable debe centrarse en su variabilidad absoluta.

Tabla 3: Estadísticos descriptivos para el análisis exploratorio de datos

	FG3M	FG3A	FG3_PCT	FG_PCT	FT_PCT	TOV
Media	9.870000	27.547000	0.356000	0.460000	0.767000	14.202000
Mediana	10.000000	27.000000	0.355000	0.459000	0.773000	14.000000
Moda	9.000000	26.000000	0.333000	0.500000	0.750000	14.000000
Desv. Estándar	4.255000	9.153000	0.098000	0.056000	0.103000	3.905000
Varianza	18.104000	83.785000	0.010000	0.003000	0.011000	15.247000
Coef. Var. (%)	43.110000	33.228000	27.397000	12.071000	13.471000	27.494000
Mínimo	0.000000	3.000000	0.000000	0.246000	0.000000	1.000000
Máximo	29.000000	70.000000	0.842000	0.687000	1.000000	31.000000
Rango	29.000000	67.000000	0.842000	0.441000	1.000000	30.000000
Q1	7.000000	21.000000	0.292000	0.422000	0.700000	11.000000
Q3	13.000000	34.000000	0.419000	0.500000	0.839000	17.000000
IQR	6.000000	13.000000	0.127000	0.078000	0.139000	6.000000

Triples convertidos (FG3M)

El promedio de triples convertidos por partido es de 9.87, con una mediana de 10 y una moda de 9, lo que indica que la mayoría de los equipos encestan alrededor de 9 a 10 triples por encuentro. La cercanía entre estas medidas de tendencia central sugiere una distribución relativamente simétrica, centrada en valores medios.

La desviación estándar de 4.26 y el coeficiente de variación del 43.11 % evidencian una elevada variabilidad relativa. El rango observado, que va desde 0 hasta 29 triples, refleja diferencias marcadas entre partidos con escasa eficacia desde el perímetro y otros con un alto volumen de acierto exterior.

Triples intentados (FG3A)

El número medio de triples intentados por partido es de 27.55, con una mediana de 27 y una moda de 26, lo que indica que la mayoría de los equipos lanzan entre 25 y 30 triples por encuentro. La proximidad entre la media y la mediana sugiere una distribución aproximadamente simétrica.

La desviación estándar es de 9.15 y el coeficiente de variación alcanza el 33.23 %, reflejando una variabilidad considerable en el volumen de lanzamientos exteriores. El rango, que se extiende desde 3 hasta 70 intentos, pone de manifiesto la coexistencia de estilos ofensivos muy distintos, desde esquemas centrados en el juego interior hasta ofensivas altamente orientadas al tiro exterior.

Porcentaje de triples convertidos (FG3_PCT)

El porcentaje medio de triples convertidos es de 0.356 (35.6 %), con una mediana prácticamente idéntica (35.5 %), lo que indica una eficiencia exterior relativamente estable

en la liga. La desviación estándar es de 0.098, reflejando una dispersión moderada en la efectividad desde el perímetro.

El rango observado, que va desde 0 % hasta 84.2 %, corresponde a partidos atípicos, en los que se producen rendimientos extremadamente bajos o excepcionalmente altos, generalmente asociados a muestras pequeñas de intentos o a encuentros muy desequilibrados.

El coeficiente de variación del 27.40 % sugiere que, aunque la eficiencia exterior presenta cierta variabilidad, esta es menor que la observada en las métricas de volumen, como FG3M o FG3A.

Porcentaje de tiros de campo (FG_PCT)

El porcentaje medio de tiros de campo convertidos es de 0.46 (46 %), con una mediana muy cercana (45.9 %), lo que indica una eficiencia ofensiva general estable a lo largo de los partidos. La desviación estándar es baja (0.056), confirmando que esta variable presenta una dispersión limitada.

El coeficiente de variación del 12.07 % refuerza la idea de que FG_PCT es una métrica consistente, menos sensible a fluctuaciones extremas que las variables de volumen. El rango, que va desde 24.6 % hasta 68.7 %, corresponde a partidos atípicos con rendimientos ofensivos muy por debajo o por encima del promedio.

Porcentaje de tiros libres (FT_PCT)

El porcentaje medio de tiros libres convertidos es de 0.767 (76.7 %), con una mediana de 77.3 % y una moda de 75 %, lo que indica una eficiencia relativamente alta y estable desde la línea de tiros libres. La desviación estándar es de 0.103, mostrando una dispersión moderada.

El coeficiente de variación del 13.47 % sugiere que, aunque existen diferencias entre partidos, la efectividad en tiros libres es una métrica consistente y menos volátil que otras estadísticas ofensivas. El rango observado, que se extiende desde 0 % hasta 100 %, corresponde a situaciones extremas poco frecuentes, generalmente asociadas a un número reducido de intentos.

Pérdidas de balón (TOV)

El número medio de pérdidas de balón por partido es de 14.20, con una mediana y una moda iguales a 14, lo que indica una distribución centrada y relativamente simétrica. La desviación estándar es de 3.91, reflejando una variabilidad moderada entre partidos.

El coeficiente de variación del 27.49 % sugiere que las pérdidas de balón presentan una dispersión considerable, aunque menor que la observada en variables como los triples

convertidos. El rango, que va desde 1 hasta 31 pérdidas, evidencia la coexistencia de partidos con un control del balón muy eficiente y otros con numerosos errores no forzados.

Conclusión del análisis descriptivo

En conjunto, el análisis descriptivo evidencia una clara diferenciación entre variables de volumen, variables de eficiencia y métricas asociadas al control del juego. Las estadísticas de volumen ofensivo, como puntos (PTS), triples intentados (FG3A), triples convertidos (FG3M) y asistencias (AST), presentan una elevada variabilidad relativa, reflejando diferencias sustanciales en el ritmo de juego y en los estilos ofensivos de los equipos. Estas variables aportan información relevante sobre la identidad táctica de los equipos, aunque son más sensibles al contexto del partido.

Por el contrario, las métricas de eficiencia, como el porcentaje de tiros de campo (FG_PCT) y el porcentaje de tiros libres (FT_PCT), muestran una dispersión considerablemente menor, lo que las convierte en indicadores estables del rendimiento ofensivo. Su menor variabilidad sugiere que capturan la calidad de ejecución más que el volumen de juego, siendo especialmente útiles para comparaciones consistentes entre equipos y partidos.

Las variables que presentan los valores extremos más pronunciados son el diferencial de puntos (PLUS_MINUS), los intentos de triple (FG3A) y los triples convertidos (FG3M). En particular, PLUS_MINUS exhibe el mayor rango y desviación estándar, reflejando la coexistencia de partidos muy igualados con otros altamente desequilibrados. Esta característica lo convierte en una variable clave para evaluar el impacto combinado de múltiples estadísticas y para identificar escenarios de dominancia o colapso competitivo.

Asimismo, las pérdidas de balón (TOV) y los robos (STL) muestran una variabilidad moderada-alta, aportando información relevante sobre el control del balón y la presión defensiva. Estas métricas resultan especialmente útiles para explicar diferencias de rendimiento que no se reflejan directamente en la anotación, pero que influyen de manera decisiva en la posesión y el flujo del juego.

En síntesis, los valores extremos observados en las variables de volumen y en el diferencial de puntos aportan información crítica para el análisis estadístico posterior, ya que permiten identificar patrones asociados a partidos atípicos y a desempeños excepcionalmente altos o bajos. Esta diversidad en la dispersión de las variables justifica la aplicación de modelos estadísticos multivariados, en los que la combinación de métricas de volumen, eficiencia y control del juego permite capturar de forma más completa la complejidad del rendimiento de los equipos en la NBA.

1.3. Análisis de la Distribución de Resultados

La variable WL representa el resultado final de cada partido, clasificándolo como victoria (W) o derrota (L). El análisis de su distribución es fundamental para evaluar el equilibrio del conjunto de datos y la posible presencia de sesgos en la variable objetivo.

Tabla 4: Distribución de resultados de partidos

Resultado	Frecuencia	Porcentaje
Derrota (L)	16658	50.00 %
Victoria (W)	16658	50.00 %

Los resultados muestran una distribución perfectamente balanceada, con 16,658 victorias y 16,658 derrotas, lo que corresponde exactamente al 50 % de los registros para cada categoría. Este equilibrio indica que el dataset no presenta predominancia de un resultado sobre otro, lo cual es deseable desde el punto de vista estadístico.

La ausencia de desbalance en la variable WL valida el uso posterior de técnicas inferenciales y de clasificación, como pruebas de hipótesis o regresión logística, sin necesidad de aplicar métodos de corrección por desbalance de clases. Asimismo, refuerza la representatividad del conjunto de datos para el análisis del rendimiento competitivo de los equipos.

1.4. Análisis gráfico de las distribuciones

Con el objetivo de profundizar en la estructura estadística de las variables y complementar el análisis descriptivo previo, se realiza a continuación un estudio gráfico basado en histogramas y polígonos de frecuencias acumuladas. Estas representaciones permiten evaluar la forma de las distribuciones, identificar posibles asimetrías, concentraciones de valores y la presencia de observaciones extremas, aspectos que no siempre resultan evidentes a partir de los estadísticos resumen.

Dado el elevado número de variables cuantitativas disponibles en el conjunto de datos, el análisis gráfico se organiza de manera selectiva y estructurada. En primer lugar, se agrupan aquellas variables que presentan distribuciones aproximadamente normales y un comportamiento estadístico estable, caracterizado por una alta similitud en la forma, la dispersión y la relación entre media y mediana. Para este grupo, se muestran únicamente algunas variables representativas, con el fin de ilustrar el patrón común observado y evitar redundancias innecesarias en la presentación gráfica.

Posteriormente, se analizan de forma individual aquellas variables cuya distribución presenta características diferenciadas, ya sea por su mayor asimetría, su escala acotada, su naturaleza discreta o su significado competitivo específico dentro del juego. En estos casos, la representación gráfica aporta información relevante para la interpretación de cada métrica, justificando un análisis separado de sus histogramas y polígonos acumulados.

Esta organización permite equilibrar claridad expositiva y profundidad analítica, asegurando que el análisis gráfico se centre en aquellas variables donde la visualización aporta un valor interpretativo real, y sentando una base sólida para los modelos estadísticos inferenciales que se desarrollarán en secciones posteriores.

Variables con distribución aproximadamente normal y comportamiento estable

Las variables PTS, AST, REB, FG3M, FG3A y TOV presentan distribuciones con un comportamiento estadístico similar, caracterizado por una forma aproximadamente normal, una estrecha correspondencia entre media y mediana, y una dispersión moderada. Estas características indican que dichas métricas describen fenómenos recurrentes y estructurales del juego, asociados al ritmo ofensivo, la generación colectiva, el control del balón y la producción global de puntos.

En todos los casos, los histogramas muestran una concentración clara alrededor de valores centrales, mientras que los polígonos acumulados exhiben curvas suaves y simétricas, lo que confirma la estabilidad de estas variables a lo largo del conjunto de partidos analizados. La presencia de valores extremos es limitada y coherente con contextos competitivos particulares, sin alterar el patrón general de las distribuciones.

Dado el alto grado de similitud en la forma y comportamiento estadístico de estas variables, la representación gráfica individual de todas ellas resultaría redundante y no aportaría información adicional relevante al análisis descriptivo. Por este motivo, se selecciona un conjunto representativo de variables para su visualización mediante histogramas y polígonos acumulados, utilizando dichas gráficas como ejemplos ilustrativos del comportamiento común observado en el grupo. Las variables restantes comparten patrones análogos, por lo que su interpretación se infiere directamente a partir de las distribuciones mostradas.

Desde el punto de vista analítico, estos resultados sugieren que dichas variables aportan información complementaria pero consistente, siendo especialmente adecuadas para su utilización conjunta en análisis multivariados posteriores, donde actúan como indicadores robustos del volumen y la organización del juego.




Figura 1: Histograma de Puntos Totales (PTS). Media: 106.04, Mediana: 106.00




Figura 2: Polígono acumulado de PTS




Figura 3: Histograma de Asistencias (AST). Media: 23.38, Mediana: 23.00




Figura 4: Polígono acumulado de Asistencias (AST)




Figura 5: Histograma de Rebotes Totales (REB). Media: 43.44, Mediana: 43.00




Figura 6: Polígono acumulado de REB

Variables restantes

Dada la diversidad en la forma, dispersión y significado estadístico de estas variables, se realiza un análisis gráfico individual para cada una. Este enfoque permite capturar las particularidades de sus distribuciones y resaltar aquellos rasgos que resultan rele-

vantes para la interpretación del juego y para su incorporación en modelos estadísticos posteriores.

Distribución del Porcentaje de Triples (FG3_PCT)




Figura 7: Histograma de Porcentaje de Triples (FG3_PCT)




Figura 8: Polígono acumulado de FG3 %

El porcentaje de triples presenta una distribución aproximadamente normal con centro alrededor del 35 %-40 %. La distribución es más dispersa que la de tiros de campo generales, reflejando la mayor variabilidad inherente al tiro de tres puntos. La simetría observada sugiere que los valores extremos (tanto muy bajos como muy altos) son igualmente probables. El polígono acumulado muestra una curva en forma de S suave, confirmando la naturaleza simétrica de la distribución, con aproximadamente el 50 % de los partidos registrando un porcentaje inferior al 40 %.

Distribución del Porcentaje de Tiros Libres (FT_PCT)




Figura 9: Histograma de Porcentaje de Tiros Libres (FT_PCT). Media: 0.77, Mediana: 0.77




Figura 10: Polígono acumulado de FT %

El porcentaje de tiros libres presenta una distribución asimétrica con cola hacia la izquierda, centrada en 0.77 (77 %). La coincidencia exacta entre media y mediana ocurre

en una distribución no simétrica debido a la compensación entre valores. La concentración principal se observa entre 0.7 y 0.85, indicando que la mayoría de los partidos tienen una eficiencia en tiros libres dentro de este rango. El polígono acumulado muestra una progresión inicial rápida que luego se estabiliza, reflejando que aproximadamente el 80 % de los partidos tienen un porcentaje superior al 70 %.

Distribución del Diferencial de Puntos (PLUS_MINUS)




Figura 11: Histograma de Diferencial de Puntos (PLUS_MINUS). Media: 0.00, Mediana: 0.00




Figura 12: Polígono acumulado de PLUS_MINUS

El diferencial de puntos muestra una distribución perfectamente simétrica centrada en cero, como era de esperar en un conjunto de datos balanceado que incluye tanto victorias como derrotas. La forma aproximadamente normal con colas extendidas indica la presencia de partidos con diferencias extremas en ambas direcciones. La coincidencia exacta entre media y mediana en cero confirma el perfecto equilibrio de la distribución. El polígono acumulado presenta la clásica forma de S invertida, con punto de inflexión exactamente en el 50 %, indicando que la mitad de los partidos tienen diferencial negativo y la otra mitad positivo.

Distribución de Robos de Balón (STL)




Figura 13: Histograma de Robos de Balón (STL). Media: 7.62, Mediana: 7.00




Figura 14: Polígono acumulado de STL

Los robos de balón muestran una distribución claramente asimétrica con cola hacia la derecha, típica de variables con límite inferior en cero. La diferencia entre media (7.62) y mediana (7.00) confirma esta asimetría. La mayoría de los partidos registran entre 5 y 10 robos, con una frecuencia que disminuye rápidamente para valores superiores. El polígono acumulado muestra una curva de crecimiento rápido inicial que luego se suaviza, indicando que aproximadamente el 80 % de los partidos tienen menos de 10 robos.

Distribución de Bloques (BLK)




Figura 15: Histograma de Bloques (BLK). Media: 4.88, Mediana: 5.00




Figura 16: Polígono acumulado de Bloques (BLK)

La distribución de bloques por partido muestra una asimetría marcada hacia la derecha, típica de variables con límite inferior en cero. La mayoría de los partidos registran entre 2.5 y 7.5 bloques, con un pico alrededor de 5 bloques. La proximidad entre media (4.88) y mediana (5.00) sugiere una distribución razonablemente equilibrada pese a la asimetría. El polígono acumulado presenta una curva de crecimiento rápido inicial que luego se suaviza, indicando que aproximadamente el 80 % de los partidos tienen menos de 10 bloques.

Distribución de la Proporción de Triples Intentados (FG3A/FGA)




Figura 17: Histograma de Proporción FG3A/FGA. Media: 0.32, Mediana: 0.32




Figura 18: Polígono acumulado de FG3A/FGA

La proporción de triples intentados respecto al total de tiros muestra una distribución aproximadamente normal centrada en 0.32 (32 %), con coincidencia exacta entre media y mediana. Esto indica que, en promedio, aproximadamente un tercio de los tiros de campo son intentos de tres puntos. La distribución compacta alrededor de este valor sugiere una relativa homogeneidad en las estrategias ofensivas entre equipos y partidos. El polígono acumulado muestra una curva suave y simétrica, confirmando la consistencia en esta proporción, con aproximadamente el 50 % de los partidos registrando una proporción inferior al 32 %.

1.5. Boxplots y Detección de Valores Atípicos

Con el objetivo de complementar el análisis descriptivo previo basado en histogramas y polígonos acumulados, se emplean boxplots para examinar la dispersión, simetría y presencia de valores atípicos en las variables cuantitativas seleccionadas. Este tipo de representación permite identificar de manera sintética la estructura central de los datos mediante la mediana, el rango intercuartílico y los extremos no atípicos, así como detectar observaciones extremas que pueden resultar relevantes en el contexto competitivo o para la especificación de modelos estadísticos posteriores.

Resumen del grupo: métricas de volumen, tiro exterior y control del juego

Las variables incluidas en este grupo (*PTS*, *FG3M*, *FG3A*, *AST*, *REB* y *TOV*) representan métricas de **volumen ofensivo, generación colectiva, orientación al tiro exterior y control del ritmo de juego**. En conjunto, los boxplots muestran distribuciones mayormente simétricas, con medias y medianas próximas, lo que sugiere un comportamiento estable de estas variables a lo largo del conjunto de partidos analizados. Los rangos intercuartílicos son moderados en todas las métricas, indicando que, si

bien existe variabilidad natural entre encuentros, el desempeño del equipo se concentra alrededor de valores centrales bien definidos.

Un rasgo común del grupo es la presencia de **valores atípicos en ambos extremos**, asociados a partidos con condiciones excepcionales, como ritmos de juego inusualmente altos o bajos, diferencias marcadas en el nivel de los oponentes o ajustes tácticos específicos. Estos valores no alteran la estructura central de las distribuciones, pero aportan información relevante sobre escenarios de desempeño extremo.

Desde una perspectiva comparativa, cada variable resalta un aspecto particular del juego. *PTS* sintetiza el resultado final de la producción ofensiva total; *AST* refleja el grado de juego colectivo y la circulación del balón; *REB* captura el control físico y posicional del partido; *TOV* actúa como un indicador inverso del orden y la eficiencia en la ejecución ofensiva. En relación con el tiro exterior, *FG3A* evidencia la orientación táctica hacia el lanzamiento de tres puntos, mientras que *FG3M* muestra una mayor dispersión, confirmando el carácter situacional y dependiente del acierto de esta variable dentro del juego.

En conjunto, estas métricas ofrecen una visión coherente y complementaria del estilo de juego del equipo. Por esta razón, se presenta únicamente una selección representativa de boxplots, evitando redundancias descriptivas sin pérdida de información analítica relevante.




Figura 19: Boxplots representativos del grupo de métricas de volumen ofensivo, tiro exterior y control del juego.

Resumen del grupo: métricas de eficiencia y perfil de tiro

Las variables incluidas en este grupo (FG_PCT , $FG3_PCT$, FT_PCT y $FG3A/FGA$) describen la **eficiencia ofensiva y la orientación del lanzamiento** del equipo. En conjunto, los boxplots muestran distribuciones claramente más concentradas que las observadas en métricas de volumen, lo que refleja una mayor estabilidad relativa en los porcentajes de acierto a lo largo de los partidos analizados.

Un rasgo común del grupo es la **proximidad entre media y mediana**, lo que sugiere distribuciones aproximadamente simétricas y un comportamiento consistente en términos de eficiencia. Sin embargo, se observa una diferencia clara entre métricas: FG_PCT y FT_PCT presentan rangos intercuartílicos reducidos, indicando una elevada estabilidad, mientras que $FG3_PCT$ exhibe una dispersión notablemente mayor, confirmando el carácter más volátil del tiro de tres puntos.

La variable $FG3A/FGA$ aporta una perspectiva complementaria al describir el **perfil táctico de lanzamiento** más que la eficiencia en sí. Su dispersión moderada y la escasa presencia de valores atípicos sugieren que, aunque existen variaciones estratégicas entre partidos, la proporción de tiros de tres puntos se mantiene dentro de un rango relativamente homogéneo.

En conjunto, estos boxplots permiten diferenciar claramente entre métricas de eficiencia estable (FG_PCT , FT_PCT), métricas altamente dependientes del contexto ($FG3_PCT$) y métricas de estilo ofensivo ($FG3A/FGA$), justificando su análisis conjunto y evitando redundancias descriptivas mediante la presentación de una selección representativa.




Figura 20: Boxplots de las métricas de eficiencia y perfil de tiro.

Boxplot del Diferencial de Puntos (PLUS_MINUS)

El boxplot de PLUS_MINUS se caracteriza por una perfecta simetría alrededor de cero, con mediana y media coincidentes y un rango intercuartílico amplio ($IQR = 18$). Este comportamiento es consistente con un conjunto de datos balanceado que incluye tanto victorias como derrotas. La presencia de numerosos valores atípicos en ambos extremos refleja partidos con diferencias marcadas en el marcador, representativos de contextos

competitivos desiguales o rendimientos excepcionales.




Figura 21: Boxplot del diferencial de puntos (PLUS_MINUS).

Boxplot de los Robos de Balón (STL)

La variable STL exhibe un boxplot claramente asimétrico hacia la derecha, con mediana de 7 robos y un rango intercuartílico reducido ($IQR = 3$). La elevada cantidad de valores atípicos superiores indica la existencia de partidos con presión defensiva intensa y alta capacidad de recuperación de balón. Esta asimetría es característica de variables de conteo con límite inferior en cero y confirma que los robos representan eventos menos frecuentes pero altamente dependientes del contexto defensivo y del rival.




Figura 22: Boxplot de los robos de balón (STL).

Boxplot de los Bloqueos (BLK)

El boxplot de BLK muestra una mediana de 5 bloqueos por partido y un rango intercuartílico de 3, con una distribución también asimétrica hacia la derecha. La proximidad entre media y mediana sugiere un equilibrio razonable en la estructura central, aunque la presencia de numerosos valores atípicos elevados refleja partidos con una actividad defensiva excepcional cerca del aro. Este comportamiento confirma que los bloqueos, al igual que los robos, son eventos discretos y situacionales, sensibles a la composición del equipo y al tipo de ataque rival.




Figura 23: Boxplot de los bloqueos (BLK).

2. Pregunta 1: Análisis de la Relación entre Triples y Victoria

¿Existe una correlación significativa entre el número de triples anotados (FG3M) y la victoria (WL) de un equipo en un partido, controlando por la efectividad general de tiro (FG_PCT)?

Con el objetivo de responder de forma robusta a la Pregunta 1, se adoptó un enfoque estadístico complementario que combina un modelo de regresión logística binaria con una prueba no paramétrica de comparación de grupos Mann–Whitney U. Esta estrategia permite evaluar la relación entre el número de triples anotados y la probabilidad de victoria desde dos perspectivas estadísticas coherentes pero conceptualmente distintas.

2.1. Regresión logística binaria

La regresión logística se emplea como herramienta principal de modelación, dado que la variable respuesta es dicotómica (WL: victoria/derrota). Este modelo permite cuantificar el efecto marginal del número de triples anotados (FG3M) sobre la probabilidad de ganar un partido, controlando simultáneamente por la efectividad general de tiro (FG_PCT). En este contexto, el objetivo de la regresión logística es evaluar si el volumen de triples posee un impacto estadísticamente significativo sobre la probabilidad de victoria, independientemente de la eficiencia ofensiva global, expresando los resultados en términos de odds ratios, fácilmente interpretables en el ámbito deportivo.

Previo a la estimación del modelo de regresión logística binaria, se realizó una preparación y exploración de las variables con el objetivo de garantizar la validez estadística del análisis y justificar la metodología empleada.

La variable respuesta fue codificada de forma binaria como WL_bin, donde 1 representa victoria y 0 derrota, lo cual es coherente con la naturaleza dicotómica requerida por la regresión logística. Como variables predictoras se utilizaron el número de triples anotados (FG3M) y el porcentaje total de tiros de campo convertidos (FG_PCT), seleccionadas por su relevancia directa en la producción ofensiva y su vínculo teórico con la probabilidad de victoria.

El análisis se planteó bajo las siguientes hipótesis inferenciales:

- Hipótesis principal del modelo logístico:

$$H_0 : \beta_{\text{FG3M}} = 0 \quad \text{vs.} \quad H_1 : \beta_{\text{FG3M}} \neq 0$$

lo que implica contrastar si el número de triples anotados tiene un efecto estadísticamente significativo sobre la probabilidad de victoria, controlando por la efectividad general de tiro.

- Hipótesis auxiliar:

$$H_0 : \beta_{\text{FG_PCT}} = 0 \quad \text{vs.} \quad H_1 : \beta_{\text{FG_PCT}} \neq 0$$

evaluando el impacto de la eficiencia ofensiva total en el resultado del partido.

Cada observación del conjunto de datos corresponde a un partido distinto, por lo que se asume independencia entre observaciones. Este supuesto se considera satisfecho por el propio diseño del experimento observacional, al no existir mediciones repetidas ni dependencia temporal directa entre filas.

A diferencia de los modelos lineales clásicos, la regresión logística no requiere normalidad de las variables explicativas ni homocedasticidad de los residuos, ya que la variable

respuesta sigue una distribución binomial y el modelo se estima mediante máxima verosimilitud. En consecuencia, la ausencia de normalidad en variables como FG3M no invalida el uso de este modelo.

2.1.1. Evaluación de supuestos y resultados del modelo logístico

La correlación de Spearman entre FG3M y FG_PCT fue $\rho = 0,280$ con un valor-p de $p = 0,0000$.

Tabla 5: Factores de Inflación de la Varianza (VIF)

Variable	VIF
const	69.646
FG3M	1.096
FG_PCT	1.096

Tabla 6: Coeficientes del modelo Logit

	Coeficiente	Std.Error	z	p-value
const	-9.4013	0.1272	-73.9209	0.0000
FG3M	0.0496	0.0031	16.1441	0.0000
FG_PCT	19.3723	0.2787	69.5131	0.0000

Tabla 7: Odds Ratios e intervalos de confianza al 95 %

	OR	CI 2.5\ %	CI 97.5\ %
const	0.0001	0.0001	0.0001
FG3M	1.0508	1.0445	1.0572
FG_PCT	258998289.0146	149995784.2750	447213326.9393

Tabla 8: Métricas de ajuste del modelo

Métrica	Valor
Pseudo R^2 (McFadden)	0.1683
Log-Likelihood	-19206.1154
AIC	38418.2308
N Observaciones	33316.0000

Antes de estimar el modelo de regresión logística, se evaluó la posible dependencia entre las variables explicativas con el objetivo de descartar problemas de multicolinealidad. Para ello, se calculó la correlación de Spearman entre FG3M y FG_PCT, obteniéndose

un coeficiente $\rho = 0,280$ con un valor-p $p < 0,001$. Este resultado indica la existencia de una asociación positiva de magnitud moderada, lo cual sugiere que ambas variables están relacionadas, pero no de forma lo suficientemente intensa como para generar inestabilidad en la estimación de los parámetros del modelo.

Este diagnóstico se confirma mediante los Factores de Inflación de la Varianza (VIF), presentados en la Tabla 5. Los valores de VIF para **FG3M** y **FG_PCT** son cercanos a 1, muy por debajo de los umbrales habitualmente utilizados para identificar multicolinealidad problemática ($VIF > 5$ o > 10). En consecuencia, se concluye que ambas variables pueden ser incluidas simultáneamente en el modelo sin comprometer la estabilidad ni la interpretabilidad de los coeficientes estimados.

Una vez verificados los supuestos estructurales básicos, se procedió a la estimación del modelo de regresión logística binaria. Los coeficientes estimados, sus errores estándar y niveles de significación se presentan en la Tabla 6. El modelo converge correctamente, lo que indica estabilidad en el proceso de maximización de la verosimilitud.

Los resultados muestran que ambas variables explicativas tienen un efecto positivo y estadísticamente significativo sobre la probabilidad de victoria. En particular, el coeficiente asociado a **FG3M** es positivo ($\hat{\beta} = 0,0496$, $p < 0,001$), lo que implica que, manteniendo constante la efectividad de tiro, un aumento en el número de triples anotados incrementa la probabilidad de ganar el partido. De forma análoga, **FG_PCT** presenta un coeficiente positivo de gran magnitud ($\hat{\beta} = 19,37$, $p < 0,001$), reflejando el papel central de la eficiencia ofensiva en el resultado final del encuentro.

Para facilitar la interpretación de estos efectos, la Tabla 7 presenta los correspondientes *odds ratios*. En este contexto, un incremento unitario en **FG3M** multiplica las probabilidades de victoria por un factor aproximado de 1.05, mientras que aumentos en **FG_PCT** se asocian con un crecimiento muy pronunciado de las probabilidades de éxito, coherente con la fuerte influencia de la eficiencia de tiro observada en los coeficientes del modelo.

Finalmente, la calidad global del ajuste se resume en la Tabla 8. El pseudo coeficiente de determinación de McFadden ($R^2 = 0,168$) indica que el modelo explica una proporción relevante de la variabilidad del resultado del partido, especialmente considerando la naturaleza binaria del fenómeno analizado. Asimismo, los valores del log-verosímil y del criterio de información de Akaike (AIC) respaldan la adecuación del modelo como una representación parsimoniosa y estadísticamente sólida de la relación entre el rendimiento en tiros de tres puntos y la probabilidad de victoria.

En conjunto, los resultados del análisis evidencian que el número de triples anotados tiene un efecto positivo y estadísticamente significativo sobre la probabilidad de victoria, incluso al controlar por la efectividad general de tiro. La magnitud y significación de los coeficientes estimados confirman que tanto el volumen de anotación desde la línea de tres puntos como la eficiencia ofensiva contribuyen de forma independiente al éxito

del equipo. Asimismo, los diagnósticos de multicolinealidad indican que ambas variables aportan información complementaria, permitiendo concluir que el incremento en triples convertidos aumenta la probabilidad de ganar un partido más allá del efecto explicado únicamente por la precisión en el tiro.

2.2. Prueba de Mann–Whitney U para el número de triples anotados (FG3M)

Como complemento al análisis multivariado basado en regresión logística, se aplicó la prueba no paramétrica de Mann–Whitney U con el objetivo de comparar la distribución del número de triples anotados (FG3M) entre partidos ganados y partidos perdidos. Esta prueba permite evaluar si existen diferencias sistemáticas en el volumen de triples entre ambos grupos sin asumir normalidad ni homocedasticidad, condiciones que no se cumplen para esta variable según el análisis exploratorio previo.

La utilización de esta prueba resulta especialmente adecuada en este contexto debido al carácter discreto de la variable FG3M y a la presencia de asimetrías y valores extremos, frecuentes en estadísticas de rendimiento deportivo. A diferencia de las pruebas paramétricas (como la prueba *t* de Student), la prueba de Mann–Whitney no requiere que la variable analizada siga una distribución normal ni que las varianzas de ambos grupos sean iguales. En este sentido, la prueba aporta una comparación robusta entre grupos y complementa los resultados obtenidos mediante la regresión logística, al ofrecer evidencia directa sobre las diferencias observadas en los datos sin imponer restricciones paramétricas.

En consecuencia, el diseño del estudio y la naturaleza de los datos garantizan el cumplimiento de los supuestos necesarios para la aplicación de la prueba de Mann–Whitney U. La independencia entre observaciones, la adecuada escala de medición de FG3M y la independencia entre los grupos de partidos ganados y perdidos permiten interpretar los resultados de la prueba con validez estadística, asegurando que las conclusiones derivadas reflejan diferencias reales en la distribución del número de triples anotados.

2.2.1. Preparación de los datos

Antes de la realización de la prueba se seleccionaron únicamente las observaciones con información válida en las variables *WL* (resultado del partido) y *FG3M* (triples anotados). Posteriormente, los partidos se dividieron en dos grupos independientes: victorias ($WL = W$) y derrotas ($WL = L$). Ambos grupos presentan tamaños muestrales idénticos ($N = 16\,658$), lo que refuerza la robustez de la comparación.

El análisis exploratorio previo, mediante histogramas y boxplots, evidenció que la distribución de FG3M es asimétrica, presenta colas largas y valores atípicos, lo que invalida los supuestos de normalidad y homocedasticidad necesarios para pruebas paramétricas.

Por tanto, la elección de una prueba no paramétrica resulta adecuada y metodológicamente justificada.

La variable FG3M es una variable discreta de conteo, con distribución asimétrica y presencia de valores atípicos, características que justifican el uso de una prueba no paramétrica basada en rangos en lugar de pruebas paramétricas como la t de Student.

2.2.2. Hipótesis planteadas

La prueba de Mann–Whitney U se utilizó para contrastar las siguientes hipótesis:

- H_0 : La distribución del número de triples anotados (FG3M) es la misma en partidos ganados y partidos perdidos.
- H_1 : La distribución del número de triples anotados (FG3M) difiere entre partidos ganados y partidos perdidos.

Desde una perspectiva sustantiva, la hipótesis alternativa implica que los partidos ganados tienden a presentar valores sistemáticamente mayores de triples anotados que los partidos perdidos.

2.2.3. Resultados e interpretación

Tabla 9: Estadísticos descriptivos de FG3M por resultado del partido

Grupo	N	Mediana FG3M	Q1	Q3
Victorias	16658	10.000	8.000	14.000
Derrotas	16658	9.000	6.000	12.000

Tabla 10: Resultados de la prueba de Mann–Whitney U para FG3M

U statistic	Z value	p value	Effect size r
170661761.0000	36.3631	0.0000	0.1992

Los estadísticos descriptivos presentados en la Tabla 9 muestran que la mediana de triples anotados en los partidos ganados (Mediana = 10) es superior a la observada en los partidos perdidos (Mediana = 9). Asimismo, los cuartiles primero y tercero del grupo de victorias ($Q1 = 8$, $Q3 = 14$) se encuentran sistemáticamente desplazados hacia valores mayores en comparación con los correspondientes al grupo de derrotas ($Q1 = 6$, $Q3 = 12$). Esta diferencia en la localización y dispersión de las distribuciones sugiere, desde un punto de vista descriptivo, una mayor producción de triples en los encuentros que culminan en victoria.

Desde el enfoque inferencial, los resultados de la prueba de Mann–Whitney U, resumidos en la Tabla 10, indican un estadístico $U = 170,661,761$, con un valor estandarizado $Z = 36,36$ y un p -value inferior a 0.001. Este resultado proporciona evidencia estadística muy sólida para rechazar la hipótesis nula de igualdad entre las distribuciones de FG3M en partidos ganados y perdidos, confirmando que la diferencia observada no puede atribuirse al azar.

Adicionalmente, el tamaño del efecto estimado ($r = 0,199$) corresponde a un efecto pequeño a moderado según los criterios habituales. Este valor indica que, aunque la diferencia entre ambos grupos es altamente significativa desde el punto de vista estadístico —favorecida en parte por el gran tamaño muestral—, el número de triples anotados explica únicamente una proporción limitada, aunque relevante, de la variabilidad asociada al resultado del partido.

2.2.4. Conclusión de la prueba

En conjunto, los resultados de la prueba de Mann–Whitney U confirman que los partidos ganados tienden a presentar un mayor número de triples anotados que los partidos perdidos. Esta evidencia inferencial, basada en una comparación directa de las distribuciones de FG3M entre ambos grupos, complementa los hallazgos obtenidos mediante la regresión logística y refuerza la idea de que el tiro de tres puntos constituye un factor relevante en la probabilidad de victoria, aunque no exclusivo ni suficiente por sí solo para explicar el resultado de un partido.

Conclusión global del análisis

Los resultados obtenidos mediante la regresión logística y la prueba no paramétrica de Mann–Whitney U son consistentes y complementarios. El análisis multivariado muestra que el número de triples anotados (FG3M) se asocia de forma positiva y estadísticamente significativa con la probabilidad de victoria, incluso al controlar por la efectividad general de tiro (FG_PCT), lo que confirma la relevancia independiente del lanzamiento de tres puntos en el resultado del partido.

De manera concordante, la prueba de Mann–Whitney U evidencia que los equipos ganadores presentan, en términos generales, un mayor volumen de triples anotados que los equipos perdedores, con una diferencia altamente significativa desde el punto de vista estadístico, aunque de magnitud moderada. En conjunto, ambos enfoques refuerzan la conclusión de que el tiro de tres puntos constituye un factor relevante en la probabilidad de victoria, si bien su efecto debe interpretarse como parte de un conjunto más amplio de determinantes del rendimiento competitivo.

3. Pregunta 2: Análisis de la Evolución Temporal del Juego

¿Como ha cambiado la media de puntos por partido (PTS) y el porcentaje de tiros de tres puntos intentados (FG3A/FGA) a lo largo de las temporadas (SEASON_YEAR), y existe una relación temporal significativa entre ambas variables?

Para estudiar la evolución temporal de la producción ofensiva se combinaron dos enfoques estadísticos complementarios: un análisis de varianza (ANOVA) de una vía y un modelo de regresión lineal. Esta estrategia permite responder a la pregunta desde una perspectiva comparativa y desde una perspectiva temporal continua.

El ANOVA de una vía se utilizó para evaluar si las medias de puntos por partido (PTS) y del porcentaje de tiros de tres puntos intentados (FG3A/FGA) difieren significativamente entre temporadas. Este análisis permite detectar la existencia de cambios estructurales en el promedio de estas variables a lo largo del tiempo, sin asumir una forma funcional específica para dicha evolución.

Sin embargo, el ANOVA no proporciona información sobre la dirección ni la magnitud del cambio temporal. Por esta razón, se estimaron modelos de regresión lineal utilizando la temporada como variable explicativa continua. Este enfoque permite evaluar si existe una tendencia temporal sistemática, determinar si el cambio es creciente o decreciente y cuantificar la tasa media de variación anual de cada indicador ofensivo.

En conjunto, el ANOVA permite identificar diferencias significativas entre temporadas, mientras que la regresión lineal traduce estas diferencias en una relación temporal interpretable, ofreciendo una visión integral de cómo ha evolucionado el juego y de si ambas variables presentan una dinámica temporal significativa y coherente.

3.1. Ejecución de ANOVA

En primer lugar, se aplicó un ANOVA de una vía con el objetivo de evaluar si las medias de las variables de interés difieren de forma estadísticamente significativa entre temporadas. En este contexto, la temporada actúa como un factor categórico que divide el conjunto de datos en múltiples grupos independientes, mientras que las variables respuesta (PTS y FG3A/FGA) son cuantitativas continuas. El ANOVA resulta apropiado cuando se desea comparar medias entre más de dos grupos, evitando la realización de múltiples contrastes bivariados que incrementarían el riesgo de error tipo I.

Los boxplots y estadísticos descriptivos mostraron que, a nivel agregado por temporada, las distribuciones de PTS y FG3A/FGA presentan rangos intercuartílicos moderados y una variabilidad relativamente estable entre temporadas. Esta estabilidad sugiere que el supuesto de homogeneidad de varianzas se cumple de forma aproximada, sin evidencia de

heterocedasticidad severa entre grupos como para invalidar el ANOVA, pues esta prueba es conocida por su robustez ante heterocedasticidad moderada cuando los tamaños muestrales son grandes y balanceados.

Asimismo, el elevado tamaño muestral por temporada permite invocar el teorema del límite central, de modo que las medias muestrales pueden considerarse aproximadamente normales, aun cuando los datos a nivel de partido no sigan estrictamente una distribución normal. Esta combinación de tamaños muestrales grandes y varianzas comparables confiere robustez al ANOVA frente a desviaciones moderadas de los supuestos clásicos, justificando su uso para evaluar diferencias globales entre temporadas.

3.1.1. Preparación de los datos

Para aplicar un ANOVA de una vía en el análisis de la evolución temporal, fue necesaria una preparación previa de los datos y la evaluación de los supuestos asociados a esta técnica.

En primer lugar, la variable temporal SEASON_YEAR se trató como un factor categórico, dado que el objetivo del ANOVA es comparar las medias de las variables de interés entre temporadas discretas. Cada nivel del factor representa una temporada de la NBA, lo que define grupos independientes de observaciones.

Las variables respuesta consideradas fueron:

- PTS: puntos totales anotados por partido.
- FG3A/FGA: proporción de intentos de triple sobre el total de tiros de campo.

Para la variable FG3A/FGA, se construyó explícitamente la razón entre FG3A y FGA a nivel de partido, garantizando que ambas variables estuvieran definidas y fueran positivas. Esta transformación permite capturar la orientación estratégica hacia el tiro de tres puntos de forma estandarizada y comparable entre temporadas.

Posteriormente, se eliminaron observaciones con valores faltantes en cualquiera de las variables implicadas, asegurando la consistencia del conjunto de datos utilizado en el análisis.

3.2. Hipótesis estadísticas

Para cada variable dependiente se plantearon las siguientes hipótesis:

Para FG3A/FGA

- H_0 : La media de FG3A/FGA es igual en todas las temporadas.
- H_1 : Al menos una temporada presenta una media de FG3A/FGA diferente.

Para PTS

- H_0 : La media de puntos por partido (PTS) es igual en todas las temporadas.
- H_1 : Al menos una temporada presenta una media de PTS diferente.

3.3. Resultados del ANOVA

Tabla 11: Estadísticos descriptivos de FG3A/FGA por temporada

SEASON_YEAR	mean	std	n
2010-11	0.2221	0.0689	2460
2011-12	0.2263	0.0707	1980
2012-13	0.2439	0.0712	2458
2013-14	0.2600	0.0706	2460
2014-15	0.2685	0.0755	2460
2015-16	0.2851	0.0767	2460
2016-17	0.3168	0.0761	2460
2017-18	0.3379	0.0770	2460
2018-19	0.3592	0.0782	2460
2019-20	0.3845	0.0758	2118
2020-21	0.3928	0.0790	2160
2021-22	0.4002	0.0727	2460
2022-23	0.3883	0.0769	2460
2023-24	0.3952	0.0684	2460

Tabla 12: Estadísticos descriptivos de PTS por temporada

SEASON_YEAR	mean	std	n
2010-11	-0.4776	0.8834	2460
2011-12	-0.7198	0.8564	1980
2012-13	-0.5816	0.8560	2458
2013-14	-0.3703	0.8730	2460
2014-15	-0.4435	0.8653	2460
2015-16	-0.2479	0.8641	2460
2016-17	-0.0330	0.8942	2460
2017-18	0.0216	0.8880	2460
2018-19	0.3805	0.9312	2460
2019-20	0.4238	0.9153	2118
2020-21	0.4454	0.9205	2160
2021-22	0.3368	0.9289	2460
2022-23	0.6364	0.8808	2460
2023-24	0.6015	0.9455	2460

Tabla 13: ANOVA de una vía para FG3A/FGA por temporada

Fuente	F	p-value
Temporada	1950.5527	0.0000
Residual		

Tabla 14: ANOVA de una vía para PTS por temporada

Fuente	F	p-value
Temporada	647.8556	0.0000
Residual		

Los estadísticos descriptivos por temporada para la proporción de tiros de tres puntos intentados (FG3A/FGA) y para los puntos por partido (PTS) se presentan en las Tablas 11 y 12, respectivamente. En ambos casos se observa una evolución temporal clara: la media de FG3A/FGA muestra un incremento sostenido desde la temporada 2010–11 hasta 2023–24, mientras que la media de PTS presenta una tendencia general creciente, especialmente a partir de la segunda mitad del período analizado.

El contraste formal mediante ANOVA de una vía confirma que estas diferencias descriptivas entre temporadas son estadísticamente significativas. Para la variable FG3A/FGA, el estadístico obtenido fue $F = 1950,55$ con un valor-p prácticamente nulo ($p < 0,001$), como se muestra en la Tabla 13. Este resultado proporciona evidencia muy fuerte para rechazar la hipótesis nula de igualdad de medias, indicando que la proporción de tiros de tres puntos intentados ha cambiado de manera significativa entre temporadas.

De forma análoga, el ANOVA aplicado a la variable PTS arrojó un estadístico $F = 647,86$ con $p < 0,001$ (Tabla 14), lo que indica la existencia de diferencias estadísticamente significativas en la media de puntos por partido a lo largo de las distintas temporadas de la NBA.

En conjunto, los resultados del ANOVA corroboran desde un punto de vista inferencial lo observado en los estadísticos descriptivos: tanto el volumen ofensivo medido a través de PTS como la orientación hacia el tiro de tres puntos, capturada por FG3A/FGA, han experimentado cambios estructurales significativos a lo largo del tiempo. No obstante, aunque el ANOVA confirma la existencia de diferencias entre temporadas, no permite cuantificar la dirección ni la magnitud del cambio temporal, lo que motiva el uso de la regresión lineal como análisis complementario.

3.4. Regresión lineal para el análisis temporal (Pregunta 2)

3.5. Regresión lineal para el análisis temporal (Pregunta 2)

Con el objetivo de cuantificar de manera formal la evolución temporal identificada en el análisis descriptivo y confirmada mediante el ANOVA, se ajustó un modelo de regresión lineal simple que relaciona el tiempo, representado por las temporadas, con las variables de interés. Mientras que el ANOVA permitió establecer la existencia de diferencias estadísticamente significativas entre temporadas, la regresión lineal posibilita estimar la dirección y magnitud promedio del cambio a lo largo del período analizado.

La idoneidad del modelo se sustenta, en primer lugar, en la evidencia empírica obtenida a partir de los gráficos exploratorios. Los promedios por temporada, así como los boxplots, muestran una tendencia claramente monotónica y aproximadamente lineal en el tiempo, sin cambios abruptos de régimen ni comportamientos cíclicos pronunciados. Esta estructura justifica el supuesto de linealidad como una aproximación razonable para describir la tendencia media de las variables, incluso cuando existen variaciones intra-temporada a nivel de partido.

En relación con la independencia de los errores, cada observación corresponde a un partido distinto, lo que reduce la probabilidad de dependencia directa entre observaciones. Adicionalmente, la matriz de correlación presentada en la Tabla 15 muestra que las asociaciones relevantes se concentran entre la variable temporal y las medias de las variables de interés, mientras que las correlaciones entre las propias variables de resultado son de magnitud moderada. Este patrón es consistente con una evolución estructural entre temporadas y no con una dependencia secuencial fuerte a nivel de partido. Dado que el objetivo del modelo es capturar una tendencia global promedio entre temporadas, y no realizar predicción temporal de corto plazo, la posible existencia de dependencias débiles intra-temporada no compromete la validez del modelo lineal para inferencia sobre la media condicional.

Tabla 15: Matriz de correlación entre variables del análisis temporal

	season_num	PTS	FG3_ratio
season_num	1.000000	0.431000	0.641000
PTS	0.431000	1.000000	0.352000
FG3_ratio	0.641000	0.352000	1.000000

El análisis de los histogramas de las variables y de los residuos indica desviaciones de la normalidad, principalmente asociadas a asimetrías leves y colas pesadas. Sin embargo, estas características ya se evidencian en los análisis descriptivos previos y están directamente relacionadas con el tamaño muestral muy elevado. En este contexto, las pruebas formales de normalidad tienden a ser excesivamente sensibles, mientras que el teorema

central del límite garantiza la validez asintótica de los estimadores y de la inferencia basada en mínimos cuadrados ordinarios.

De manera similar, los boxplots y los análisis de dispersión de los residuos sugieren cierta heterogeneidad en la varianza a lo largo del tiempo, consistente con los cambios estructurales del juego observados en el análisis previo. No obstante, dicha heteroscedasticidad no presenta patrones extremos ni compromete la estimación de la tendencia media, por lo que el modelo lineal sigue siendo una herramienta adecuada para el objetivo del estudio.

En conjunto, la evidencia gráfica, descriptiva y estadística obtenida en las etapas anteriores respalda el uso de la regresión lineal como un modelo robusto para el análisis temporal. Así, la regresión no sustituye al ANOVA, sino que lo complementa, permitiendo traducir las diferencias entre temporadas en una estimación cuantitativa del ritmo de evolución del juego a lo largo del período analizado.

3.5.1. Preparación de los datos

Para la implementación del modelo de regresión se realizaron los siguientes pasos:

1. La variable `SEASON_YEAR` fue transformada en una variable numérica ordinal que representa el orden temporal de las temporadas. Esta transformación es necesaria para interpretar el coeficiente de regresión como una tasa de cambio anual.
2. Se utilizaron como variables dependientes:
 - `PTS`: puntos anotados por partido.
 - `FG3A/FGA`: proporción de tiros de tres puntos intentados.
3. Se eliminaron observaciones con valores faltantes para asegurar la correcta estimación del modelo.
4. No se aplicaron transformaciones adicionales a las variables dependientes, ya que el objetivo principal del análisis es estimar la tendencia media a lo largo del tiempo y no realizar inferencia puntual a nivel individual.

Esta preparación permite interpretar directamente los coeficientes estimados como el cambio promedio por temporada en cada variable.

3.5.2. Detalles del modelo

Con el objetivo de cuantificar la evolución temporal del juego en la NBA, se estimaron dos modelos de regresión lineal simple utilizando como variable explicativa el orden temporal de las temporadas (`season_num`). Las variables dependientes analizadas fueron los puntos anotados por partido (`PTS`) y la proporción de intentos de triples (`FG3A/FGA`).

Para cada variable dependiente se estimó el siguiente modelo:

$$Y_i = \beta_0 + \beta_1 \cdot \text{Temporada}_i + \varepsilon_i$$

donde:

- Y_i representa PTS o FG3A/FGA,
- β_0 es el valor esperado al inicio del período,
- β_1 mide la tendencia temporal promedio por temporada,
- ε_i es el término de error aleatorio.

El cual con el objetivo de evaluar si el tiempo tiene un efecto sistemático sobre las variables analizadas plantea las siguientes hipótesis:

- H_0 : $\beta_1 = 0$ (no existe tendencia temporal significativa).
- H_1 : $\beta_1 \neq 0$ (existe una tendencia temporal significativa).

3.6. Análisis de los resultados del modelo

Tabla 16: Resultados de la regresión lineal para FG3_ratio

Dep. Variable:	FG3_ratio	R-squared:	0.412
Model:	OLS	Adj. R-squared:	0.411
Method:	Least Squares	F-statistic:	2.330e+04
Date:	Tue, 27 Jan 2026	Prob (F-statistic):	0.00
Time:	17:43:30	Log-Likelihood:	38794.
No. Observations:	33316	AIC:	-7.758e+04
Df Residuals:	33314	BIC:	-7.757e+04
Df Model:	1		
Covariance Type:	nonrobust		

	coef	std err	t	P> t	[0.025	0.975]
const	0.2177	0.001	276.243	0.000	0.216	0.219
season_num	0.0157	0.000	152.628	0.000	0.015	0.016

Omnibus:	507.475	Durbin-Watson:	0.929
Prob(Omnibus):	0.000	Jarque-Bera (JB):	533.625
Skew:	0.298	Prob(JB):	1.33e-116
Kurtosis:	3.173	Cond. No.	14.8

Notes:

[1] Standard Errors assume that the covariance matrix of the errors is correctly specified.

Tabla 17: Resultados de la regresión lineal para PTS

Dep. Variable:	PTS	R-squared:	0.186
Model:	OLS	Adj. R-squared:	0.186
Method:	Least Squares	F-statistic:	7603.
Date:	Tue, 27 Jan 2026	Prob (F-statistic):	0.00
Time:	17:43:30	Log-Likelihood:	-43849.
No. Observations:	33316	AIC:	8.770e+04
Df Residuals:	33314	BIC:	8.772e+04
Df Model:	1		
Covariance Type:	nonrobust		

	coef	std err	t	P> t	[0.025	0.975]
const	-0.6988	0.009	-74.212	0.000	-0.717	-0.680
season_num	0.1071	0.001	87.194	0.000	0.105	0.110

Omnibus:	109.572	Durbin-Watson:	1.133
Prob(Omnibus):	0.000	Jarque-Bera (JB):	111.415
Skew:	0.133	Prob(JB):	6.41e-25
Kurtosis:	3.097	Cond. No.	14.8

Notes:

[1] Standard Errors assume that the covariance matrix of the errors is correctly specified.

3.6.1. Resultados del modelo para PTS

Los resultados de la regresión lineal para la variable PTS, presentados en la Tabla 17, evidencian una relación positiva y estadísticamente significativa entre el tiempo y la cantidad de puntos anotados por partido. El coeficiente estimado para la variable temporal es $\beta_1 = 0,1071$ ($p < 0,001$), lo que indica que, en promedio, los puntos por partido aumentan aproximadamente en 0.11 unidades por cada temporada considerada en el orden cronológico del análisis.

El estadístico F del modelo resulta altamente significativo, lo que permite rechazar la hipótesis nula de ausencia de relación temporal y confirmar la existencia de una tendencia creciente en la anotación de puntos a lo largo del período analizado. El coeficiente de determinación obtenido ($R^2 = 0,186$) sugiere que el tiempo explica cerca del 19

3.6.2. Resultados del modelo para FG3A/FGA

En el caso de la proporción de intentos de triples, los resultados mostrados en la Tabla 16 revelan una relación temporal aún más marcada. El coeficiente asociado a la variable **season_num** es positivo y altamente significativo, con un valor estimado de $\beta_1 = 0,0157$ ($p < 0,001$). Este resultado indica que, en promedio, la proporción de tiros de tres puntos intentados aumenta aproximadamente en 0.016 unidades por temporada, reflejando un cambio sostenido en la estrategia ofensiva de los equipos a lo largo del tiempo.

El coeficiente de determinación del modelo ($R^2 = 0,412$) es considerablemente mayor que el obtenido para la variable PTS, lo que sugiere que el paso del tiempo explica una fracción sustancial de la variabilidad observada en el uso del tiro de tres puntos. Este hallazgo es coherente con la evidencia descriptiva y con los resultados del ANOVA, y confirma que la adopción progresiva del tiro exterior constituye uno de los principales motores de la evolución ofensiva del juego durante el período analizado.

3.6.3. Conclusión de la prueba

El análisis ANOVA mostró que existen diferencias significativas entre las temporadas tanto en el promedio de puntos por partido (PTS) como en la proporción de lanzamientos de tres puntos (FG3A/FGA). Para complementar este resultado, se utilizó una regresión lineal que permitió medir la magnitud de estos cambios a lo largo del tiempo. Los resultados indican que, en promedio, los equipos aumentaron alrededor de 1,46 puntos por partido por temporada y que la proporción de triples creció aproximadamente 1,6 puntos porcentuales por año. Si bien se observaron algunas desviaciones respecto de los supuestos clásicos de los modelos, el gran tamaño de la muestra y el buen balance de los datos hacen que tanto el ANOVA como la regresión sean lo suficientemente robustos, lo que respalda la validez de los resultados obtenidos.

3.7. Conclusion General de la pregunta

El análisis muestra que el juego en la NBA cambió de manera clara y medible entre 2010 y 2024. A lo largo de estos años se observa un aumento sostenido tanto en la cantidad de puntos anotados como en el uso estratégico del tiro de tres puntos. Esta evolución respalda con evidencia estadística lo que suele llamarse la “revolución del triple”, y deja en claro que existe una relación positiva en el tiempo: a medida que el tiro exterior ganó protagonismo, también aumentó la productividad ofensiva general de la liga.

4. Pregunta 3: Análisis de Predictores del Diferencial de Puntos

¿Que combinación de estadísticas de juego (por ejemplo, asistencias AST, rebotes REB, robos STL, porcentaje de tiros FG_PCT) predice de manera más robusta la diferencia de puntos (PLUS_MINUS) en un partido?

La pregunta planteada busca identificar qué combinación de estadísticas de juego predice de manera más robusta el diferencial de puntos (PLUS_MINUS) en un partido. Dado que la variable respuesta es cuantitativa continua y que se dispone de múltiples variables

predictoras también cuantitativas, la regresión lineal múltiple constituye una herramienta metodológicamente adecuada para este objetivo. Este enfoque permite estimar de forma simultánea la contribución marginal de cada estadística del box score, controlando el efecto del resto de variables, y evaluar tanto la dirección como la magnitud de su asociación con el impacto neto del equipo en el marcador.

La aplicabilidad del modelo se sustenta en la verificación razonable de sus supuestos básicos. En primer lugar, se asume una relación aproximadamente lineal entre las variables explicativas y el diferencial de puntos. El análisis descriptivo previo muestra que PLUS_MINUS presenta una distribución perfectamente simétrica, centrada en cero y con una forma aproximadamente normal, lo que sugiere que puede responder de manera lineal a variaciones en métricas de rendimiento colectivo. De igual forma, variables como asistencias, rebotes, pérdidas de balón y porcentajes de tiro exhiben comportamientos estables y continuos, coherentes con relaciones lineales esperables en el contexto del baloncesto.

El supuesto de independencia de las observaciones también resulta razonable, dado que cada registro corresponde a un partido distinto y no se observa una estructura jerárquica ni dependencia temporal explícita entre los encuentros analizados. En cuanto a la homocedasticidad, la dispersión simétrica del diferencial de puntos y la ausencia de concentraciones extremas en regiones específicas sugieren una varianza de los errores aproximadamente constante a lo largo del rango de valores predichos, lo cual puede ser confirmado posteriormente mediante el análisis de residuos.

Respecto a la normalidad de los errores, la distribución centrada y simétrica de PLUS_MINUS favorece la obtención de residuos aproximadamente normales. Aunque algunas variables predictoras, como robos y bloqueos, presentan asimetrías propias de variables de conteo con límite inferior en cero, esta característica no invalida el modelo, ya que la normalidad se exige a los residuos y no a las variables explicativas.

El supuesto más delicado del modelo corresponde a la ausencia de multicolinealidad severa entre los predictores. Dado que varias métricas del box score describen dimensiones relacionadas del juego, como la eficiencia ofensiva, el control del balón y la intensidad defensiva, resulta necesario evaluar empíricamente el grado de asociación lineal entre las variables explicativas. Con este objetivo, se construyó la matriz de correlaciones entre las variables estandarizadas, presentada en la Tabla 18, como una herramienta diagnóstica preliminar para identificar posibles relaciones lineales elevadas que pudieran comprometer la estabilidad del modelo de regresión.

El análisis de la matriz de correlaciones revela que, en general, las asociaciones entre los predictores son de magnitud baja a moderada. Las correlaciones más altas se observan entre AST y FG_PCT (0.559), así como entre FG_PCT y FG3_PCT (0.490), y entre AST y FG3_PCT (0.374). Estos valores reflejan una relación esperable entre métricas vinculadas a la eficiencia ofensiva y al movimiento del balón, sin alcanzar niveles considerados

problemáticos desde el punto de vista de la multicolinealidad severa.

El resto de las correlaciones presentan magnitudes reducidas, cercanas a cero, como ocurre entre STL y BLK (0.009), BLK y FG_PCT (0.043), o FT_PCT con el resto de las variables, cuyos coeficientes no superan en valor absoluto el 0.045. Asimismo, las correlaciones negativas observadas, como la existente entre REB y FG_PCT (-0.171) o entre AST y TOV (-0.062), son de baja magnitud y no sugieren dependencias lineales fuertes.

En conjunto, estos resultados indican que, si bien existen asociaciones conceptualmente coherentes entre algunas métricas ofensivas, no se detectan correlaciones extremadamente altas que indiquen la presencia de multicolinealidad severa. No obstante, la coexistencia de relaciones moderadas entre variables relacionadas con la eficiencia ofensiva justifica la consideración de técnicas complementarias, como el análisis de componentes principales, para mejorar la estabilidad de los coeficientes y facilitar la interpretación global del modelo.

Tabla 18: Matriz de correlaciones entre las variables explicativas estandarizadas.

	AST	REB	STL	BLK	TOV	FG_PCT	FG3_PCT	FT_PCT
AST	1.000	0.052	0.073	0.068	-0.062	0.559	0.374	0.027
REB	0.052	1.000	-0.109	0.164	0.123	-0.171	-0.099	-0.045
STL	0.073	-0.109	1.000	0.009	0.094	0.008	-0.021	-0.015
BLK	0.068	0.164	0.009	1.000	0.046	0.043	0.011	0.001
TOV	-0.062	0.123	0.094	0.046	1.000	0.029	0.018	-0.024
FG_PCT	0.559	-0.171	0.008	0.043	0.029	1.000	0.490	0.034
FG3_PCT	0.374	-0.099	-0.021	0.011	0.018	0.490	1.000	0.028
FT_PCT	0.027	-0.045	-0.015	0.001	-0.024	0.034	0.028	1.000

A pesar de esta limitación, la regresión lineal múltiple resulta útil para abordar el problema planteado, ya que permite identificar qué estadísticas están asociadas de forma significativa a un diferencial de puntos positivo y distinguir entre métricas estructurales del rendimiento colectivo y métricas más dependientes del contexto del partido. No obstante, para mitigar los efectos de la multicolinealidad y mejorar la robustez del modelo, resulta metodológicamente pertinente aplicar un análisis de componentes principales (PCA) como paso previo a la regresión.

La aplicación de componentes principales permite reducir la dimensionalidad del conjunto de predictores sin una pérdida sustancial de información, condensando la variabilidad compartida de las estadísticas del box score en un número reducido de componentes no correlacionados entre sí. Este procedimiento elimina la multicolinealidad, garantiza el cumplimiento del supuesto de independencia entre predictores y mejora la estabilidad de las estimaciones. Además, los componentes obtenidos pueden interpretarse como dimensiones latentes del juego, asociadas a la producción ofensiva, la eficiencia de tiro, el

control del balón y la intensidad defensiva, lo que aporta una lectura táctica coherente del modelo.

4.1. Preparación de los datos

La preparación de los datos comienza con la selección de las variables relevantes para el análisis, considerando como variable respuesta el diferencial de puntos del equipo en el partido (`PLUS_MINUS`) y como variables explicativas un conjunto de estadísticas del box score asociadas al rendimiento ofensivo y defensivo. Con el fin de garantizar la coherencia del análisis multivariante, se eliminan aquellas observaciones que presentan valores faltantes en cualquiera de las variables consideradas, asegurando así una base de datos completa y consistente para la aplicación del análisis de componentes principales y la regresión lineal.

Antes de aplicar el análisis de componentes principales, todas las variables explicativas son sometidas a un proceso de estandarización mediante el método de puntuaciones tipificadas. Este procedimiento transforma cada variable restando su media y dividiéndola por su desviación estándar, de modo que todas queden expresadas en una escala común con media cero y varianza unitaria. La estandarización es necesaria debido a que las métricas analizadas se encuentran originalmente en escalas heterogéneas, lo que podría provocar que aquellas con mayor varianza dominen artificialmente la extracción de componentes principales.

La estandarización utilizada corresponde al escalado clásico implementado por el algoritmo `StandardScaler`, el cual preserva la forma de las distribuciones originales y las relaciones lineales entre variables, limitándose a una transformación de escala. Este enfoque resulta especialmente adecuado tanto para el análisis de componentes principales, que se basa en la estructura de varianzas y covarianzas, como para la regresión lineal posterior, ya que mejora la estabilidad numérica del modelo y facilita la interpretación de las relaciones entre variables.

4.2. Análisis gráfico de relaciones lineales con `PLUS_MINUS`

Una vez estandarizadas las variables explicativas, se procede a evaluar de forma exploratoria la relación lineal entre cada predictor y el diferencial de puntos mediante gráficos de dispersión. En todos los casos, las variables explicativas representadas en el eje horizontal han sido previamente estandarizadas, con media cero y desviación estándar unitaria, lo cual facilita la comparación directa de la intensidad y dirección de las relaciones observadas entre distintas métricas de juego.




Figura 24: Relación entre asistencias estandarizadas (AST) y PLUS_MINUS.

En el caso de las asistencias (AST), se aprecia una relación positiva moderada con el PLUS_MINUS. A medida que aumenta el valor estandarizado de las asistencias, el diferencial de puntos tiende a incrementarse. La nube de puntos presenta una dispersión relativamente contenida alrededor de una tendencia ascendente, lo que sugiere que el juego colectivo y la creación de oportunidades para los compañeros se asocian de manera consistente con un mayor impacto positivo en el marcador.




Figura 25: Relación entre bloqueos estandarizados (BLK) y PLUS_MINUS.

El gráfico correspondiente a los bloqueos (BLK) muestra una relación débil o prácticamente neutra con el PLUS_MINUS. La distribución de los puntos se concentra en columnas verticales, reflejando la naturaleza discreta de esta estadística. Aunque la protección del aro es un aspecto defensivo relevante, un mayor número de tapones individuales no se

traduce necesariamente en un diferencial de puntos favorable.




Figura 26: Relación entre porcentaje de tiros de campo estandarizado (FG_PCT) y PLUS_MINUS.

La efectividad en tiros de campo (FG_PCT) presenta una de las relaciones más claras y robustas con el PLUS_MINUS. El gráfico evidencia una tendencia lineal positiva bien definida, con una diagonal pronunciada y relativamente poca dispersión. Esto indica que una mayor eficiencia ofensiva se asocia de manera directa con un impacto positivo en el marcador.




Figura 27: Relación entre porcentaje de triples estandarizado (FG3_PCT) y PLUS_MINUS.

El porcentaje de triples (FG3_PCT) muestra una relación positiva con el PLUS_MINUS, aunque con una dispersión mayor que la observada en el porcentaje total de tiros de campo. Esta variabilidad indica que el triple es una herramienta ofensiva potente pero volátil,

cuyo impacto depende en gran medida del contexto general del juego y del desempeño en otras áreas.




Figura 28: Relación entre porcentaje de tiros libres estandarizado (FT_PCT) y PLUS_MINUS.

El gráfico de los tiros libres (FT_PCT) presenta una relación positiva general con el PLUS_MINUS, aunque con una concentración de observaciones en valores extremadamente bajos del eje horizontal. Estas observaciones corresponden probablemente a jugadores con un volumen muy reducido de intentos desde la línea, que tras la estandarización adquieren valores extremos.




Figura 29: Relación entre rebotes estandarizados (REB) y PLUS_MINUS.

El análisis de los rebotes totales (REB) revela una correlación positiva sólida con el PLUS_MINUS. La nube de puntos presenta una tendencia ascendente clara, lo que refuerza

la idea de que el control de las posesiones constituye un factor determinante para mantener un diferencial de puntos favorable.




Figura 30: Relación entre robos estandarizados (STL) y PLUS_MINUS.

Los robos de balón (STL) muestran una relación ligeramente positiva pero altamente dispersa con el PLUS_MINUS. Aunque un robo genera una oportunidad inmediata, la elevada variabilidad sugiere que intentar robar el balón en exceso puede comprometer el balance defensivo.




Figura 31: Relación entre pérdidas de balón estandarizadas (TOV) y PLUS_MINUS.

Finalmente, el gráfico correspondiente a las pérdidas de balón (TOV) muestra una relación aparentemente neutra o ligeramente negativa con el PLUS_MINUS. Este patrón refleja que los jugadores con mayor responsabilidad ofensiva tienden a acumular más

pérdidas, pero también compensan estos errores con una mayor contribución global al rendimiento del equipo.

En conjunto, el análisis visual sugiere que la eficiencia en el tiro de campo, el control del rebote y la generación de asistencias destacan como los predictores más consistentes del impacto positivo en el marcador, lo que justifica el uso posterior de modelos de regresión multivariante y análisis de componentes principales.

4.3. Análisis de Componentes Principales y regresión

Dado que el análisis gráfico y la matriz de correlaciones evidencian la existencia de relaciones moderadas entre varias variables explicativas, se emplea el Análisis de Componentes Principales (PCA) como una técnica de reducción de dimensionalidad previa a la estimación del modelo de regresión. El objetivo principal del PCA en este contexto es transformar el conjunto original de variables correlacionadas en un nuevo conjunto de componentes ortogonales, eliminando la dependencia lineal entre predictores y mejorando la estabilidad del modelo.

El algoritmo se aplica sobre las variables previamente estandarizadas, garantizando que todas contribuyan de forma equilibrada a la construcción de los componentes. A partir de la descomposición espectral de la matriz de covarianzas, se obtienen los autovalores y las cargas factoriales que describen la importancia relativa de cada componente y la contribución de las variables originales a su definición.

Los resultados del PCA muestran que el primer componente principal explica el 24.73% de la varianza total del conjunto de datos, mientras que los cinco primeros componentes acumulan aproximadamente el 78.03% de la variabilidad total, tal como se observa en la Tabla 19. Este criterio de varianza acumulada justifica la retención de un subconjunto reducido de componentes que conserva la mayor parte de la información original, evitando el uso directo de todas las variables iniciales.

Tabla 19: Varianza explicada por los componentes principales.

	Autovalor	Varianza_Explicada	Varianza_Acumulada
0	1.9784	0.2473	0.2473
1	1.2439	0.1555	0.4028
2	1.0945	0.1368	0.5396
3	0.9925	0.1241	0.6637
4	0.9332	0.1166	0.7803
5	0.8082	0.1010	0.8813
6	0.5860	0.0733	0.9546
7	0.3635	0.0454	1.0000

El análisis de las cargas factoriales, presentado en la Tabla 20, permite interpretar conceptualmente los componentes principales. El primer componente está dominado por

las variables asociadas a la eficiencia ofensiva y al juego colectivo, destacándose el porcentaje de tiros de campo (FG_PCT), las asistencias (AST) y el porcentaje de triples (FG3_PCT), todas con cargas positivas elevadas. El segundo componente refleja principalmente el control del rebote y la protección del aro, con contribuciones relevantes de REB y BLK, mientras que el tercer componente está fuertemente asociado a las acciones defensivas y de presión, particularmente los robos de balón (STL) y las pérdidas (TOV).

Tabla 20: Cargas factoriales de las variables en los componentes principales.

	CP1	CP2	CP3	CP4	CP5	CP6	CP7	CP8
AST	0.558	0.154	-0.049	-0.033	-0.146	0.382	-0.388	-0.586
REB	-0.134	0.682	-0.210	-0.026	0.093	0.580	0.221	0.279
STL	0.048	-0.077	0.783	0.158	-0.436	0.319	0.216	0.125
BLK	0.049	0.573	-0.058	0.224	-0.543	-0.565	0.003	-0.046
TOV	-0.019	0.397	0.549	0.100	0.649	-0.228	-0.184	-0.154
FG_PCT	0.614	-0.004	0.013	-0.036	0.065	-0.088	-0.311	0.716
FG3_PCT	0.535	-0.002	-0.042	-0.065	0.197	-0.150	0.789	-0.154
FT_PCT	0.058	-0.140	-0.184	0.953	0.145	0.119	0.018	0.010

A partir de los componentes seleccionados, se estima un modelo de regresión lineal utilizando como predictores los componentes principales retenidos y como variable respuesta el diferencial de puntos (PLUS_MINUS). Este enfoque permite capturar la relación entre el rendimiento global del equipo y las dimensiones latentes del juego identificadas por el PCA, evitando problemas de multicolinealidad y facilitando una interpretación más estructurada del impacto conjunto de las estadísticas del box score.

4.3.1. Modelo Estadístico

Una vez realizado el Análisis de Componentes Principales y seleccionados los componentes que explican al menos el 80 % de la varianza total, se especifica el modelo de regresión lineal múltiple en función de dichos componentes como:

$$\text{PLUS_MINUS} = \beta_0 + \beta_1 \cdot \text{CP}_1 + \beta_2 \cdot \text{CP}_2 + \beta_3 \cdot \text{CP}_3 + \beta_4 \cdot \text{CP}_4 + \beta_5 \cdot \text{CP}_5 + \beta_6 \cdot \text{CP}_6 + \epsilon$$

donde:

- β_0 representa el término constante del modelo
- $\beta_1, \beta_2, \dots, \beta_6$ son los coeficientes asociados a cada componente principal retenido
- CP_i denota el i -ésimo componente principal obtenido a partir de las variables explicativas estandarizadas
- ϵ es el término de error aleatorio

4.3.2. Hipótesis Estadísticas

El contraste de significancia global del modelo se plantea mediante las siguientes hipótesis:

- H_0 : $\beta_1 = \beta_2 = \dots = \beta_6 = 0$ (los componentes principales no tienen efecto sobre PLUS_MINUS)
- H_1 : Existe al menos un $\beta_i \neq 0$ (al menos un componente principal influye en PLUS_MINUS)

4.4. Análisis del funcionamiento del modelo de regresión

El modelo de regresión lineal estimado mediante mínimos cuadrados ordinarios presenta un desempeño global moderadamente elevado, considerando la naturaleza agregada y multicausal del fenómeno analizado. El coeficiente de determinación obtenido es $R^2 = 0,466$, valor que indica que aproximadamente el 46.6 % de la variabilidad observada en la variable dependiente es explicada por el conjunto de variables incluidas en el modelo. El hecho de que el R^2 ajustado coincida numéricamente con el R^2 sugiere que el modelo no está sobreajustado y que las variables explicativas aportan información relevante de forma consistente.

Dep. Variable:	y	R-squared:	0.466
Model:	OLS	Adj. R-squared:	0.466
Method:	Least Squares	F-statistic:	4838.
Date:	Wed, 28 Jan 2026	Prob (F-statistic):	0.00
Time:	06:10:34	Log-Likelihood:	-1.2516e+05
No. Observations:	33316	AIC:	2.503e+05
Df Residuals:	33309	BIC:	2.504e+05
Df Model:	6		
Covariance Type:	nonrobust		

	coef	std err	t	P> t	[0.025	0.975]
const	-6.106e-16	0.057	-1.08e-14	1.000	-0.111	0.111
x1	5.3381	0.040	132.288	0.000	5.259	5.417
x2	3.5833	0.051	70.413	0.000	3.484	3.683
x3	-0.8788	0.054	-16.198	0.000	-0.985	-0.772
x4	1.4429	0.057	25.325	0.000	1.331	1.555
x5	-2.1615	0.059	-36.787	0.000	-2.277	-2.046
x6	4.1456	0.063	65.661	0.000	4.022	4.269

Omnibus:	169.014	Durbin-Watson:	0.853
Prob(Omnibus):	0.000	Jarque-Bera (JB):	176.779
Skew:	-0.155	Prob(JB):	4.10e-39
Kurtosis:	3.175	Cond. No.	1.56

Notes:

[1] Standard Errors assume that the covariance matrix of the errors is correctly specified.

La significancia global del modelo queda confirmada a través del estadístico F, cuyo valor asciende a 4838 con una probabilidad asociada prácticamente nula. Este resultado permite rechazar de manera contundente la hipótesis nula de que todos los coeficientes de pendiente sean simultáneamente iguales a cero, evidenciando que el modelo posee capacidad explicativa conjunta. Este comportamiento es reforzado por el tamaño muestral elevado, con un total de 33316 observaciones, lo que contribuye a una estimación estable y precisa de los parámetros.

El análisis individual de los coeficientes revela que todas las variables explicativas incluidas en el modelo resultan estadísticamente significativas al nivel usual de significancia, con valores p inferiores a 0.001 en todos los casos. Los coeficientes estimados presentan magnitudes y signos coherentes con la interpretación esperada del fenómeno. En particular, los predictores asociados a efectos positivos sobre la variable respuesta muestran coeficientes elevados, como ocurre con x_1 , cuyo coeficiente estimado es 5.3381, y con x_6 , que presenta un valor de 4.1456. Por el contrario, las variables con impacto negativo exhiben coeficientes negativos bien definidos, como x_3 con un valor de -0.8788 y x_5 con -2.1615, lo que indica una relación inversa clara con la variable dependiente.

Los intervalos de confianza al 95 % para todos los coeficientes excluyen el valor cero, lo que refuerza la evidencia estadística de su relevancia individual dentro del modelo. Además, el término constante resulta no significativo, con un coeficiente cercano a cero y un valor p igual a uno, lo cual es consistente con el hecho de que las variables explicativas han sido previamente estandarizadas.

Desde el punto de vista del diagnóstico de residuos, el estadístico de Durbin-Watson presenta un valor de 0.853, lo que sugiere la posible existencia de autocorrelación positiva en los errores. No obstante, dado el carácter transversal del conjunto de datos y el elevado tamaño muestral, este resultado no invalida la utilidad predictiva del modelo, aunque sí debe tenerse en cuenta en la interpretación inferencial. Las pruebas de normalidad de los residuos, como Omnibus y Jarque-Bera, rechazan la hipótesis de normalidad estricta, si bien los valores de asimetría (-0.155) y curtosis (3.175) indican desviaciones moderadas respecto a la normalidad teórica.

Finalmente, el número de condición reportado es 1.56, valor bajo que confirma la ausencia de problemas de multicolinealidad severa entre los predictores utilizados. Este resultado es consistente con el proceso previo de preparación de los datos y respalda la estabilidad numérica de los coeficientes estimados. En conjunto, estos indicadores per-

miten concluir que el modelo presenta un funcionamiento estadísticamente sólido, con capacidad explicativa relevante y coeficientes interpretables, dentro de las limitaciones inherentes al enfoque lineal adoptado.

4.5. Conclusiones

Los resultados muestran que el diferencial de puntos se explica de forma más sólida mediante una combinación de métricas que reflejan eficiencia ofensiva, generación de juego colectivo y control de las posesiones. En particular, el porcentaje de tiros de campo (FG_PCT) y el porcentaje de triples (FG3_PCT) destacan como los predictores más robustos del PLUS_MINUS, reforzados por el aporte consistente de las asistencias (AST). Los rebotes totales (REB) contribuyen positivamente al rendimiento global, mientras que las pérdidas de balón (TOV) ejercen un efecto negativo significativo. Por el contrario, las métricas defensivas individuales como los robos (STL) y los bloqueos (BLK) presentan un impacto más limitado y menos estable. En conjunto, la combinación de eficiencia en el tiro, creación ofensiva y dominio del rebote constituye la base más consistente para explicar y predecir el impacto de un jugador o equipo en el marcador.