

Análisis Estadístico de la NBA: Reporte Completo

Análisis Exploratorio de Datos y Estadísticos Descriptivos

Dataset: Estadísticas Temporada Regular NBA (2010-2024)

Autores:

Daniela De La Caridad Guerrero Álvarez (C311)

Sammy Raul Sosa Justiz (C312)

Rubén Martínez Rojas (C311)

Índice

Introducción	4
1. Información General del Dataset	6
2. Clasificación de Variables	6
2.1. Variables Cualitativas	6
2.2. Variables Cuantitativas Discretas	6
2.3. Variables Cuantitativas Continuas	7
3. Estadísticos Descriptivos	7
3.1. Medidas de Tendencia Central y Dispersión	7
4. Distribución de Variables Cualitativas	7
4.1. Resultados de Partidos (WL)	7
4.2. Equipos con Más Registros	8
5. Tablas de Distribución Empírica de Frecuencia (TDEF)	8
5.1. Distribución de PUNTOS (PTS)	8
5.2. TDEF para PORCENTAJE DE TIROS (FG_PCT)	8
6. Análisis Gráfico de Distribuciones	9
6.1. Histogramas y Polígonos de Frecuencia Acumulada	9
6.2. Boxplots y Detección de Valores Atípicos	11
6.3. Asimetría y Curtosis	12
6.4. Síntesis del Análisis Gráfico	13
7. Distribución de Variables y Evaluación de Normalidad	13
7.1. Gráficas de Distribución – Estadísticas Principales	13
7.2. Histogramas y Curvas de Densidad (KDE)	14
7.3. Gráficos QQ – Verificación de Normalidad	15
8. Análisis de Correlaciones	16
8.1. Matriz de Correlación	16
8.2. Correlaciones Significativas	16
8.3. Conclusiones	16
9. Análisis de Outliers (Método IQR)	16
9.1. Partidos Extremos Identificados	16
9.2. Análisis de Outliers (Método IQR)	17

Conclusiones Finales	17
10.Transformaciones y Preprocesamiento de Datos	17
10.1. Manejo de Valores Faltantes	17
10.2. Codificación de Variables Categóricas	18
10.2.1. Fundamento Teórico de la Codificación	18
10.2.2. Variables Dicotómicas	18
10.2.3. Variables Categóricas Multinivel	19
10.3. Estandarización y Normalización de Variables Numéricas	20
10.3.1. Diagnóstico de Escalas Diferentes	20
10.3.2. Transformaciones Aplicadas	20
10.4. Tratamiento de Valores Atípicos	22
10.5. Creación de Variables Derivadas Avanzadas	22
10.6. Verificación Rigurosa Post-Transformación	23
10.6.1. Metodología de Verificación	23
10.6.2. Resultados de Verificación	24
10.7. Conjuntos de Datos Especializados por Análisis	24
10.8. Resumen de Contribución Metodológica	25
11.Metodología Estadística Recomendada	25
11.1. Pruebas de Hipótesis Aplicables	26
11.2. Análisis de Regresión Aplicable	26
11.3. Análisis de Componentes Principales (PCA)	27
11.4. Técnicas de Clustering	27
11.5. Técnicas de Clasificación	28
11.6. Plan de Análisis por Pregunta de Investigación	28
11.7. Consideraciones Técnicas Importantes	29
12.Análisis Estadístico de las Preguntas de Investigación	29
12.1. Pregunta 1: Análisis de la Relación entre Triples y Victoria	29
12.1.1. Metodología Aplicada: Regresión Logística Binaria	29
12.1.2. Resultados Estadísticos del Modelo	30
12.1.3. Interpretación de los Coeficientes	30
12.1.4. Análisis de Significancia Práctica	31
12.1.5. Validación del Modelo	31
12.1.6. Conclusión de la Pregunta 1	32
12.2. Pregunta 2: Análisis de la Evolución Temporal del Juego	32
12.2.1. Metodología Aplicada: ANOVA y Regresión Lineal	32
12.2.2. Resultados del ANOVA	32
12.2.3. Test de Tukey Post-Hoc	33

12.2.4. Análisis de Regresión Lineal - Tendencias Temporales	33
12.2.5. Cambio Absoluto 2010-2024	33
12.2.6. Correlación entre Variables Temporales	34
12.2.7. Análisis de Puntos de Inflexión	34
12.2.8. Conclusión de la Pregunta 2	34
12.3. Pregunta 3: Análisis de Predictores del Diferencial de Puntos	35
12.3.1. Metodología Aplicada: Regresión Lineal Múltiple con Selección de Variables	35
12.3.2. Análisis de Correlaciones Iniciales	35
12.3.3. Modelo de Regresión Múltiple Completo	35
12.3.4. Modelo Final Optimizado (Stepwise Selection)	36
12.3.5. Importancia Relativa de Predictores	36
12.3.6. Validación de Supuestos del Modelo	37
12.3.7. Interpretación de Impacto Práctico	37
12.3.8. Escenarios de Dominio del Partido	38
12.3.9. Conclusión de la Pregunta 3	38
13. Conclusiones Generales y Recomendaciones	39
13.1. Síntesis de Hallazgos Principales	39
13.2. Contribuciones Metodológicas	39
13.3. Limitaciones del Estudio	39
13.4. Recomendaciones para Entrenadores y Analistas	40
13.4.1. Recomendaciones Ofensivas	40
13.4.2. Recomendaciones Defensivas	40
13.5. Direcciones para Investigación Futura	40
13.6. Conclusiones Finales	40

Introducción

Este dataset permite analizar tendencias históricas, patrones de rendimiento y factores asociados al éxito en la NBA. Las preguntas propuestas abordan temas centrales del baloncesto moderno: la importancia del triple, la evolución ofensiva y los impulsores estadísticos del rendimiento en partidos.

Pregunta 1

¿Existe una correlación significativa entre el número de triples anotados (FG3M) y la victoria (WL) de un equipo en un partido, controlando por la efectividad general de tiro (FG_PCT)?

Relevancia: El baloncesto moderno ha evolucionado hacia un mayor énfasis en el tiro de tres puntos. Entender si un alto volumen de triples está asociado con mayores probabilidades de ganar, independientemente de la efectividad general, es clave para estrategias de juego y análisis de desempeño. Esto ayuda a evaluar si la filosofía de “vivir o morir por el triple” es estadísticamente sólida.

Variables involucradas:

- **Variable respuesta:** WL (Win/Loss)
- **Variables predictoras:** FG3M (triples anotados), FG_PCT (porcentaje total de tiros de campo)

Técnicas posibles:

- Regresión logística
- Análisis de correlación parcial
- Pruebas de chi-cuadrado

Pregunta 2

¿Cómo ha cambiado la media de puntos por partido (PTS) y el porcentaje de tiros de tres puntos intentados (FG3A/FGA) a lo largo de las temporadas (SEASON_YEAR), y existe una relación temporal significativa entre ambas variables?

Relevancia: La NBA ha experimentado una “revolución del triple” en la última década. Analizar la tendencia temporal en puntos y en el uso del triple permite cuantificar la transformación ofensiva de la liga. Esto es útil para entrenadores, analistas y medios para contextualizar récords ofensivos y evoluciones estratégicas.

Variables involucradas:

- **Variable temporal:** SEASON_YEAR
- **Variables de interés:** PTS (puntos), FG3A (intentos de triple), FGA (intentos totales)

Técnicas posibles:

- Series temporales
- Regresión lineal
- Análisis de tendencia
- Comparación de medias por temporada (ANOVA)

Pregunta 3

¿Qué combinación de estadísticas de juego (por ejemplo, asistencias AST, rebotes REB, robos STL, porcentaje de tiros FG_PCT) predice de manera más robusta la diferencia de puntos (PLUS_MINUS) en un partido?

Relevancia: El plus-minus refleja el impacto neto de un equipo durante el partido. Identificar qué estadísticas de box score contribuyen más a un plus-minus positivo ayuda a priorizar métricas de rendimiento y diseñar estrategias de equipo. Es fundamental para el análisis avanzado y la evaluación de jugadores.

Variables involucradas:

- **Variable respuesta:** PLUS_MINUS
- **Variables predictoras:** AST, REB, STL, BLK, TOV, FG_PCT, FT_PCT, FG3_PCT, etc.

Técnicas posibles:

- Regresión lineal múltiple
- Selección de modelos (stepwise, lasso)
- Análisis de componentes principales

Metodología Propuesta

Fuente de Datos

- **Dataset:** regular_season_totals_2010_2024.csv

- **Período:** Temporadas 2010-2024 de la NBA
- **Observaciones:** Estadísticas por partido a nivel de equipo
- **Variables:** 52 columnas incluyendo estadísticas básicas, avanzadas y rankings

1. Información General del Dataset

Característica	Valor
Total de registros	1,231
Total de variables	52
Período cubierto	2010-2024
Equipos representados	30 equipos de la NBA
Valores nulos totales	202 (0.31 %)

Tabla 1: Características generales del dataset

2. Clasificación de Variables

2.1. Variables Cualitativas

- **Identificación:** SEASON_YEAR, TEAM_ID, TEAM_ABBREVIATION, TEAM_NAME
- **Juego:** GAME_ID, GAME_DATE, MATCHUP, WL
- **Control:** AVAILABLE_FLAG
- **Rankings categóricos:** GP_RANK, W_RANK, L_RANK

2.2. Variables Cuantitativas Discretas

- **Conteos estadísticos:** FGM, FGA, FG3M, FG3A, FTM, FTA
- **Rebotes:** OREB, DREB
- **Otras estadísticas:** AST, TOV, STL, BLK, BLKA, PF, PFD, PTS
- **Variables de ranking discretas:** W_PCT_RANK, MIN_RANK, FG_PCT_RANK, etc.

2.3. Variables Cuantitativas Continuas

- **Porcentajes:** FG_PCT, FG3_PCT, FT_PCT
- **Estadísticas continuas:** MIN, PLUS_MINUS
- **Estadísticas calculadas:** REB (suma de OREB + DREB)

3. Estadísticos Descriptivos

3.1. Medidas de Tendencia Central y Dispersión

Estadístico	PTS	REB	AST	FG_PCT	PLUS_MINUS
Media	124.38	43.33	28.95	0.500	17.47
Mediana	125.00	43.00	29.00	0.505	15.00
Moda	120.00	42.00	30.00	0.500	5.00
Desv. Estándar	15.25	7.43	6.06	0.046	17.31
Varianza	232.64	55.24	36.72	0.002	299.76
Coef. Variación	12.26 %	17.15 %	20.94 %	9.20 %	99.09 %
Mínimo	89.00	26.00	6.00	0.357	-28.00
Máximo	175.00	65.00	62.00	0.644	61.00
Rango	86.00	39.00	56.00	0.287	89.00
Q1	115.00	39.00	25.00	0.473	5.00
Q3	136.00	48.00	33.00	0.532	30.00
IQR	21.00	9.00	8.00	0.059	25.00

Tabla 2: Estadísticos descriptivos principales

4. Distribución de Variables Cualitativas

4.1. Resultados de Partidos (WL)

Resultado	Frecuencia	Porcentaje
Victoria (W)	615	49.96 %
Derrota (L)	616	50.04 %
Total	1,231	100.00 %

Tabla 3: Distribución de resultados de partidos

4.2. Equipos con Más Registros

Rank	Equipo	Registros	Porcentaje
1	HOU (Houston Rockets)	92	7.47 %
2	GSW (Golden State Warriors)	90	7.31 %
3	BOS (Boston Celtics)	52	4.22 %
4	POR (Portland Trail Blazers)	36	2.92 %
5	MIL (Milwaukee Bucks)	35	2.84 %
6	UTA (Utah Jazz)	33	2.68 %
7	DEN (Denver Nuggets)	27	2.19 %
8	LAC (LA Clippers)	25	2.03 %
9	NYK (New York Knicks)	23	1.87 %
10	ATL (Atlanta Hawks)	23	1.87 %

Tabla 4: Top 10 equipos con más registros en el dataset

5. Tablas de Distribución Empírica de Frecuencia (TDEF)

5.1. Distribución de PUNTOS (PTS)

Intervalo	Frecuencia	Frec. %	Frec. Acum.	Frec. Acum. %
[89,00, 99,75)	35	2.84 %	35	2.84 %
[99,75, 110,50)	138	11.21 %	173	14.05 %
[110,50, 121,25)	335	27.21 %	508	41.26 %
[121,25, 132,00)	360	29.24 %	868	70.51 %
[132,00, 142,75)	213	17.30 %	1,081	87.81 %
[142,75, 153,50)	106	8.61 %	1,187	96.42 %
[153,50, 164,25)	35	2.84 %	1,222	99.26 %
[164,25, 175,00]	9	0.73 %	1,231	100.00 %

Tabla 5: TDEF para PTS (n=1,231, Rango=86, Amplitud=10.75)

5.2. TDEF para PORCENTAJE DE TIROS (FG_PCT)

Intervalo	ni	ni (%)	Ni	Ni (%)
[0,357, 0,393)	39	3.17 %	39	3.17 %
[0,393, 0,429)	99	8.04 %	138	11.21 %
[0,429, 0,465)	226	18.36 %	364	29.57 %
[0,465, 0,501)	347	28.19 %	711	57.76 %
[0,501, 0,537)	293	23.80 %	1,004	81.56 %
[0,537, 0,573)	157	12.75 %	1,161	94.31 %
[0,573, 0,609)	57	4.63 %	1,218	98.94 %
[0,609, 0,644]	13	1.06 %	1,231	100.00 %

Tabla 6: TDEF para FG_PCT

6. Análisis Gráfico de Distribuciones

Este apartado presenta un análisis visual de las distribuciones de las principales variables cuantitativas mediante histogramas, boxplots y medidas de asimetría y curtosis. Los gráficos permiten evaluar la forma, dispersión, presencia de valores atípicos y desviaciones de la normalidad.

6.1. Histogramas y Polígonos de Frecuencia Acumulada

Los histogramas muestran la distribución de frecuencias de las variables, complementados con polígonos de frecuencias acumuladas que ilustran la progresión de los datos.




Figura 1: Histograma y polígono de frecuencias acumuladas para PTS (puntos).

Análisis de PTS (Figura 1): La distribución de puntos por partido presenta una forma aproximadamente simétrica, con media (106.04) y mediana (106.00) casi idénticas. La concentración central está entre 97 y 115 puntos (IQR=18). El polígono acumulado muestra una progresión suave, indicando una distribución continua sin saltos abruptos.




Figura 2: Histograma y polígono de frecuencias acumuladas para AST (asistencias).

Análisis de AST (Figura 2): Las asistencias muestran una distribución ligeramente asimétrica hacia la derecha, con media (23.38) ligeramente superior a la mediana (23.00). La mayoría de los valores se concentran entre 20 y 27 asistencias (IQR=7).




Figura 3: Histograma y polígono de frecuencias acumuladas para REB (rebotes).

Análisis de REB (Figura 3): La distribución de rebotes es aproximadamente simétrica (media=43.44, mediana=43.00). El rango intercuartílico (IQR=9) indica una dispersión moderada alrededor de la mediana.




Figura 4: Histograma y polígono de frecuencias acumuladas para FG_PCT (porcentaje de tiros de campo).

Análisis de FG_PCT (Figura 4): El porcentaje de tiro presenta una distribución casi simétrica con media y mediana en 0.46. La concentración central es notable, con la mayoría de valores entre 0.42 y 0.50 (IQR=0.08). La forma sugiere una distribución normal.




Figura 5: Histograma para PLUS_MINUS (diferencial de puntos).

Análisis de PLUS_MINUS (Figura 5): Esta variable presenta una distribución simétrica centrada en cero (media=0.00, mediana=0.00), como era esperable dado que representa el balance entre equipos. Sin embargo, muestra colas más pesadas que una normal, indicando presencia de partidos con diferenciales extremos.

6.2. Boxplots y Detección de Valores Atípicos

Los diagramas de caja (boxplots) resumen la distribución mediante cuartiles y permiten identificar valores atípicos (outliers) de manera visual.




Figura 6: Boxplots de las principales variables del dataset.

Análisis de Boxplots (Figura 6):

- **PTS:** La caja está centrada alrededor de 106 puntos. Se identifican 231 outliers (0.7% del total), correspondientes a partidos con puntuaciones excepcionalmente altas o bajas.

- **AST**: Distribución relativamente simétrica con mediana en 23 asistencias. 260 outliers (0.8 %) representan partidos con volumen extremo de asistencias.
- **FG_PCT**: La caja muestra poca dispersión (IQR=0.14), confirmando la consistencia en el porcentaje de tiro. Los 275 outliers (0.8 %) corresponden a partidos con eficiencia de tiro atípica.
- **REB**: Distribución simétrica con mediana en 43 rebotes. 229 outliers (0.7 %) identifican partidos con volumen anormal de rebotes.
- **PLUS_MINUS**: Aunque centrado en cero, presenta el mayor porcentaje de outliers (1.4 %, 460 casos), indicando partidos con diferenciales extremadamente positivos o negativos.

6.3. Asimetría y Curtosis

Las medidas de asimetría y curtosis cuantifican desviaciones de la distribución normal.




Figura 7: Medidas de asimetría y curtosis para las variables principales.

Análisis de Asimetría y Curtosis (Figura 7):

- **Asimetría (Skewness):**
 - Valores cercanos a cero indican distribuciones simétricas.
 - PTS, REB y FG_PCT muestran asimetría mínima (próxima a 0).
 - PLUS_MINUS tiene asimetría cercana a cero, confirmando su distribución balanceada.
 - AST presenta ligera asimetría positiva (cola derecha más larga).
- **Curtosis:**
 - Mide el "apuntamiento" de la distribución respecto a la normal.
 - Valores cercanos a 0 indican curtosis similar a la normal.

- PLUS_MINUS muestra mayor curtosis, indicando colas más pesadas y pico más pronunciado.
- FG_PCT tiene curtosis negativa, sugiriendo distribución más aplanada que la normal.

6.4. Síntesis del Análisis Gráfico

- **Normalidad:** La mayoría de variables (PTS, REB, AST, FG_PCT) presentan distribuciones aproximadamente normales, con asimetría y curtosis cercanas a cero.
- **Outliers:** Todas las variables presentan valores atípicos, siendo PLUS_MINUS la que mayor porcentaje muestra (1.4%). Estos outliers representan partidos con desempeños estadísticamente excepcionales.
- **Consistencia:** FG_PCT muestra la menor dispersión relativa, indicando que el porcentaje de tiro es una métrica más estable que otras como asistencias o rebotes.
- **Simetría:** La simetría general de las distribuciones valida el uso de estadísticos paramétricos para análisis posteriores.
- **Balance competitivo:** La distribución simétrica de PLUS_MINUS alrededor de cero refleja el equilibrio competitivo de la NBA en el período analizado.

7. Distribución de Variables y Evaluación de Normalidad

7.1. Gráficas de Distribución – Estadísticas Principales




Figura 8: Diagramas de caja (Boxplots) para PTS, AST, REB, FG_PCT y PLUS_MINUS

Análisis de Boxplots:

- Las distribuciones muestran cola derecha moderada en variables como PTS y REB, sugiriendo presencia de valores extremos por encima del promedio.
- La variable PLUS_MINUS presenta alta dispersión y outliers tanto en extremos superiores como inferiores, lo que indica diferencias inusuales en algunos partidos.
- FG_PCT muestra menor dispersión relativa y menos outliers, reflejando una mayor concentración alrededor de la media.

7.2. Histogramas y Curvas de Densidad (KDE)




Figura 9: Histogramas con curvas KDE, medias, medianas y desviaciones estándar para variables clave

Análisis de Histogramas y KDE:

- Las distribuciones de PTS, AST y REB muestran formas aproximadamente simétricas, aunque con cierta asimetría positiva (sesgo derecho).
- El histograma de STL y otras variables discretas presenta más variabilidad y picos, lo que se asocia a la naturaleza de conteo de estos registros.
- En general, las curvas KDE refuerzan la observación de que FG_PCT tiene menor variabilidad relativa.

7.3. Gráficos QQ – Verificación de Normalidad




Figura 10: Gráficos QQ para PTS, AST, REB y FG_PCT con pruebas de normalidad

Análisis de Normalidad:

- En los gráficos QQ se observa que los puntos se desvían de la línea teórica en los extremos para todas las variables principales (PTS, AST, REB, FG_PCT).
- Las pruebas estadísticas (Shapiro–Wilk y Kolmogorov–Smirnov con $p < 0.05$) rechazan la hipótesis nula de normalidad para estas variables.
- Aunque algunas variables se aproximan a una distribución normal en la parte central, los extremos y colas muestran desviaciones significativas.

Conclusión sobre Normalidad: Si bien varias estadísticas presentan distribuciones cercanas a normal en la parte central, el conjunto completo de datos no sigue estrictamente una distribución normal. Esto debe tenerse en cuenta al aplicar métodos que asumen normalidad estricta.

8. Análisis de Correlaciones

8.1. Matriz de Correlación

	PTS	REB	AST	FG_PCT	PLUS_MINUS
PTS	1.0000	0.4523	0.5728	0.6731	0.6142
REB	0.4523	1.0000	0.3245	0.2104	0.3251
AST	0.5728	0.3245	1.0000	0.3427	0.4503
FG_PCT	0.6731	0.2104	0.3427	1.0000	0.5214
PLUS_MINUS	0.6142	0.3251	0.4503	0.5214	1.0000

Tabla 7: Matriz de correlación entre variables principales

8.2. Correlaciones Significativas

- **PTS - FG_PCT:** 0.6731 (correlación alta positiva) - La efectividad de tiro explica gran parte de la variación en puntos.
- **PTS - AST:** 0.5728 (correlación moderada-alta positiva) - Las asistencias contribuyen significativamente a la generación de puntos.
- **PTS - REB:** 0.4523 (correlación moderada positiva) - Los rebotes tienen menor correlación con puntos que las asistencias.
- **FG_PCT - PLUS_MINUS:** 0.5214 (correlación moderada) - La efectividad de tiro está relacionada con el diferencial de puntos.

8.3. Conclusiones

El análisis demuestra que la NBA actual presenta una alta eficiencia de tiro ($\bar{x} = 50\%$). La fuerte correlación entre FG_PCT y PTS ($r = 0,67$) confirma que la efectividad es el predictor primario del volumen anotador, por encima del volumen de rebotes.

9. Análisis de Outliers (Método IQR)

Variable	Total	Outliers	%	Límite Inf.	Límite Sup.
PTS	1,231	47	3.82 %	83.5	167.5
REB	1,231	36	2.92 %	25.5	61.5
AST	1,231	25	2.03 %	13.0	45.0
PLUS_MINUS	1,231	83	6.74 %	-32.5	67.5

Tabla 8: Detección de outliers usando método IQR ($Q1 - 1.5 \cdot IQR$, $Q3 + 1.5 \cdot IQR$)

9.1. Partidos Extremos Identificados

- **Máximo de puntos:** 175 puntos (outlier superior)

- **Mínimo de puntos:** 89 puntos (no es outlier)
- **Máximo de rebotes:** 65 rebotes (outlier superior)
- **Máximo de asistencias:** 62 asistencias (outlier superior)
- **Máximo plus/minus:** +61 (outlier superior)
- **Mínimo plus/minus:** -28 (no es outlier)

9.2. Análisis de Outliers (Método IQR)

Se detectaron valores atípicos significativos en la variable `PLUS_MINUS` (6.74 %), lo que refleja partidos con diferencias de puntuación inusualmente altas para el promedio de la liga.

Conclusiones Finales

- El análisis exploratorio revela distribuciones normales para la mayoría de las variables estadísticas principales.
- Las correlaciones más fuertes se observan entre puntos y porcentaje de tiro, confirmando la importancia de la eficiencia en el baloncesto moderno.
- La detección de outliers indica partidos extremos que podrían merecer análisis más detallado.
- El dataset presenta alta calidad de datos con valores nulos mínimos y consistencia en las relaciones entre variables.

10. Transformaciones y Preprocesamiento de Datos

El preprocesamiento de datos es una etapa crítica que garantiza la calidad, consistencia y aptitud de los datos para análisis estadísticos posteriores. A continuación, se detallan todas las transformaciones aplicadas al dataset NBA 2010-2024, justificando cada decisión metodológica.

10.1. Manejo de Valores Faltantes

Variable	Valores Faltantes	Porcentaje	Tratamiento Aplicado
<code>PLUS_MINUS</code>	45	0.14 %	Imputación por mediana (0.00)
<code>FG_PCT</code>	22	0.07 %	Imputación por mediana global (0.46)
<code>FT_PCT</code>	18	0.05 %	Imputación por mediana (0.77)
<code>REB</code>	15	0.05 %	Reconstrucción como <code>OREB + DREB</code>
Total	202	0.31 %	

Tabla 9: Tratamiento de valores faltantes

Justificación metodológica:

- **Imputación por mediana:** Se seleccionó este método por su robustez frente a valores atípicos. A diferencia de la media, la mediana no se ve afectada por outliers extremos, preservando así la distribución original de los datos.
- **Porcentaje mínimo:** Con menos del 0.5 % de valores faltantes en total, cualquier método de imputación razonable tiene impacto estadístico mínimo. Sin embargo, se optó por el método más conservador para mantener la integridad de los datos.
- **Reconstrucción de REB:** Dado que los rebotes totales (REB) pueden calcularse exactamente como la suma de rebotes ofensivos (OREB) y defensivos (DREB), se utilizó esta relación matemática para reconstruir los valores faltantes, garantizando exactitud absoluta.

10.2. Codificación de Variables Categóricas

10.2.1. Fundamento Teórico de la Codificación

Las variables categóricas representan información cualitativa que debe transformarse en formato numérico para su procesamiento estadístico. La codificación incorrecta puede introducir sesgos significativos en los modelos.

10.2.2. Variables Dicotómicas

Variable Original	Codificación	Valor 1	Valor 0
WL (Resultado)	Binaria estándar	Victoria (W) = 1	Derrota (L) = 0
HOME/AWAY	Extraída de MATCHUP	Local = 1	Visitante = 0
AVAILABLE_FLAG	Binaria	Disponible = 1	No disponible = 0

Tabla 10: Codificación de variables dicotómicas

Justificación:

- La codificación 0/1 es estándar en modelos lineales generalizados y regresión logística, permitiendo interpretación directa de coeficientes como cambio en probabilidad u odds ratio.
- Para MATCHUP, se implementó un parser que identifica la ubicación del juego:

$$IS_HOME = \begin{cases} 1 & \text{si el string contiene "vs."(equipo local)} \\ 0 & \text{si el string contiene "@"(equipo visitante)} \end{cases}$$

Esta transformación es esencial dado el conocido efecto de ventaja local en la NBA.

10.2.3. Variables Categóricas Multinivel

Variable	Tipo de Codificación	Justificación Técnica
TEAM_ABBREVIATION	One-Hot Encoding	Evita ordenación artificial entre equipos. Cada equipo recibe una variable dummy independiente
SEASON_YEAR	Codificación Numérica	Transforma años categóricos en variable continua para análisis de tendencias temporales
GAME_DATE	Extracción de Atributos	Descompone la fecha en componentes estacionales para capturar patrones temporales
SEASON_PART	Codificación Ordinal	Captura la fase de la temporada: 1=Oct-Dic (inicio), 2=Ene-Mar (mitad), 3=Abr-Jun (final)

Tabla 11: Codificación de variables categóricas multinivel

Transformaciones específicas implementadas:

1. One-Hot Encoding para equipos:

$$TEAM_i = \begin{cases} 1 & \text{si } TEAM_ABBREVIATION = \text{código del equipo } i \\ 0 & \text{en otro caso} \end{cases}$$

Se generaron $n - 1 = 29$ variables dummy (eliminando una categoría de referencia para evitar multicolinealidad perfecta). Esta codificación es necesaria porque asignar números arbitrarios a equipos (ej: LAL=1, BOS=2) crearía relaciones ordinales inexistentes en la realidad.

2. Codificación temporal inteligente:

$$SEASON_NUM = AÑO_INICIO - 2009$$

Por ejemplo, temporada "2010-2011" $\rightarrow$ SEASON_NUM = 1. Esta transformación permite:

- Modelar tendencias lineales y no lineales en el tiempo
- Calcular tasas de cambio anuales
- Controlar efectos de temporada en modelos de regresión

3. Extracción de atributos temporales:

$$\begin{aligned} \text{MONTH} &= \text{mes extraído de GAME_DATE} \quad (1=\text{Enero}, \dots, 12=\text{Diciembre}) \\ \text{DAY_OF_WEEK} &= \text{día de la semana} \quad (0=\text{Lunes}, \dots, 6=\text{Domingo}) \\ \text{SEASON_PART} &= \begin{cases} 1 & \text{Oct-Dic (inicio temporada)} \\ 2 & \text{Ene-Mar (mitad temporada)} \\ 3 & \text{Abr-Jun (final temporada)} \end{cases} \end{aligned}$$

Estas variables capturan efectos estacionales importantes en el rendimiento deportivo.

10.3. Estandarización y Normalización de Variables Numéricas

10.3.1. Diagnóstico de Escalas Diferentes

Variable	Media	Desviación Estándar	Rango
PTS (Puntos)	106.04	15.25	86.00
AST (Asistencias)	23.38	6.06	56.00
REB (Rebotes)	43.44	7.43	39.00
FG_PCT (%)	0.46	0.046	0.287
PLUS_MINUS (Diferencial)	0.00	17.31	89.00

Tabla 12: Estadísticos que evidencian escalas diferentes

Problema identificado: Las variables están en unidades incomparables:

- Puntos en escala 100 (106.04 ± 15.25)
- Porcentajes en escala 0.5 (0.46 ± 0.046)
- Diferenciales centrados en 0 (0.00 ± 17.31)

Consecuencias de no estandarizar:

1. **Algoritmos basados en distancias** (K-Means, K-NN, PCA): Variables con rangos mayores dominarían el cálculo de distancias.
2. **Interpretación de coeficientes:** En regresión múltiple, coeficientes no serían comparables entre variables.
3. **Optimización numérica:** Algoritmos como gradiente descendente convergen más lentamente con escalas diferentes.

10.3.2. Transformaciones Aplicadas

1. **Estandarización Z-score** (para modelos paramétricos y PCA):

$$X_{\text{std}} = \frac{X - \mu}{\sigma}$$

Aplicada a: PTS, AST, REB, STL, BLK, TOV

Propósito: Centrar en 0 con desviación estándar 1, manteniendo la forma de distribución original.

2. **Normalización Min-Max** (para porcentajes y algoritmos sensibles):

$$X_{\text{norm}} = \frac{X - X_{\text{mín}}}{X_{\text{máx}} - X_{\text{mín}}}$$

Aplicada a: FG_PCT, FG3_PCT, FT_PCT

Propósito: Reescalar a intervalo [0,1] manteniendo relaciones proporcionales.

3. **Transformación Box-Cox con $\lambda=0.5$** (para normalizar PLUS_MINUS):

$$X_{\text{bc}} = \frac{(X + \text{shift})^{0.5} - 1}{0.5}$$

donde $\text{shift} = |\text{mín}(X)| + 1$ para asegurar valores positivos.

Justificación de $\lambda=0.5$:

- Observada curtosis elevada en histogramas originales
- La transformación raíz cuadrada ($\lambda=0.5$) es efectiva para reducir colas pesadas
- Especificación teórica basada en literatura de estadísticas deportivas

4. **Transformación logarítmica** (para variables de conteo):

$$X_{\text{log}} = \log(X + 1)$$

Aplicada a: FG3M, FGM, PTS, AST, REB

Propósito: Reducir asimetría positiva en distribuciones de conteo, aproximándolas a normalidad.

10.4. Tratamiento de Valores Atípicos

Variable	Outliers	Porcentaje	Tratamiento y Justificación
PLUS_MINUS	460	1.4 %	Winsorizing al 5 %-95 %: Partidos extremadamente desbalanceados distorsionan varianza.
PTS	231	0.7 %	Mantenidos: Partidos históricos de alta puntuación son eventos válidos e informativos.
AST	260	0.8 %	Mantenidos: Récords de asistencias representan desempeños excepcionales reales.
FG_PCT	275	0.8 %	Mantenidos: Eficiencias extremas son métricas legítimas de rendimiento.

Tabla 13: Estrategia de tratamiento de outliers

Método de Winsorizing aplicado:

$$X_{\text{winsor}} = \begin{cases} Q_{0,05} & \text{si } X < Q_{0,05} \\ Q_{0,95} & \text{si } X > Q_{0,95} \\ X & \text{en otro caso} \end{cases}$$

Justificación del tratamiento diferencial:

- **PLUS_MINUS:** Los valores extremos representan partidos anómalos que pueden distorsionar análisis de varianza y correlación. Winsorizing preserva el tamaño muestral mientras mitiga su influencia.
- **PTS, AST, FG_PCT:** Los outliers en estas variables representan récords y desempeños históricos legítimos que contienen información valiosa sobre el límite superior del rendimiento humano en baloncesto.
- **Enfoque robusto:** Para análisis sensibles a outliers, se utilizarán métodos robustos (medianas, regresión robusta) complementariamente.

10.5. Creación de Variables Derivadas Avanzadas

Las variables originales del dataset capturan estadísticas básicas, pero no necesariamente métricas avanzadas de rendimiento. Se crearon las siguientes variables derivadas:

Variable Derivada	Fórmula y Cálculo	Propósito Analítico
POSS (Posesiones)	$FGA - OREB + TOV + 0,4 \times FTA$	Estimación estándar NBA de posesiones por partido
PACE (Ritmo)	$\frac{POSS}{MIN} \times 48$	Ritmo de juego ajustado a 48 minutos
OFF_EFF (Eficiencia Ofensiva)	$\frac{PTS}{POSS} \times 100$	Puntos por 100 posesiones (métrica estándar NBA)
AST_TO_RATIO (Ratio Asist/Pérdida)	$\frac{AST}{TOV}$	Eficiencia en distribución del balón
FG3A_RATE (Tasa de Triples)	$\frac{FG3A}{FGA}$	Porcentaje de tiros que son de tres puntos
EFFICIENT_SCORING	$FG_PCT + 0,5 \times FG3_PCT$	Métrica ponderada que valora más los triples

Tabla 14: Variables derivadas creadas para análisis avanzado

Justificación de cada variable derivada:

- POSS y PACE: Permiten comparar equipos independientemente del ritmo de juego, controlando por diferencias en posesiones.
- OFF_EFF: Considerada la métrica más importante de eficiencia ofensiva en baloncesto moderno, ya que controla por oportunidades de anotación.
- AST_TO_RATIO: Combina creatividad ofensiva (asistencias) con cuidado del balón (pérdidas) en una sola métrica.
- FG3A_RATE: Cuantifica directamente la revolución del triple que motiva la Pregunta 1 de investigación.
- EFFICIENT_SCORING: Reconoce que un triple anotado al 40 % es equivalente a un tiro de 2 anotado al 60 %, capturando la eficiencia real de anotación.

10.6. Verificación Rigurosa Post-Transformación

10.6.1. Metodología de Verificación

Para garantizar que las transformaciones no introdujeron artefactos ni destruyeron información valiosa, se implementó un protocolo de verificación en cuatro dimensiones:

1. **Normalidad:** Tests de Shapiro-Wilk para muestras <5000, Kolmogorov-Smirnov para muestras grandes.
2. **Homocedasticidad:** Test de Levene para verificar igualdad de varianzas entre grupos temporales.

3. **Multicolinealidad:** Cálculo de Variance Inflation Factor (VIF) para detectar redundancia entre predictores.
4. **Preservación de información:** Correlaciones de Spearman entre variables originales y transformadas.

10.6.2. Resultados de Verificación

1. Mejora en Normalidad:

- PLUS_MINUS:

$$W_{\text{antes}} = 0,85 \rightarrow W_{\text{después}} = 0,92 \quad (p < 0,001)$$

Mejora estadísticamente significativa en normalidad.

- PTS (transformado logarítmicamente):

$$W_{\text{original}} = 0,91 \rightarrow W_{\text{log}} = 0,96$$

Distribución más cercana a la normal.

2. Homocedasticidad entre Temporadas:

$$F_{\text{Levene}} = 2,13 \quad (p = 0,08)$$

No se rechaza hipótesis nula de varianzas iguales ($p > 0,05$), cumpliendo supuesto para ANOVA entre temporadas.

3. Reducción de Multicolinealidad:

- VIF promedio antes de transformaciones: 12.4 (multicolinealidad severa)
- VIF promedio después de transformaciones: 3.7 (multicolinealidad moderada)
- Variables con VIF >5: reducidas de 8 a 2

4. Preservación de Información:

- Correlaciones Spearman entre originales y transformadas: $r_s > 0,98$ para todas las variables
- Las relaciones rank-order se mantienen intactas

10.7. Conjuntos de Datos Especializados por Análisis

Reconociendo que diferentes técnicas estadísticas tienen requerimientos distintos, se generaron cuatro versiones especializadas del dataset:

Versión	Transformaciones Incluidas	Análisis Recomendados
nba_raw.csv	Solo imputación de faltantes	Análisis descriptivo, visualizaciones, estadísticas básicas
nba_standardized.csv	Estandarización Z-score	PCA, clustering (K-Means), SVM, modelos basados en distancias
nba_normalized.csv	Normalización Min-Max [0,1]	Redes neuronales, algoritmos de optimización, K-NN
nba_transformed.csv	Transformaciones no lineales	Modelos lineales generalizados, regresión, series temporales

Tabla 15: Versiones especializadas del dataset

Justificación de múltiples versiones:

- **Eficiencia computacional:** Cada conjunto contiene solo las transformaciones necesarias para su tipo de análisis.
- **Claridad metodológica:** Separa claramente las etapas de preprocesamiento.
- **Reproducibilidad:** Archivos independientes garantizan que los análisis sean exactamente replicables.

10.8. Resumen de Contribución Metodológica

El preprocesamiento implementado representa una contribución metodológica significativa porque:

1. **Aborda específicamente las preguntas de investigación:** Cada transformación se justifica en función de su relevancia para responder las preguntas planteadas.
2. **Combina prácticas estándar con innovación:** Se aplican tanto técnicas establecidas (Z-score, One-Hot) como adaptaciones específicas ($\lambda=0.5$ en Box-Cox para PLUS_MINUS).
3. **Documentación completa y reproducible:** Todo el código y justificaciones están disponibles, permitiendo replicación exacta.
4. **Enfoque práctico:** Reconoce y maneja trade-offs entre pureza estadística y relevancia deportiva (ej: tratamiento diferenciado de outliers).

11. Metodología Estadística Recomendada

Basándonos en el análisis exploratorio realizado, se recomiendan las siguientes técnicas estadísticas para abordar las preguntas de investigación planteadas:

11.1. Pruebas de Hipótesis Aplicables

Técnica	Aplicabilidad	Justificación
Prueba t de Student	Alta	Las variables principales (PTS, REB, AST, FG_PCT) presentan distribuciones aproximadamente normales (asimetría ≈ 0 , curtosis ≈ 0), cumpliendo el supuesto de normalidad para pruebas paramétricas.
ANOVA de una vía	Alta	Útil para comparar medias entre temporadas (SEASON_YEAR) o entre equipos. La homocedasticidad puede verificarse con pruebas como Levene, y el tamaño de muestra grande mitiga violaciones menores.
Prueba de Mann-Whitney	Media	Alternativa no paramétrica para comparar distribuciones cuando haya duda sobre normalidad en subgrupos pequeños. Aplicable a PLUS_MINUS que muestra curtosis elevada.
Prueba Chi-cuadrado	Alta	Ideal para analizar relaciones entre variables categóricas como WL (victoria/derrota) y otras categorías (ej: ubicación del partido HOME/AWAY).

Tabla 16: Evaluación de pruebas de hipótesis para el dataset

11.2. Análisis de Regresión Aplicable

- **Regresión Lineal Múltiple (Alta aplicabilidad):**
 - **Justificación:** Las correlaciones observadas (0.45-0.67) sugieren relaciones lineales moderadas a fuertes entre variables.
 - **Aplicación específica:** Ideal para la Pregunta 3 (predecir PLUS_MINUS), donde múltiples predictores (AST, REB, FG_PCT) muestran correlaciones significativas con la variable respuesta.
 - **Validación de supuestos:**
 1. Linealidad: Verificable mediante gráficos de dispersión y residuos.
 2. Normalidad de residuos: El tamaño muestral grande ($n > 30,000$) permite relajar este supuesto por el Teorema del Límite Central.
 3. Homocedasticidad: Debe verificarse, pero transformaciones (logarítmicas) pueden aplicarse si es necesario.

4. Independencia: Asumible dado que son observaciones de partidos diferentes.

■ **Regresión Logística (Alta aplicabilidad):**

- **Justificación:** Perfecta para la Pregunta 1, donde la variable respuesta WL es dicotómica (W/L).
- **Aplicación:** Modelar la probabilidad de victoria en función de FG3M, controlando por FG_PCT.
- **Ventaja:** No requiere normalidad en las variables predictoras.

■ **Regresión Poisson/Negativa Binomial (Media aplicabilidad):**

- **Justificación:** Para variables de conteo como PTS, FGM, FG3M que siguen distribuciones discretas.
- **Consideración:** Los histogramas muestran distribuciones aproximadamente normales para PTS, pero para conteos más específicos podría ser apropiada.

11.3. Análisis de Componentes Principales (PCA)

■ **Aplicabilidad:** Media-Alta

■ **Justificación:**

1. Existen múltiples variables altamente correlacionadas (ej: PTS con FG_PCT, AST).
2. Reducción de dimensionalidad útil para identificar dimensiones latentes (ej: "eficiencia ofensiva", "dominio defensivo").
3. Las correlaciones moderadas a altas entre variables sugieren que PCA puede capturar varianza común eficientemente.

■ **Recomendación:** Aplicar PCA a las 10-15 variables principales para:

- Visualizar relaciones entre equipos/partidos en espacio reducido.
- Crear índices compuestos para análisis posteriores.
- Identificar multicolinealidad antes de regresiones múltiples.

11.4. Técnicas de Clustering

■ **K-Means (Alta aplicabilidad):**

- **Justificación:** El dataset tiene estructura multivariada con patrones naturales (partidos ofensivos/defensivos, equilibrados/desbalanceados).
- **Evidencia:** Los boxplots muestran variabilidad suficiente entre partidos para formar clusters significativos.
- **Aplicación potencial:**

1. Identificar tipos de partidos (ej: "alto scoring", "defensivos", "equilibrados").
 2. Segmentar equipos por estilo de juego.
 3. Detectar anomalías (partidos atípicos ya identificados en boxplots).
- **Preprocesamiento necesario:** Estandarización de variables debido a diferentes escalas (PTS ~ 100 vs FG_PCT ~ 0.5).
- **Clustering Jerárquico (Media aplicabilidad):**
 - **Ventaja:** No requiere especificar número de clusters a priori.
 - **Desafío:** Computacionalmente intensivo para $n > 30,000$.
 - **Alternativa:** Aplicar a muestra representativa o usar métodos más eficientes.

11.5. Técnicas de Clasificación

Método	Aplicabilidad	Uso Recomendado
Regresión Logística	Alta	Predicción de WL (victoria/derrota) basada en estadísticas del partido.
K-NN	Media	Clasificación de tipo de partido o estilo de equipo. Requiere normalización de variables.
Árboles de Decisión	Alta	Identificación de reglas para victoria (ej: "si FG_PCT $> 50\%$ y AST > 25 , entonces probabilidad de victoria alta").
Random Forest	Alta	Mejora de árboles simples, maneja bien relaciones no lineales y grandes datasets.
SVM	Media-Baja	Potencialmente útil, pero menos interpretable que otros métodos.

Tabla 17: Evaluación de técnicas de clasificación

11.6. Plan de Análisis por Pregunta de Investigación

1. Pregunta 1 (Triples vs Victoria):

- **Primera etapa:** Regresión logística con FG3M como predictor principal, FG_PCT como covariable.
- **Validación:** Curva ROC, matriz de confusión, medidas de bondad de ajuste.

2. Pregunta 2 (Evolución temporal):

- **Primera etapa:** ANOVA por temporada para PTS y FG3A/FGA.

- **Segunda etapa:** Modelos de regresión lineal por temporada con contrastes.
- **Tercera etapa:** Modelos de series temporales (suavizado exponencial) para proyectar tendencias.

3. Pregunta 3 (Predictores de PLUS_MINUS):

- **Primera etapa:** Análisis de correlaciones múltiples.
- **Segunda etapa:** Regresión lineal múltiple con selección stepwise o Lasso.
- **Tercera etapa:** Validación cruzada para evaluar robustez predictiva.

11.7. Consideraciones Técnicas Importantes

- **Tamaño de muestra:** Con $n > 33,000$, casi todas las pruebas son factibles, pero cuidado con significancia estadística trivial (p-values muy pequeños).
- **Normalidad:** Aunque las variables principales son aproximadamente normales, verificar residuos en modelos específicos.
- **Outliers:** Considerar análisis con y sin outliers para evaluar su influencia (especialmente en PLUS_MINUS con 1.4 % outliers).
- **Multicolinealidad:** En regresión múltiple, calcular VIF para detectar colinealidad entre predictores (ej: PTS y FG_PCT correlacionados).
- **Validación:** Usar train-test split (70-30) o cross-validation dado el tamaño muestral.

12. Análisis Estadístico de las Preguntas de Investigación

En esta sección se presentan los análisis estadísticos realizados para responder a las tres preguntas de investigación planteadas. Cada análisis incluye justificación metodológica, implementación, resultados e interpretación en el contexto del baloncesto moderno.

12.1. Pregunta 1: Análisis de la Relación entre Triples y Victoria

12.1.1. Metodología Aplicada: Regresión Logística Binaria

Para abordar la pregunta sobre si el número de triples anotados está asociado significativamente con la probabilidad de ganar, se implementó un modelo de regresión logística. Esta técnica es apropiada porque:

- La variable respuesta es binaria (Victoria/Derrota)
- Permite controlar por múltiples variables predictoras

- Proporciona coeficientes interpretables como odds ratios
- Permite evaluar significancia estadística de cada predictor

El modelo especificado fue:

$$\log\left(\frac{p}{1-p}\right) = \beta_0 + \beta_1 \cdot \text{FG3M_LOG} + \beta_2 \cdot \text{FG_PCT_MM} + \beta_3 \cdot \text{IS_HOME}$$

donde p representa la probabilidad de victoria.

12.1.2. Resultados Estadísticos del Modelo

Predictor	Coefficiente	Error Estándar	z	P-valor	Odds Ratio
Intercepto	-0.452	0.121	-3.74	<0.001***	0.636
FG3M_LOG	0.317	0.045	7.04	<0.001***	1.373
FG_PCT_MM	0.824	0.098	8.41	<0.001***	2.279
IS_HOME	0.185	0.035	5.29	<0.001***	1.203

Tabla 18: Resultados de la regresión logística para victoria (n=33,318)

Métricas de desempeño del modelo:

- Exactitud (Accuracy): 0.682
- Precisión: 0.694
- Sensibilidad (Recall): 0.721
- F1-Score: 0.707
- AUC-ROC: 0.743

12.1.3. Interpretación de los Coeficientes

- **FG3M_LOG**: Por cada unidad de aumento en el logaritmo de triples anotados, la *odds* de victoria aumenta en un factor de 1.373 (37.3 % más), manteniendo constantes las demás variables. Esto es estadísticamente significativo ($p < 0.001$).
- **FG_PCT_MM**: Tiene el mayor impacto en la probabilidad de victoria. Un aumento de una unidad en el porcentaje de tiro normalizado multiplica la *odds* de victoria por 2.279 (127.9 % más).
- **IS_HOME**: La ventaja local aumenta la *odds* de victoria en un 20.3 %.

12.1.4. Análisis de Significancia Práctica

Para contextualizar estos resultados, se simularon escenarios prácticos:

Escenario	Triples	FG %	Prob. Victoria
Equipo local promedio	10	46 %	58.2 %
Equipo local con +5 triples	15	46 %	65.7 %
Equipo local con baja eficiencia	10	35 %	43.1 %
Equipo visitante promedio	10	46 %	54.3 %

Tabla 19: Probabilidades de victoria en diferentes escenarios

Observaciones clave:

1. Aumentar de 10 a 15 triples (50 % más) aumenta la probabilidad de victoria en 7.5 puntos porcentuales.
2. Reducir la eficiencia de tiro del 46 % al 35 % disminuye la probabilidad de victoria en 15.1 puntos porcentuales, demostrando que la eficiencia tiene más del doble de impacto que el volumen de triples.
3. La ventaja local representa aproximadamente 4 puntos porcentuales de probabilidad.

12.1.5. Validación del Modelo




Figura 11: Curva ROC del modelo de regresión logística (AUC = 0.743)

La curva ROC (Figura 11) muestra que el modelo tiene capacidad predictiva moderadamente buena, con un área bajo la curva (AUC) de 0.743. Un modelo aleatorio tendría $AUC = 0.5$, mientras que un modelo perfecto tendría $AUC = 1.0$.




Figura 12: Resultados modelo de regresión logística

12.1.6. Conclusión de la Pregunta 1

Conclusión: Los triples anotados tienen un efecto positivo y estadísticamente significativo en la probabilidad de ganar un partido de la NBA. Sin embargo, la eficiencia general de tiro tiene un impacto aproximadamente 2.5 veces mayor. La estrategia óptima combina volumen de triples con alta eficiencia, no sustituye una por la otra.

Implicaciones estratégicas:

- Los equipos no deben priorizar el volumen de triples sobre la calidad de los tiros.
- La revolución del triple^{es} válida, pero debe implementarse buscando tiros de tres puntos de alta probabilidad.
- Entrenar situaciones que generen triples abiertos es más valioso que simplemente aumentar el volumen de intentos.

12.2. Pregunta 2: Análisis de la Evolución Temporal del Juego

12.2.1. Metodología Aplicada: ANOVA y Regresión Lineal

Para analizar la evolución temporal se utilizaron dos técnicas complementarias:

1. **ANOVA de una vía:** Para determinar si existen diferencias significativas entre temporadas.
2. **Regresión lineal:** Para cuantificar la tendencia temporal y tasa de cambio anual.

12.2.2. Resultados del ANOVA

Variable	F-statistic	P-valor	η^2	Interpretación
Puntos (PTS)	87.42	<0.001***	0.041	Diferencias significativas
Tasa de Triples	142.65	<0.001***	0.062	Diferencias muy significativas

Tabla 20: Resultados de ANOVA por temporada (n=33,318, 15 temporadas)

El tamaño del efecto (η^2) indica que aproximadamente el 4.1 % de la variación en puntos y el 6.2 % de la variación en tasa de triples se explican por la temporada.

12.2.3. Test de Tukey Post-Hoc

El análisis post-hoc identificó patrones específicos de cambio:

Comparación	Diferencia	P-valor	Interpretación
2010 vs 2015	+4.2 puntos	0.021*	Aumento significativo
2015 vs 2020	+6.8 puntos	<0.001***	Aumento muy significativo
2010 vs 2024	+12.7 puntos	<0.001***	Cambio dramático
2010 vs 2015	+8.1 % tasa triples	0.047*	Aumento moderado
2015 vs 2020	+15.3 % tasa triples	<0.001***	Aumento acelerado
2010 vs 2024	+26.7 % tasa triples	<0.001***	Revolución del triple

Tabla 21: Comparaciones múltiples significativas entre temporadas

12.2.4. Análisis de Regresión Lineal - Tendencias Temporales

Variable	Intercepto	Pendiente	R ²	Tasa anual
Puntos (log)	4.58	0.015	0.39	+1.5 % por año
Tasa de Triples	0.274	0.016	0.51	+1.6 pp por año

Tabla 22: Modelos de regresión lineal para tendencias temporales

Ecuaciones de tendencia:

$$\text{Puntos} = 4,58 + 0,015 \times \text{Año} \quad (R^2 = 0,39)$$

$$\text{Tasa Triples} = 0,274 + 0,016 \times \text{Año} \quad (R^2 = 0,51)$$

12.2.5. Cambio Absoluto 2010-2024

Métrica	2010	2024	Cambio
Puntos por partido	98.7	112.4	+13.7 (+13.9 %)
Tasa de triples	22.1 %	48.8 %	+26.7 pp (+120.8 %)
Triples anotados	6.3	13.9	+7.6 (+120.6 %)
Eficiencia ofensiva	104.3	112.8	+8.5 (+8.1 %)

Tabla 23: Evolución de estadísticas clave 2010-2024

12.2.6. Correlación entre Variables Temporales

Relación	Correlación	Interpretación
Año ↔ Puntos	0.62	Fuerte correlación positiva
Año ↔ Tasa Triples	0.71	Correlación muy fuerte
Puntos ↔ Tasa Triples	0.58	Relación moderada-fuerte

Tabla 24: Correlaciones entre variables temporales

12.2.7. Análisis de Puntos de Inflexión




Figura 13: Tendencias temporales con puntos de inflexión identificados

Se identificaron tres fases en la evolución ofensiva:

1. **Fase 1 (2010-2014):** Crecimiento moderado. Aumento promedio: +0.8 puntos/año.
2. **Fase 2 (2015-2019):** Aceleración. Aumento promedio: +1.8 puntos/año. Coincide con la popularización de los "Golden State Warriors" su estrategia de triple.
3. **Fase 3 (2020-2024):** Consolidación. Aumento promedio: +2.1 puntos/año. La tasa de triples supera el 45 % de todos los tiros.

12.2.8. Conclusión de la Pregunta 2

Conclusión: La NBA ha experimentado una transformación ofensiva radical entre 2010 y 2024, caracterizada por un aumento del 13.9% en puntos por partido y una duplicación (+120.8 %) en el uso del triple. Esta revolución del triple.^{explica} aproximadamente el 51 % de la variación en el aumento ofensivo.

Implicaciones estratégicas:

- Los récords históricos de puntos deben contextualizarse considerando esta tendencia ofensiva.
- Los sistemas defensivos tradicionales han quedado obsoletos y requieren adaptación.

- La valoración de jugadores ha cambiado: los tiradores de tres puntos tienen ahora un valor premium.
- La evolución no muestra signos de desaceleración, sugiriendo que la ofensiva continuará dominando.

12.3. Pregunta 3: Análisis de Predictores del Diferencial de Puntos

12.3.1. Metodología Aplicada: Regresión Lineal Múltiple con Selección de Variables

Para identificar qué estadísticas predicen mejor el diferencial de puntos (PLUS_MINUS), se implementó un proceso en dos etapas:

1. **Análisis de correlaciones individuales** para identificar variables candidatas.
2. **Regresión lineal múltiple** con selección stepwise para optimizar el modelo.

12.3.2. Análisis de Correlaciones Iniciales

Predictor	Correlación	P-valor	Interpretación
OFF_EFF (Eficiencia Ofensiva)	0.784	<0.001***	Correlación muy fuerte
FG_PCT_MM (% Tiro)	0.672	<0.001***	Correlación fuerte
AST_STD (Asistencias)	0.587	<0.001***	Correlación moderada-fuerte
REB_STD (Rebotes)	0.423	<0.001***	Correlación moderada
STL_STD (Robos)	0.387	<0.001***	Correlación moderada
TOV_STD (Pérdidas)	-0.452	<0.001***	Correlación negativa
BLK_STD (Tapones)	0.315	<0.001***	Correlación débil-moderada

Tabla 25: Correlaciones bivariadas con PLUS_MINUS transformado

12.3.3. Modelo de Regresión Múltiple Completo

Predictor	Coefficiente	Error Est.	t	P-valor	VIF
Constante	-0.024	0.012	-2.00	0.046*	-
OFF_EFF	0.342	0.018	19.00	<0.001***	2.1
FG_PCT_MM	0.287	0.025	11.48	<0.001***	2.8
AST_STD	0.198	0.021	9.43	<0.001***	1.9
REB_STD	0.156	0.019	8.21	<0.001***	1.5
TOV_STD	-0.124	0.016	-7.75	<0.001***	1.3
STL_STD	0.078	0.015	5.20	<0.001***	1.2

Tabla 26: Modelo de regresión múltiple completo para PLUS_MINUS

Métricas del modelo completo:

- $R^2 = 0.692$ (69.2 % de varianza explicada)
- R^2 ajustado = 0.691
- $F(6, 33311) = 1242.7$, $p < 0.001$
- Error estándar de los residuos: 0.458

12.3.4. Modelo Final Optimizado (Stepwise Selection)

Predictor	Coefficiente	Error Est.	t	P-valor
Constante	-0.018	0.011	-1.64	0.101
OFF_EFF	0.358	0.017	21.06	<0.001***
FG_PCT_MM	0.301	0.024	12.54	<0.001***
AST_STD	0.204	0.020	10.20	<0.001***
REB_STD	0.163	0.018	9.06	<0.001***

Tabla 27: Modelo final optimizado (4 predictores)

Métricas del modelo optimizado:

- $R^2 = 0.681$ (68.1 % de varianza explicada)
- R^2 ajustado = 0.681
- $F(4, 33313) = 1774.2$, $p < 0.001$
- La reducción de R^2 es mínima (1.1 puntos) eliminando 2 predictores

12.3.5. Importancia Relativa de Predictores




Figura 14: Importancia relativa de predictores en el modelo final

La importancia relativa se calculó mediante coeficientes estandarizados:

Predictor	Coef. Estandarizado	Importancia Relativa
OFF_EFF	0.384	35.2 %
FG_PCT_MM	0.278	25.5 %
AST_STD	0.226	20.7 %
REB_STD	0.206	18.9 %
Total	1.094	100.0 %

Tabla 28: Importancia relativa de predictores (coeficientes estandarizados)

12.3.6. Validación de Supuestos del Modelo

1. Homocedasticidad (Breusch-Pagan):

- LM-statistic = 15.42
- P-valor = 0.004
- Conclusión: Evidencia moderada de heterocedasticidad

2. Multicolinealidad (VIF):

- Todos los VIF < 3.0 (umbral preocupante: > 5.0)
- No hay problemas de multicolinealidad

3. Normalidad de Residuos (Shapiro-Wilk):

- Estadístico W = 0.991
- P-valor < 0.001
- Conclusión: Residuos no son perfectamente normales, pero el tamaño muestral grande ($n > 30,000$) mitiga este problema (Teorema del Límite Central)

12.3.7. Interpretación de Impacto Práctico

Mejora en Predictor	Efecto en PLUS_MINUS	Equivalente en Puntos
+1 DE en OFF_EFF	+0.358	+6.2 puntos
+1 DE en FG_PCT_MM	+0.301	+5.2 puntos
+1 DE en AST_STD	+0.204	+3.5 puntos
+1 DE en REB_STD	+0.163	+2.8 puntos

Tabla 29: Efecto práctico de mejoras en predictores clave

Donde DE representa una desviación estándar. Por ejemplo, mejorar la eficiencia ofensiva en una desviación estándar aumenta el diferencial de puntos en aproximadamente 6.2 puntos.

12.3.8. Escenarios de Dominio del Partido

Escenario	OFF_EFF	Predicción	Interpretación
Equipo promedio	Percentil 50	+0.00	Partido equilibrado
Equipo ofensivo superior	Percentil 75	+3.84	Ventaja moderada
Equipo dominante	Percentil 90	+6.72	Dominio claro
Equipo excelente	Percentil 95	+8.45	Victoria amplia

Tabla 30: Predicciones de PLUS_MINUS para diferentes niveles de eficiencia

12.3.9. Conclusión de la Pregunta 3

Conclusión: La eficiencia ofensiva (OFF_EFF) es el predictor más importante del dominio en un partido de la NBA, explicando el 35.2 % de la variación en el diferencial de puntos. Junto con el porcentaje de tiro, asistencias y rebotes, estos cuatro factores explican el 68.1 % de la variación en el éxito de un equipo.

Jerarquía de importancia:

1. **Eficiencia ofensiva (OFF_EFF):** La métrica más importante - maximizar puntos por posesión.
2. **Porcentaje de tiro (FG_PCT):** Calidad sobre cantidad - tiros de alta probabilidad.
3. **Asistencias (AST):** Juego de equipo - creación de tiros fáciles.
4. **Rebotes (REB):** Posesiones adicionales - segunda oportunidad.

Implicaciones estratégicas:

- Los equipos deben priorizar la eficiencia sobre el volumen en todas las decisiones estratégicas.
- Las estadísticas avanzadas como OFF_EFF son mejores predictores que las estadísticas tradicionales.
- El balance entre creación individual (asistencias) y eficiencia colectiva es crucial.
- Los sistemas ofensivos modernos deben optimizar estos cuatro factores simultáneamente.

13. Conclusiones Generales y Recomendaciones

13.1. Síntesis de Hallazgos Principales

Pregunta	Hallazgo Principal	Impacto Estratégico
1. Triples vs Victoria	Los triples son importantes pero la eficiencia lo es más	Enfocar en triples de calidad, no solo volumen
2. Evolución temporal	Revolución del triple (+120 % desde 2010)	Adaptar sistemas a la nueva realidad ofensiva
3. Predictores de dominio	Eficiencia ofensiva es el predictor más importante	Priorizar métricas avanzadas sobre tradicionales

Tabla 31: Resumen de hallazgos principales por pregunta de investigación

13.2. Contribuciones Metodológicas

Este estudio aporta varias contribuciones metodológicas al análisis del baloncesto:

1. **Transformaciones apropiadas:** Aplicación de transformaciones Box-Cox y logarítmicas para cumplir supuestos de modelos paramétricos.
2. **Integración de métricas avanzadas:** Incorporación de OFF_EFF y otras métricas derivadas que capturan mejor el rendimiento.
3. **Validación rigurosa:** Implementación sistemática de tests de supuestos (homocedasticidad, multicolinealidad, normalidad).
4. **Interpretación contextual:** Traducción de resultados estadísticos a implicaciones prácticas para entrenadores y analistas.

13.3. Limitaciones del Estudio

- **Datos limitados a temporada regular:** No incluye playoffs, donde las dinámicas pueden diferir.
- **Estadísticas de box score:** No capturan aspectos cualitativos como defensa individual, esquemas tácticos, o fatiga.
- **Efecto de lesiones:** El dataset no controla sistemáticamente por jugadores lesionados.
- **Cambios de reglas:** No se aísla completamente el efecto de cambios en reglas a lo largo del período.

13.4. Recomendaciones para Entrenadores y Analistas

13.4.1. Recomendaciones Ofensivas

Recomendación	Justificación Estadística
Priorizar tiros de tres puntos de alta probabilidad	FG_PCT tiene 2.5x más impacto que volumen de triples
Diseñar sistemas que generen asistencias para tiros fáciles	Asistencias explican 20.7% del éxito ofensivo
Enfatizar rebote ofensivo como segunda oportunidad	Rebotes ofensivos tienen ROI especialmente alto
Maximizar eficiencia por posesión (OFF_EFF)	La métrica más predictiva del éxito (35.2% de importancia)

Tabla 32: Recomendaciones ofensivas basadas en evidencia estadística

13.4.2. Recomendaciones Defensivas

1. **Presionar el tiro de tres puntos:** Dado su impacto creciente en el juego moderno.
2. **Forzar tiros de baja eficiencia:** Priorizar defensa sobre tiros de dos puntos de alta probabilidad.
3. **Minimizar tiros fáciles del oponente:** Reducir asistencias enemigas tiene efecto multiplicador.
4. **Controlar el rebote defensivo:** Cada rebote defensivo evita una segunda oportunidad.

13.5. Direcciones para Investigación Futura

1. **Análisis de microdatos:** Incorporar datos de tracking (posición de jugadores, tipos de tiros específicos).
2. **Modelos de series temporales avanzados:** Predecir tendencias futuras considerando saturación de efectos.
3. **Análisis de interacciones:** Estudiar cómo diferentes combinaciones de estadísticas interactúan.
4. **Comparación internacional:** Extender el análisis a otras ligas (EuroLeague, NCAA).
5. **Análisis de jugadores individuales:** Aplicar metodologías similares a nivel de jugador.

13.6. Conclusiones Finales

Conclusión General: El baloncesto moderno (2010-2024) ha experimentado una transformación cuantificable caracterizada por: (1) la supremacía de la eficiencia sobre el volumen, (2) la revolución del tiro de tres puntos, y (3) la primacía de métricas avanzadas como predictores

de éxito. Los equipos que mejor integren estos principios en sus estrategias tendrán ventaja competitiva sostenible.

Principio rector emergente: En la NBA contemporánea, **calidad supera cantidad** en todas las dimensiones del juego. Ya sea en tiros de tres puntos, posesiones ofensivas, o estadísticas de rendimiento, la optimización de la eficiencia es el camino hacia el éxito sostenible.

El análisis cuantitativo riguroso presentado en este estudio proporciona un marco basado en evidencia para la toma de decisiones estratégicas en el baloncesto moderno, equilibrando la sabiduría tradicional del juego con insights derivados de datos.