

Análisis Estadístico de la NBA: Reporte Completo

Análisis Exploratorio de Datos y Estadísticos Descriptivos

Dataset: Estadísticas Temporada Regular NBA (2010-2024)

Autores:

Daniela De La Caridad Guerrero Álvarez (C311)

Sammy Raul Sosa Justiz (C312)

Rubén Martínez Rojas (C311)

Índice

Introducción	3
1. Información General del Dataset	5
2. Clasificación de Variables	5
2.1. Variables Cualitativas	5
2.2. Variables Cuantitativas Discretas	5
2.3. Variables Cuantitativas Continuas	6
3. Estadísticos Descriptivos	6
3.1. Medidas de Tendencia Central y Dispersión	6
4. Distribución de Variables Cualitativas	6
4.1. Resultados de Partidos (WL)	6
4.2. Equipos con Más Registros	7
5. Tablas de Distribución Empírica de Frecuencia (TDEF)	7
5.1. Distribución de PUNTOS (PTS)	7
5.2. TDEF para PORCENTAJE DE TIROS (FG_PCT)	7
6. Análisis Gráfico de Distribuciones	8
6.1. Histogramas y Polígonos de Frecuencia Acumulada	8
6.2. Boxplots y Detección de Valores Atípicos	10
6.3. Asimetría y Curtosis	11
6.4. Síntesis del Análisis Gráfico	12
7. Distribución de Variables y Evaluación de Normalidad	12
7.1. Gráficas de Distribución – Estadísticas Principales	12
7.2. Histogramas y Curvas de Densidad (KDE)	13
7.3. Gráficos QQ – Verificación de Normalidad	14
8. Análisis de Correlaciones	15
8.1. Matriz de Correlación	15
8.2. Correlaciones Significativas	15
8.3. Conclusiones	15
9. Análisis de Outliers (Método IQR)	15
9.1. Partidos Extremos Identificados	15
9.2. Análisis de Outliers (Método IQR)	16

Introducción

Este dataset permite analizar tendencias históricas, patrones de rendimiento y factores asociados al éxito en la NBA. Las preguntas propuestas abordan temas centrales del baloncesto moderno: la importancia del triple, la evolución ofensiva y los impulsores estadísticos del rendimiento en partidos.

Pregunta 1

¿Existe una correlación significativa entre el número de triples anotados (FG3M) y la victoria (WL) de un equipo en un partido, controlando por la efectividad general de tiro (FG_PCT)?

Relevancia: El baloncesto moderno ha evolucionado hacia un mayor énfasis en el tiro de tres puntos. Entender si un alto volumen de triples está asociado con mayores probabilidades de ganar, independientemente de la efectividad general, es clave para estrategias de juego y análisis de desempeño. Esto ayuda a evaluar si la filosofía de “vivir o morir por el triple” es estadísticamente sólida.

Variables involucradas:

- **Variable respuesta:** WL (Win/Loss)
- **Variables predictoras:** FG3M (triples anotados), FG_PCT (porcentaje total de tiros de campo)

Técnicas posibles:

- Regresión logística
- Análisis de correlación parcial
- Pruebas de chi-cuadrado

Pregunta 2

¿Cómo ha cambiado la media de puntos por partido (PTS) y el porcentaje de tiros de tres puntos intentados (FG3A/FGA) a lo largo de las temporadas (SEASON_YEAR), y existe una relación temporal significativa entre ambas variables?

Relevancia: La NBA ha experimentado una “revolución del triple” en la última década. Analizar la tendencia temporal en puntos y en el uso del triple permite cuantificar la transformación ofensiva de la liga. Esto es útil para entrenadores, analistas y medios para contextualizar récords ofensivos y evoluciones estratégicas.

Variables involucradas:

- **Variable temporal:** SEASON_YEAR
- **Variables de interés:** PTS (puntos), FG3A (intentos de triple), FGA (intentos totales)

Técnicas posibles:

- Series temporales
- Regresión lineal
- Análisis de tendencia
- Comparación de medias por temporada (ANOVA)

Pregunta 3

¿Qué combinación de estadísticas de juego (por ejemplo, asistencias AST, rebotes REB, robos STL, porcentaje de tiros FG_PCT) predice de manera más robusta la diferencia de puntos (PLUS_MINUS) en un partido?

Relevancia: El plus-minus refleja el impacto neto de un equipo durante el partido. Identificar qué estadísticas de box score contribuyen más a un plus-minus positivo ayuda a priorizar métricas de rendimiento y diseñar estrategias de equipo. Es fundamental para el análisis avanzado y la evaluación de jugadores.

Variables involucradas:

- **Variable respuesta:** PLUS_MINUS
- **Variables predictoras:** AST, REB, STL, BLK, TOV, FG_PCT, FT_PCT, FG3_PCT, etc.

Técnicas posibles:

- Regresión lineal múltiple
- Selección de modelos (stepwise, lasso)
- Análisis de componentes principales

Metodología Propuesta

Fuente de Datos

- **Dataset:** regular_season_totals_2010_2024.csv

- **Período:** Temporadas 2010-2024 de la NBA
- **Observaciones:** Estadísticas por partido a nivel de equipo
- **Variables:** 52 columnas incluyendo estadísticas básicas, avanzadas y rankings

1. Información General del Dataset

Característica	Valor
Total de registros	1,231
Total de variables	52
Período cubierto	2010-2024
Equipos representados	30 equipos de la NBA
Valores nulos totales	202 (0.31 %)

Tabla 1: Características generales del dataset

2. Clasificación de Variables

2.1. Variables Cualitativas

- **Identificación:** SEASON_YEAR, TEAM_ID, TEAM_ABBREVIATION, TEAM_NAME
- **Juego:** GAME_ID, GAME_DATE, MATCHUP, WL
- **Control:** AVAILABLE_FLAG
- **Rankings categóricos:** GP_RANK, W_RANK, L_RANK

2.2. Variables Cuantitativas Discretas

- **Conteos estadísticos:** FGM, FGA, FG3M, FG3A, FTM, FTA
- **Rebotes:** OREB, DREB
- **Otras estadísticas:** AST, TOV, STL, BLK, BLKA, PF, PFD, PTS
- **Variables de ranking discretas:** W_PCT_RANK, MIN_RANK, FG_PCT_RANK, etc.

2.3. Variables Cuantitativas Continuas

- Porcentajes: FG_PCT, FG3_PCT, FT_PCT
- Estadísticas continuas: MIN, PLUS_MINUS
- Estadísticas calculadas: REB (suma de OREB + DREB)

3. Estadísticos Descriptivos

3.1. Medidas de Tendencia Central y Dispersión

Estadístico	PTS	REB	AST	FG_PCT	PLUS_MINUS
Media	124.38	43.33	28.95	0.500	17.47
Mediana	125.00	43.00	29.00	0.505	15.00
Moda	120.00	42.00	30.00	0.500	5.00
Desv. Estándar	15.25	7.43	6.06	0.046	17.31
Varianza	232.64	55.24	36.72	0.002	299.76
Coef. Variación	12.26 %	17.15 %	20.94 %	9.20 %	99.09 %
Mínimo	89.00	26.00	6.00	0.357	-28.00
Máximo	175.00	65.00	62.00	0.644	61.00
Rango	86.00	39.00	56.00	0.287	89.00
Q1	115.00	39.00	25.00	0.473	5.00
Q3	136.00	48.00	33.00	0.532	30.00
IQR	21.00	9.00	8.00	0.059	25.00

Tabla 2: Estadísticos descriptivos principales

4. Distribución de Variables Cualitativas

4.1. Resultados de Partidos (WL)

Resultado	Frecuencia	Porcentaje
Victoria (W)	615	49.96 %
Derrota (L)	616	50.04 %
Total	1,231	100.00 %

Tabla 3: Distribución de resultados de partidos

4.2. Equipos con Más Registros

Rank	Equipo	Registros	Porcentaje
1	HOU (Houston Rockets)	92	7.47 %
2	GSW (Golden State Warriors)	90	7.31 %
3	BOS (Boston Celtics)	52	4.22 %
4	POR (Portland Trail Blazers)	36	2.92 %
5	MIL (Milwaukee Bucks)	35	2.84 %
6	UTA (Utah Jazz)	33	2.68 %
7	DEN (Denver Nuggets)	27	2.19 %
8	LAC (LA Clippers)	25	2.03 %
9	NYK (New York Knicks)	23	1.87 %
10	ATL (Atlanta Hawks)	23	1.87 %

Tabla 4: Top 10 equipos con más registros en el dataset

5. Tablas de Distribución Empírica de Frecuencia (TDEF)

5.1. Distribución de PUNTOS (PTS)

Intervalo	Frecuencia	Frec. %	Frec. Acum.	Frec. Acum. %
[89,00, 99,75)	35	2.84 %	35	2.84 %
[99,75, 110,50)	138	11.21 %	173	14.05 %
[110,50, 121,25)	335	27.21 %	508	41.26 %
[121,25, 132,00)	360	29.24 %	868	70.51 %
[132,00, 142,75)	213	17.30 %	1,081	87.81 %
[142,75, 153,50)	106	8.61 %	1,187	96.42 %
[153,50, 164,25)	35	2.84 %	1,222	99.26 %
[164,25, 175,00]	9	0.73 %	1,231	100.00 %

Tabla 5: TDEF para PTS (n=1,231, Rango=86, Amplitud=10.75)

5.2. TDEF para PORCENTAJE DE TIROS (FG_PCT)

Intervalo	ni	ni (%)	Ni	Ni (%)
[0,357, 0,393)	39	3.17 %	39	3.17 %
[0,393, 0,429)	99	8.04 %	138	11.21 %
[0,429, 0,465)	226	18.36 %	364	29.57 %
[0,465, 0,501)	347	28.19 %	711	57.76 %
[0,501, 0,537)	293	23.80 %	1,004	81.56 %
[0,537, 0,573)	157	12.75 %	1,161	94.31 %
[0,573, 0,609)	57	4.63 %	1,218	98.94 %
[0,609, 0,644]	13	1.06 %	1,231	100.00 %

Tabla 6: TDEF para FG_PCT

6. Análisis Gráfico de Distribuciones

Este apartado presenta un análisis visual de las distribuciones de las principales variables cuantitativas mediante histogramas, boxplots y medidas de asimetría y curtosis. Los gráficos permiten evaluar la forma, dispersión, presencia de valores atípicos y desviaciones de la normalidad.

6.1. Histogramas y Polígonos de Frecuencia Acumulada

Los histogramas muestran la distribución de frecuencias de las variables, complementados con polígonos de frecuencias acumuladas que ilustran la progresión de los datos.




Figura 1: Histograma y polígono de frecuencias acumuladas para PTS (puntos).

Análisis de PTS (Figura 1): La distribución de puntos por partido presenta una forma aproximadamente simétrica, con media (106.04) y mediana (106.00) casi idénticas. La concentración central está entre 97 y 115 puntos ($IQR=18$). El polígono acumulado muestra una progresión suave, indicando una distribución continua sin saltos abruptos.




Figura 2: Histograma y polígono de frecuencias acumuladas para AST (asistencias).

Análisis de AST (Figura 2): Las asistencias muestran una distribución ligeramente

asimétrica hacia la derecha, con media (23.38) ligeramente superior a la mediana (23.00). La mayoría de los valores se concentran entre 20 y 27 asistencias ($IQR=7$).




Figura 3: Histograma y polígono de frecuencias acumuladas para REB (rebotes).

Análisis de REB (Figura 3): La distribución de rebotes es aproximadamente simétrica (media=43.44, mediana=43.00). El rango intercuartílico ($IQR=9$) indica una dispersión moderada alrededor de la mediana.




Figura 4: Histograma y polígono de frecuencias acumuladas para FG_PCT (porcentaje de tiros de campo).

Análisis de FG_PCT (Figura 4): El porcentaje de tiro presenta una distribución casi simétrica con media y mediana en 0.46. La concentración central es notable, con la mayoría de valores entre 0.42 y 0.50 ($IQR=0.08$). La forma sugiere una distribución normal.




Figura 5: Histograma para PLUS_MINUS (diferencial de puntos).

Análisis de PLUS_MINUS (Figura 5): Esta variable presenta una distribución simétrica centrada en cero (media=0.00, mediana=0.00), como era esperable dado que representa el balance entre equipos. Sin embargo, muestra colas más pesadas que una normal, indicando presencia de partidos con diferenciales extremos.

6.2. Boxplots y Detección de Valores Atípicos

Los diagramas de caja (boxplots) resumen la distribución mediante cuartiles y permiten identificar valores atípicos (outliers) de manera visual.




Figura 6: Boxplots de las principales variables del dataset.

Análisis de Boxplots (Figura 6):

- **PTS:** La caja está centrada alrededor de 106 puntos. Se identifican 231 outliers (0.7% del total), correspondientes a partidos con puntuaciones excepcionalmente altas o bajas.

- **AST**: Distribución relativamente simétrica con mediana en 23 asistencias. 260 outliers (0.8 %) representan partidos con volumen extremo de asistencias.
- **FG_PCT**: La caja muestra poca dispersión ($IQR=0.14$), confirmando la consistencia en el porcentaje de tiro. Los 275 outliers (0.8 %) corresponden a partidos con eficiencia de tiro atípica.
- **REB**: Distribución simétrica con mediana en 43 rebotes. 229 outliers (0.7 %) identifican partidos con volumen anormal de rebotes.
- **PLUS_MINUS**: Aunque centrado en cero, presenta el mayor porcentaje de outliers (1.4 %, 460 casos), indicando partidos con diferenciales extremadamente positivos o negativos.

6.3. Asimetría y Curtosis

Las medidas de asimetría y curtosis cuantifican desviaciones de la distribución normal.




Figura 7: Medidas de asimetría y curtosis para las variables principales.

Análisis de Asimetría y Curtosis (Figura 7):

- **Asimetría (Skewness):**
 - Valores cercanos a cero indican distribuciones simétricas.
 - PTS, REB y FG_PCT muestran asimetría mínima (próxima a 0).
 - PLUS_MINUS tiene asimetría cercana a cero, confirmando su distribución balanceada.
 - AST presenta ligera asimetría positiva (cola derecha más larga).
- **Curtosis:**
 - Mide el "apuntamiento" de la distribución respecto a la normal.
 - Valores cercanos a 0 indican curtosis similar a la normal.

- PLUS_MINUS muestra mayor curtosis, indicando colas más pesadas y pico más pronunciado.
- FG_PCT tiene curtosis negativa, sugiriendo distribución más aplanada que la normal.

6.4. Síntesis del Análisis Gráfico

- **Normalidad:** La mayoría de variables (PTS, REB, AST, FG_PCT) presentan distribuciones aproximadamente normales, con asimetría y curtosis cercanas a cero.
- **Outliers:** Todas las variables presentan valores atípicos, siendo PLUS_MINUS la que mayor porcentaje muestra (1.4 %). Estos outliers representan partidos con desempeños estadísticamente excepcionales.
- **Consistencia:** FG_PCT muestra la menor dispersión relativa, indicando que el porcentaje de tiro es una métrica más estable que otras como asistencias o rebotes.
- **Simetría:** La simetría general de las distribuciones valida el uso de estadísticos paramétricos para análisis posteriores.
- **Balance competitivo:** La distribución simétrica de PLUS_MINUS alrededor de cero refleja el equilibrio competitivo de la NBA en el período analizado.

7. Distribución de Variables y Evaluación de Normalidad

7.1. Gráficas de Distribución – Estadísticas Principales




Figura 8: Diagramas de caja (Boxplots) para PTS, AST, REB, FG_PCT y PLUS_MINUS

Análisis de Boxplots:

- Las distribuciones muestran cola derecha moderada en variables como PTS y REB, sugiriendo presencia de valores extremos por encima del promedio.
- La variable PLUS_MINUS presenta alta dispersión y outliers tanto en extremos superiores como inferiores, lo que indica diferencias inusuales en algunos partidos.
- FG_PCT muestra menor dispersión relativa y menos outliers, reflejando una mayor concentración alrededor de la media.

7.2. Histogramas y Curvas de Densidad (KDE)




Figura 9: Histogramas con curvas KDE, medias, medianas y desviaciones estándar para variables clave

Análisis de Histogramas y KDE:

- Las distribuciones de PTS, AST y REB muestran formas aproximadamente simétricas, aunque con cierta asimetría positiva (sesgo derecho).
- El histograma de STL y otras variables discretas presenta más variabilidad y picos, lo que se asocia a la naturaleza de conteo de estos registros.
- En general, las curvas KDE refuerzan la observación de que FG_PCT tiene menor variabilidad relativa.

7.3. Gráficos QQ – Verificación de Normalidad




Figura 10: Gráficos QQ para PTS, AST, REB y FG_PCT con pruebas de normalidad

Análisis de Normalidad:

- En los gráficos QQ se observa que los puntos se desvían de la línea teórica en los extremos para todas las variables principales (PTS, AST, REB, FG_PCT).
- Las pruebas estadísticas (Shapiro–Wilk y Kolmogorov–Smirnov con $p < 0.05$) rechazan la hipótesis nula de normalidad para estas variables.
- Aunque algunas variables se aproximan a una distribución normal en la parte central, los extremos y colas muestran desviaciones significativas.

Conclusión sobre Normalidad: Si bien varias estadísticas presentan distribuciones cercanas a normal en la parte central, el conjunto completo de datos no sigue estrictamente una distribución normal. Esto debe tenerse en cuenta al aplicar métodos que asumen normalidad estricta.

8. Análisis de Correlaciones

8.1. Matriz de Correlación

	PTS	REB	AST	FG_PCT	PLUS_MINUS
PTS	1.0000	0.4523	0.5728	0.6731	0.6142
REB	0.4523	1.0000	0.3245	0.2104	0.3251
AST	0.5728	0.3245	1.0000	0.3427	0.4503
FG_PCT	0.6731	0.2104	0.3427	1.0000	0.5214
PLUS_MINUS	0.6142	0.3251	0.4503	0.5214	1.0000

Tabla 7: Matriz de correlación entre variables principales

8.2. Correlaciones Significativas

- **PTS - FG_PCT:** 0.6731 (correlación alta positiva) - La efectividad de tiro explica gran parte de la variación en puntos.
- **PTS - AST:** 0.5728 (correlación moderada-alta positiva) - Las asistencias contribuyen significativamente a la generación de puntos.
- **PTS - REB:** 0.4523 (correlación moderada positiva) - Los rebotes tienen menor correlación con puntos que las asistencias.
- **FG_PCT - PLUS_MINUS:** 0.5214 (correlación moderada) - La efectividad de tiro está relacionada con el diferencial de puntos.

8.3. Conclusiones

El análisis demuestra que la NBA actual presenta una alta eficiencia de tiro ($\bar{x} = 50\%$). La fuerte correlación entre FG_PCT y PTS ($r = 0,67$) confirma que la efectividad es el predictor primario del volumen anotador, por encima del volumen de rebotes.

9. Análisis de Outliers (Método IQR)

Variable	Total	Outliers	%	Límite Inf.	Límite Sup.
PTS	1,231	47	3.82 %	83.5	167.5
REB	1,231	36	2.92 %	25.5	61.5
AST	1,231	25	2.03 %	13.0	45.0
PLUS_MINUS	1,231	83	6.74 %	-32.5	67.5

Tabla 8: Detección de outliers usando método IQR ($Q1 - 1.5 \cdot IQR$, $Q3 + 1.5 \cdot IQR$)

9.1. Partidos Extremos Identificados

- **Máximo de puntos:** 175 puntos (outlier superior)

- **Mínimo de puntos:** 89 puntos (no es outlier)
- **Máximo de rebotes:** 65 rebotes (outlier superior)
- **Máximo de asistencias:** 62 asistencias (outlier superior)
- **Máximo plus/minus:** +61 (outlier superior)
- **Mínimo plus/minus:** -28 (no es outlier)

9.2. Análisis de Outliers (Método IQR)

Se detectaron valores atípicos significativos en la variable `PLUS_MINUS` (6.74 %), lo que refleja partidos con diferencias de puntuación inusualmente altas para el promedio de la liga.

Conclusiones Finales

- El análisis exploratorio revela distribuciones normales para la mayoría de las variables estadísticas principales.
- Las correlaciones más fuertes se observan entre puntos y porcentaje de tiro, confirmando la importancia de la eficiencia en el baloncesto moderno.
- La detección de outliers indica partidos extremos que podrían merecer análisis más detallado.
- El dataset presenta alta calidad de datos con valores nulos mínimos y consistencia en las relaciones entre variables.