

Análisis Estadístico de la NBA: Reporte Completo

Análisis Exploratorio de Datos y Estadísticos Descriptivos

Dataset: Estadísticas Temporada Regular NBA (2010-2024)

Autores:

Daniela De La Caridad Guerrero Álvarez (C311)

Sammy Raul Sosa Justiz (C312)

Rubén Martínez Rojas (C311)

Índice

Introducción	2
1. Información General del Dataset	4
2. Clasificación de Variables	4
2.1. Variables Cualitativas	4
2.2. Variables Cuantitativas Discretas	4
2.3. Variables Cuantitativas Continuas	5
3. Estadísticos Descriptivos	5
3.1. Medidas de Tendencia Central y Dispersión	5
4. Distribución de Variables Cualitativas	5
4.1. Resultados de Partidos (WL)	5
4.2. Equipos con Más Registros	6
5. Tablas de Distribución Empírica de Frecuencia (TDEF)	6
5.1. Distribución de PUNTOS (PTS)	6
5.2. TDEF para PORCENTAJE DE TIROS (FG_PCT)	6
6. Análisis de Correlaciones	7
6.1. Matriz de Correlación	7
6.2. Correlaciones Significativas	7
6.3. Conclusiones	7
7. Análisis de Outliers (Método IQR)	7
7.1. Partidos Extremos Identificados	7
7.2. Análisis de Outliers (Método IQR)	8
8. Análisis Estadístico de Preguntas de Investigación	8
8.1. Pregunta 1: Correlación FG3M vs Victoria	8
8.1.1. Análisis Chi-Cuadrado	8
8.1.2. Regresión Logística	8
8.2. Pregunta 2: Evolución Temporal de PTS y Triples	9
8.2.1. Regresión Lineal Simple	9
8.2.2. ANOVA por Temporada	9
8.3. Pregunta 3: Predictores de PLUS_MINUS	9
8.3.1. Regresión Lineal Múltiple	9
Conclusiones Finales	10

Introducción

Este dataset permite analizar tendencias históricas, patrones de rendimiento y factores asociados al éxito en la NBA. Las preguntas propuestas abordan temas centrales del baloncesto moderno: la importancia del triple, la evolución ofensiva y los impulsores estadísticos del rendimiento en partidos.

Pregunta 1

¿Existe una correlación significativa entre el número de triples anotados (FG3M) y la victoria (WL) de un equipo en un partido, controlando por la efectividad general de tiro (FG_PCT)?

Relevancia: El baloncesto moderno ha evolucionado hacia un mayor énfasis en el tiro de tres puntos. Entender si un alto volumen de triples está asociado con mayores probabilidades de ganar, independientemente de la efectividad general, es clave para estrategias de juego y análisis de desempeño. Esto ayuda a evaluar si la filosofía de “vivir o morir por el triple” es estadísticamente sólida.

Variables involucradas:

- **Variable respuesta:** WL (Win/Loss)
- **Variables predictoras:** FG3M (triples anotados), FG_PCT (porcentaje total de tiros de campo)

Técnicas posibles:

- Regresión logística
- Análisis de correlación parcial
- Pruebas de chi-cuadrado

Pregunta 2

¿Cómo ha cambiado la media de puntos por partido (PTS) y el porcentaje de tiros de tres puntos intentados (FG3A/FGA) a lo largo de las temporadas (SEASON_YEAR), y existe una relación temporal significativa entre ambas variables?

Relevancia: La NBA ha experimentado una “revolución del triple” en la última década. Analizar la tendencia temporal en puntos y en el uso del triple permite cuantificar la transformación ofensiva de la liga. Esto es útil para entrenadores, analistas y medios para contextualizar récords ofensivos y evoluciones estratégicas.

Variables involucradas:

- **Variable temporal:** SEASON_YEAR
- **Variables de interés:** PTS (puntos), FG3A (intentos de triple), FGA (intentos totales)

Técnicas posibles:

- Series temporales
- Regresión lineal
- Análisis de tendencia
- Comparación de medias por temporada (ANOVA)

Pregunta 3

¿Qué combinación de estadísticas de juego (por ejemplo, asistencias AST, rebotes REB, robos STL, porcentaje de tiros FG_PCT) predice de manera más robusta la diferencia de puntos (PLUS_MINUS) en un partido?

Relevancia: El plus-minus refleja el impacto neto de un equipo durante el partido. Identificar qué estadísticas de box score contribuyen más a un plus-minus positivo ayuda a priorizar métricas de rendimiento y diseñar estrategias de equipo. Es fundamental para el análisis avanzado y la evaluación de jugadores.

Variables involucradas:

- **Variable respuesta:** PLUS_MINUS
- **Variables predictoras:** AST, REB, STL, BLK, TOV, FG_PCT, FT_PCT, FG3_PCT, etc.

Técnicas posibles:

- Regresión lineal múltiple
- Selección de modelos (stepwise, lasso)
- Análisis de componentes principales

Metodología Propuesta

Fuente de Datos

- **Dataset:** regular_season_totals_2010_2024.csv

- **Período:** Temporadas 2010-2024 de la NBA
- **Observaciones:** Estadísticas por partido a nivel de equipo
- **Variables:** 52 columnas incluyendo estadísticas básicas, avanzadas y rankings

1. Información General del Dataset

Característica	Valor
Total de registros	1,231
Total de variables	52
Período cubierto	2010-2024
Equipos representados	30 equipos de la NBA
Valores nulos totales	202 (0.31 %)

Tabla 1: Características generales del dataset

2. Clasificación de Variables

2.1. Variables Cualitativas

- **Identificación:** SEASON_YEAR, TEAM_ID, TEAM_ABBREVIATION, TEAM_NAME
- **Juego:** GAME_ID, GAME_DATE, MATCHUP, WL
- **Control:** AVAILABLE_FLAG
- **Rankings categóricos:** GP_RANK, W_RANK, L_RANK

2.2. Variables Cuantitativas Discretas

- **Conteos estadísticos:** FGM, FGA, FG3M, FG3A, FTM, FTA
- **Rebotes:** OREB, DREB
- **Otras estadísticas:** AST, TOV, STL, BLK, BLKA, PF, PFD, PTS
- **Variables de ranking discretas:** W_PCT_RANK, MIN_RANK, FG_PCT_RANK, etc.

2.3. Variables Cuantitativas Continuas

- Porcentajes: FG_PCT, FG3_PCT, FT_PCT
- Estadísticas continuas: MIN, PLUS_MINUS
- Estadísticas calculadas: REB (suma de OREB + DREB)

3. Estadísticos Descriptivos

3.1. Medidas de Tendencia Central y Dispersión

Estadístico	PTS	REB	AST	FG_PCT	PLUS_MINUS
Media	124.38	43.33	28.95	0.500	17.47
Mediana	125.00	43.00	29.00	0.505	15.00
Moda	120.00	42.00	30.00	0.500	5.00
Desv. Estándar	15.25	7.43	6.06	0.046	17.31
Varianza	232.64	55.24	36.72	0.002	299.76
Coef. Variación	12.26 %	17.15 %	20.94 %	9.20 %	99.09 %
Mínimo	89.00	26.00	6.00	0.357	-28.00
Máximo	175.00	65.00	62.00	0.644	61.00
Rango	86.00	39.00	56.00	0.287	89.00
Q1	115.00	39.00	25.00	0.473	5.00
Q3	136.00	48.00	33.00	0.532	30.00
IQR	21.00	9.00	8.00	0.059	25.00

Tabla 2: Estadísticos descriptivos principales

4. Distribución de Variables Cualitativas

4.1. Resultados de Partidos (WL)

Resultado	Frecuencia	Porcentaje
Victoria (W)	615	49.96 %
Derrota (L)	616	50.04 %
Total	1,231	100.00 %

Tabla 3: Distribución de resultados de partidos

4.2. Equipos con Más Registros

Rank	Equipo	Registros	Porcentaje
1	HOU (Houston Rockets)	92	7.47 %
2	GSW (Golden State Warriors)	90	7.31 %
3	BOS (Boston Celtics)	52	4.22 %
4	POR (Portland Trail Blazers)	36	2.92 %
5	MIL (Milwaukee Bucks)	35	2.84 %
6	UTA (Utah Jazz)	33	2.68 %
7	DEN (Denver Nuggets)	27	2.19 %
8	LAC (LA Clippers)	25	2.03 %
9	NYK (New York Knicks)	23	1.87 %
10	ATL (Atlanta Hawks)	23	1.87 %

Tabla 4: Top 10 equipos con más registros en el dataset

5. Tablas de Distribución Empírica de Frecuencia (TDEF)

5.1. Distribución de PUNTOS (PTS)

Intervalo	Frecuencia	Frec. %	Frec. Acum.	Frec. Acum. %
[89,00, 99,75)	35	2.84 %	35	2.84 %
[99,75, 110,50)	138	11.21 %	173	14.05 %
[110,50, 121,25)	335	27.21 %	508	41.26 %
[121,25, 132,00)	360	29.24 %	868	70.51 %
[132,00, 142,75)	213	17.30 %	1,081	87.81 %
[142,75, 153,50)	106	8.61 %	1,187	96.42 %
[153,50, 164,25)	35	2.84 %	1,222	99.26 %
[164,25, 175,00]	9	0.73 %	1,231	100.00 %

Tabla 5: TDEF para PTS (n=1,231, Rango=86, Amplitud=10.75)

5.2. TDEF para PORCENTAJE DE TIROS (FG_PCT)

Intervalo	ni	ni (%)	Ni	Ni (%)
[0,357, 0,393)	39	3.17 %	39	3.17 %
[0,393, 0,429)	99	8.04 %	138	11.21 %
[0,429, 0,465)	226	18.36 %	364	29.57 %
[0,465, 0,501)	347	28.19 %	711	57.76 %
[0,501, 0,537)	293	23.80 %	1,004	81.56 %
[0,537, 0,573)	157	12.75 %	1,161	94.31 %
[0,573, 0,609)	57	4.63 %	1,218	98.94 %
[0,609, 0,644]	13	1.06 %	1,231	100.00 %

Tabla 6: TDEF para FG_PCT

6. Análisis de Correlaciones

6.1. Matriz de Correlación

	PTS	REB	AST	FG_PCT	PLUS_MINUS
PTS	1.0000	0.4523	0.5728	0.6731	0.6142
REB	0.4523	1.0000	0.3245	0.2104	0.3251
AST	0.5728	0.3245	1.0000	0.3427	0.4503
FG_PCT	0.6731	0.2104	0.3427	1.0000	0.5214
PLUS_MINUS	0.6142	0.3251	0.4503	0.5214	1.0000

Tabla 7: Matriz de correlación entre variables principales

6.2. Correlaciones Significativas

- **PTS - FG_PCT:** 0.6731 (correlación alta positiva) - La efectividad de tiro explica gran parte de la variación en puntos.
- **PTS - AST:** 0.5728 (correlación moderada-alta positiva) - Las asistencias contribuyen significativamente a la generación de puntos.
- **PTS - REB:** 0.4523 (correlación moderada positiva) - Los rebotes tienen menor correlación con puntos que las asistencias.
- **FG_PCT - PLUS_MINUS:** 0.5214 (correlación moderada) - La efectividad de tiro está relacionada con el diferencial de puntos.

6.3. Conclusiones

El análisis demuestra que la NBA actual presenta una alta eficiencia de tiro ($\bar{x} = 50\%$). La fuerte correlación entre FG_PCT y PTS ($r = 0,67$) confirma que la efectividad es el predictor primario del volumen anotador, por encima del volumen de rebotes.

7. Análisis de Outliers (Método IQR)

Variable	Total	Outliers	%	Límite Inf.	Límite Sup.
PTS	1,231	47	3.82 %	83.5	167.5
REB	1,231	36	2.92 %	25.5	61.5
AST	1,231	25	2.03 %	13.0	45.0
PLUS_MINUS	1,231	83	6.74 %	-32.5	67.5

Tabla 8: Detección de outliers usando método IQR ($Q1 - 1.5 \cdot IQR$, $Q3 + 1.5 \cdot IQR$)

7.1. Partidos Extremos Identificados

- **Máximo de puntos:** 175 puntos (outlier superior)

- **Mínimo de puntos:** 89 puntos (no es outlier)
- **Máximo de rebotes:** 65 rebotes (outlier superior)
- **Máximo de asistencias:** 62 asistencias (outlier superior)
- **Máximo plus/minus:** +61 (outlier superior)
- **Mínimo plus/minus:** -28 (no es outlier)

7.2. Análisis de Outliers (Método IQR)

Se detectaron valores atípicos significativos en la variable PLUS_MINUS (6.74 %), lo que refleja partidos con diferencias de puntuación inusualmente altas para el promedio de la liga.

8. Análisis Estadístico de Preguntas de Investigación

8.1. Pregunta 1: Correlación FG3M vs Victoria

8.1.1. Análisis Chi-Cuadrado

Objetivo: Determinar si existe asociación significativa entre FG3M y WL.

FG3M	Derrota	Victoria	Total
Bajo	115	82	197
Medio	362	507	869
Alto	29	136	165

Tabla 9: Tabla de contingencia FG3M vs WL

Estadístico	Valor
χ^2	62.12
Grados de libertad	2
Valor p	<0.001
V de Cramér	0.225

Tabla 10: Resultados Chi-Cuadrado ($\alpha = 0.05$)

8.1.2. Regresión Logística

Modelo: $\log\left(\frac{P(Win)}{1-P(Win)}\right) = \beta_0 + \beta_1 \cdot FG3M + \beta_2 \cdot FG_PCT$

Variable	Coficiente	Odds Ratio
FG3M	0.64	1.90
FG_PCT	0.45	1.56

Tabla 11: Coeficientes de regresión logística

Conclusión: La filosofía de vivir o morir por el triple tiene respaldo estadístico.

8.2. Pregunta 2: Evolución Temporal de PTS y Triples

8.2.1. Regresión Lineal Simple

Objetivo: Cuantificar la relación temporal entre la temporada y PTS/FG3A.

Variable	Pendiente	R^2	Valor p	Sig.
PTS	+1.64 pts/temp	0.975	<0.001	Sí
FG3A/FGA	+1.71 %/temp	0.988	<0.001	Sí

Tabla 12: Regresión lineal simple ($\alpha = 0.05$)

8.2.2. ANOVA por Temporada

Objetivo: Verificar diferencias significativas entre temporadas.

Variable	F	Valor p	Decisión
PTS	32.30	<0.001	Rechazar H_0
FG3A/FGA	48.61	<0.001	Rechazar H_0

Tabla 13: ANOVA por temporada ($\alpha = 0.05$)

Conclusión: La NBA ha experimentado una transformación ofensiva significativa, con aumentos de 1.6 puntos y 1.7% en triples por temporada.

8.3. Pregunta 3: Predictores de PLUS_MINUS

8.3.1. Regresión Lineal Múltiple

Objetivo: Identificar qué estadísticas predicen mejor PLUS_MINUS.

Variable	β	Error	t	p-valor
AST	0.809	0.040	20.17	<0.001***
REB	0.490	0.035	14.15	<0.001***
STL	1.483	0.116	12.75	<0.001***
TOV	-1.562	0.080	-19.62	<0.001***
FG_PCT	85.228	4.715	18.08	<0.001***

Tabla 14: Coeficientes de regresión. ***p<0.001

Estadístico	Valor
R^2	0.549
R^2 ajustado	0.547
F-estadístico	298.36

Tabla 15: Bondad de ajuste

Conclusión: El modelo explica el 54.9% de la variabilidad. FG_PCT es el predictor más fuerte.

Conclusiones Finales

- El análisis exploratorio revela distribuciones normales para la mayoría de las variables estadísticas principales.
- Las correlaciones más fuertes se observan entre puntos y porcentaje de tiro, confirmando la importancia de la eficiencia en el baloncesto moderno.
- La detección de outliers indica partidos extremos que podrían merecer análisis más detallado.
- El dataset presenta alta calidad de datos con valores nulos mínimos y consistencia en las relaciones entre variables.